



人工智能：两落三起



人工智能学习特点

- 1模型存在不可解释，不可泛化等问题——关联并未反映客观自然科学规律
- 2深度学习等人工智能学习特点：数据驱动的关联学习

关联的三种来源



自然语言合成的核心神经网络是Transformer 模型

GPT 训练:

1.自监督 挖空练习

2.提示学习与指令微调：指令微调，是指在已经训练好的语言模型的基础上，通过使用有标注的特定任务数据进行进一步的微调，从而使得模型具备遵循指令的能力

3.人类反馈 强化学习

大模型的训练特点：数据驱动 关联学习

sora超级涌现力：最小单元进行关联组合

3. 时空子块有意义的时序组合 (Sora的原理)

- 最小单元：时空子块 (Video Patch)。你可以把它想象成一个既有空间信息（画面内容），又有时间信息（运动变化）的小立方体。
- 组合方式：时序（时间上的先后顺序）+ 空间。
- 含义：Sora生成视频时，它理解物体是如何运动的。比如，它知道一辆车在下一秒应该出现在哪里，而不是凭空消失或瞬移。它将一系列连续的“时空子块”拼接起来，就形成了一段流畅、符合物理规律的视频。

总结

所以，这张幻灯片想告诉你的是：

- 从Chat到Sora，技术的本质是相通的：都是对“最小单元”进行“有意义的关联组合”。
- 这种能力被称为“超级涌现力”：当AI掌握了足够多的关联规则后，它就能创造出我们从未见过但又觉得非常真实、合理的全新内容（文本、图像、视频）。
- 这标志着AI的能力边界在不断扩大：从处理一维的文字，到二维的图像，再到三维的时空视频。

因果如何赋能大模型:

1.因果去除数据偏置

2.因果支撑决策

3.因果赋能transformer

AGI三个通用世界模型:

简单来说，目前的AI往往偏科（有的擅长聊天，有的擅长看图），而未来的AGI需要是一个全能选手。这张图把AGI的能力拆解为了三个空间维度的叠加。

以下是详细解读：

1. 左边的模型：Large Language Model (LLM)

- **对应维度：语义空间**
- **核心能力：** 处理语言、符号、逻辑和知识。
- **解读：** 这是目前最成熟的领域（比如ChatGPT）。它让AI拥有了“大脑”层面的语言能力，能够理解人类的指令、进行推理、生成文本。它构建了一个基于文字和概念的虚拟世界。
- **作用：** 负责AGI的**认知与沟通**。

2. 中间的模型：Embodied AI (具身智能)

- **对应维度：物理空间**
- **核心能力：** 感知、行动、与真实世界交互。
- **解读：** 图中展示了机器人（Robots）在真实世界（Real-World）和模拟环境（Simulation）中导航（Navigation）和互动（Interaction）。这部分强调AI不能只活在服务器里，必须要有“身体”，能够理解物理定律（重力、碰撞等），并能在三维空间中移动和操作物体。
- **作用：** 负责AGI的**行动与感知**（即像人一样在物理世界中生存）。

3. 右边的模型：Large Data Model (LDM)

- **对应维度：数据空间**
- **核心能力：** 处理复杂的结构化数据、预测趋势、优化决策。
- **解读：** 图中展示了一个问号“？”，这暗示了这是目前还在探索或定义的领域。它不仅仅是处理文本或图像，而是处理更抽象的“数字数据”。比如金融市场的波动、气象数据的变化、或者复杂的科学计算。
- **作用：** 负责AGI的**量化分析与宏观决策**（处理人类语言描述不了的复杂数据规律）。

核心结论：什么是AGI？

幻灯片底部的定义总结了一切：

AGI是一种能够在几乎所有认知任务上匹配或超越人类能力的人工智能。

总结这张图的意思：

要实现真正的AGI，我们需要把这三个模型加起来：

- **LLM（语义）** 提供智慧的大脑；
- **Embodied AI（物理）** 提供行动的手脚和感官；
- **LDM（数据）** 提供处理复杂世界规律的能力。

只有这三者融合，AI才能既懂语言，又懂物理世界，还能处理复杂数据，从而真正像人类一样全面。

任何能够满足大量分布变化的遗憾界限的智能体都必须学会近似的因果模型

- 结论1：在理想情况下（最优策略），智能体的策略足以还原出环境中的因果图（Causal Bayesian Network）。
- 结论2：即使策略不是最优（有一定遗憾），也能学到一个近似的因果模型，误差随遗憾值线性增长。
- 结论3：有了因果模型，就能找到遗憾有界的策略（双向等价）。

因果世界模型驱动的Agent

将智能体与因果世界模型结合
把“因果世界模型”嵌入Agent，让Agent能基于干预/因果变量进行想象与规划，在环境变化与任务切换下保持鲁棒泛化

LLM处理结构化数据的局限性

◆ 数据层：文本数据为主，图片、视频数据为辅，结构化数据<1%

根据 OpenAI公布的数据分析，GPT-4 预训练数据集包括约 13 万亿 token 的文本数据，占比约 85%；及2万亿token 的图片等视觉数据，占比约 15%。

◆ 技术层：tokenization无法有效处理数值



文本序列: "我喜欢吃水果，尤其是香蕉"

切分token: 我, 喜欢, 吃, 水果, , 尤其, 是, 香蕉

文本序列: 9.11<9.9

切分token: 9, ., 11, <, 9., 9

◆ 应用层：难以解决数据维度的基本应用，如分类、计算、预测等



LLM无法触及工业领域核心业务场景


LLM学习海量数据
而LDM学习数据的因果关系

一、因果与关联


模型优化从性能第一到风险控制

为什么从关联到因果推理？

1. 不可解释





2. 不可用于支撑决策



3. 不稳定，随着时间数据环境变化而变化。绝大多数机器学习方法需要独立同分布假设




数据驱动
关联学习



52

4. 关联数据带来不公平性问题



T: 肤色
X: 收入
Y: 犯罪率

收入—犯罪率: 强相关
肤色—犯罪率: 强相关



收入—犯罪率: 强因果
肤色—犯罪率: 弱因果

53

关联学习导致人工智能的不能


- 关联不可解释，因果提升模型可解释性
- 关联不可决策，因果助力模型决策能力
- 虚假关联不稳定，因果关联具有不变性
- 虚假关联不公平，因果关联确保公平性

因果让不能
变成可能，
实现因果可
信人工智能

54

因果关系的三个层级：

- 问题主要根源：因果机制尚未融入机器学习



将因果引入机器学习，提升模型稳定性、可解释性和决策能力

55

关联-干预-反事实

关联：

定义：两个或多个变量之间存在的一种统计依赖关系，当其中一个变量的取值发生变化时，另一个变量的取值也倾向于随之发生规律性变化

两个关键条件：描述了一种共变模式、不蕴含方向性

真实案例：

- 下课铃响起时，学生们同时走出教室
- 下雨天中，行人撑起伞时，地面同时变湿

因果：

引起和被引起的关系，原因和结果。

定义：在控制相关变量不变的前提下，当一个变量（因）的取值发生变化时，另一个变量（果）的取值也会发生相应的改变

两个关键条件：保持其他相关变量不变条件下改变因变量，具有方向性

真实案例：

- 在控制其他因素不变的条件下，下课铃响起后，学生们就会走出教室

因果与关联区别

关联与因果的区别

(1) **是描述现象还是解释机制**：关联止步于对变量间自然发生的**共变现象**进行描述；因果则致力于阐明变量间共变现象内在的**驱动机制**

(2) **是双向相关还是单向作用**：关联仅表明变量间存在统计相依性，**不预设方向**；因果则严格遵循**从因到果的单向路径**，且原因必须先于结果发生

(3) **是观察测量还是控制验证**：关联的成立仅依赖于在**自然状态下对数据的观察与测量**；而因果关系的确立，则必须**依靠实验或统计方法主动控制相关变量**，以进行严格的验证


混淆偏差

由于共同的原因产生非因果关联。

定义：两个变量T和Y之间由于一个**共同的原因变量X**产生的非因果关联

混淆变量：共同的原因变量X

真实的因果效应：当**控制混淆变量不变时**，**改变变量T**引起的变量Y的变化




选择偏差

定义：两个变量T和Y之间由于**非随机样本选择**而**控制了一个共同的结果变量S**产生的非因果关联


非随机样本选择：收集样本过程中**受到某些变量的影响**，导致收集到的样本并非从总体随机采样的代表性样本

真实的因果效应：当**未控制共同结果变量**时，**改变变量T**引起的变量Y的变化



随机对照实验

评估教育对收入的影响



- 分析**读书**与**收入**之间的因果效应
 - 随机对照实验：做实验、发问卷
 - 干预变量 $T=1/0$ ：是否高中毕业
 - 结果变量 Y：收入
- 实际应用中，RCT也可能存在**选择偏差**
 - 如**高中毕业但收入低**的受访者，**不愿意**回答
 - 而**高中未毕业但收入高**的，**非常愿意**回答
 - 选择变量 S，由 T 和 Y（甚至 X）同时影响
 - $S=1$: X, T, Y
 - $S=0$: X, T

非随机样本选择不等于选择偏差，必须非随机样本选择与关心的原因和结果变量有关才行

小结1

人工智能学习特点：数据驱动 **关联学习** 概率输出

1.2潜在结果框架

因果效应估计

- 干预变量: $T = 1$ 或 $T = 0$
- 潜在结果变量: $Y(T = 1)$ 和 $Y(T = 0)$
- 个体因果效应 (Individual Treatment Effect, ITE) :

$$ITE(i) = Y_i(T_i = 1) - Y_i(T_i = 0)$$

- 平均因果效应 (Average Treatment Effect, ATE) :

$$ATE = E[Y(T = 1) - Y(T = 0)]$$

- **反事实问题**: $Y(T = 1)$ 或 $Y(T = 0)$

两个关键条件: 保持其他所有变量不变, 改变T

理想方案是存在平行世界

可控相关变量不变, 改变原因变量, 观察结果变量

金标准: 随机试验

个体因果效应

- **个体因果效应**: 在潜在结果框架下, 个体 i 在干预 t 相对于干预 t' 下的个体因果效应, 记作 τ_i , 由其潜在结果的差值衡量: $\tau_i(t, t') = y_i(t) - y_i(t')$ 。此处, t' 代表基准或对照干预。
- 真实案例:
 - 研究某降压药物 (T) 对患者血压 (Y) 的因果效应
 - 在某一时刻, 某患者 i 在不服用降压药 ($t_i = 0$) 时的血压为140mmHg, 即其未接受药物治疗的潜在结果 $y_i(0) = 140$
 - 在平行宇宙中, 同一时刻同一患者服用了降压药 ($t_i = 1$), 血压变为130mmHg, 即其接受药物治疗的潜在结果 $y_i(1) = 130$
 - 个体处理效应 $\tau_i(1,0) = y_i(1) - y_i(0) = -10$
- **反事实问题**: 只能观测到一种干预下的潜在结果, $y_i(t)$ 或 $y_i(t')$
- 个体因果效应在真实观测世界中**不可识别**!

平均因果效应

- **平均因果效应**：在潜在结果框架下，目标人群的平均因果效应（Average Treatment Effect, 简称ATE）为潜在结果在目标人群中的期望之差： $\tau = E_i[y_i(1) - y_i(0)] = E[Y(1)] - E[Y(0)]$ 。
- 衡量了原因变量对总体平均的因果效应，**仅用观测结果即可计算**，无需依赖反事实结果
- 总体层面的平均因果效应是否能够准确反映个体的因果效应？

如何计算：

	T	Y(1)	Y(0)
患者1	1	130（观测）	140（未知）
患者2	1	132（观测）	145（未知）
患者3	1	128（观测）	138（未知）
患者4	1	135（观测）	142（未知）
患者5	1	125（观测）	135（未知）
患者6	0	132（未知）	140（观测）
患者7	0	133（未知）	145（观测）
患者8	0	127（未知）	138（观测）
患者9	0	133（未知）	142（观测）
患者10	0	125（未知）	135（观测）

- T：是否服用降压药物
- Y：血压（mmHg）
- 处理组平均血压：
 $(130+132+128+135+125)/5=130$
- 对照组平均血压：
 $(140+145+138+142+135)/5=140$
- 平均因果效应 $\tau = E[Y(1)] - E[Y(0)] = 130 - 140 = -10$

ATE无法揭示个体层面的多样性与复杂性

条件平均因果框架

给定一组协变量 $X=x$ 的条件下，个体处理效应的期望值

	T	Y(1)	Y(0)	ITE	X
患者1	1	130（观测）	140（未知）	-10	<60
患者2	1	132（观测）	145（未知）	-13	≥ 60
患者3	1	128（观测）	138（未知）	-10	≥ 60
患者4	1	135（观测）	142（未知）	-7	<60
患者5	1	125（观测）	135（未知）	-10	≥ 60
患者6	0	132（未知）	140（观测）	-8	<60
患者7	0	133（未知）	145（观测）	-12	≥ 60
患者8	0	127（未知）	138（观测）	-11	≥ 60
患者9	0	133（未知）	142（观测）	-9	<60
患者10	0	125（未知）	135（观测）	-10	<60

- ATE为-10
- <60岁群体
 - CATE为-6.5
 - 对于患者4、6而言，CATE比ATE更逼近ITE
- ≥ 60 岁群体
 - CATE为-13.17
 - 对于患者2、7而言，CATE比ATE更逼近ITE
- CATE能够得到“该降压药对于年长者效果更好”这一额外信息

比较

- 个体因果效应：最精细、支撑个体层面分析，但不可识别
- 平均因果效应：最粗糙、支撑总体层面分析，可识别，但当总体中个体之间异质性较大时不能准确反映个体因果效应
- 条件平均因果效应：粒度适中、支撑子群体层面分析，可识别，若子群体划分得当，能够更准确地反映总体中少数特殊个体的因果效应，但当子群体内个体之间异质性较大时也无法准确反映个体因果效应
 - 当条件集合（子群体划分粒度）趋于无穷大，且样本量充足时，条件平均因果效应无限逼近于个体因果效应

当条件集合（子群体划分粒度）趋于无穷大，且样本量充足时，条件平均因果效应无限逼近于个体因果效应

潜在结果框架下的可识别假设

平均因果效应和条件平均因果效应尽管可识别，但也需要观测数据满足一定的假设

- **稳定单元处理值假设**（Stable Unit Treatment Value Assumption，简称SUTVA）：一个个体的原因变量不会影响另一个个体的结果；同一处理对所有个体的作用都相同，即不存在不同的处理版本
- **条件可忽略性/无混淆假设**（ignorability/unconfoundedness）：在给定一组充分的协变量 X 后原因变量与潜在结果独立，即 $(Y(1), Y(0)) \perp T | X$
- **正值性/重叠假设**（positivity/overlap）：对于任何协变量组合的个体，都有既可能接受处理也可能不接受处理的正概率，也有既可能被选入样本也可能未被选入样本的正概率，即 $0 < P(T = 1 | X = x) < 1$ 且 $0 < P(S = 1 | X = x) < 1$ ，其中 S 是样本选择机制， $s_i = 1$ 表示个体 i 被选入样本， $s_i = 0$ 表示个体 i 未被选入样本

98

复杂环境下因果推理三大挑战

关键信息缺失、数据偏差多样、干预变量复杂

在现实复杂环境中做因果推断时，科学家必须解决的三大核心挑战，以及对应的科学问题和研究成果。

1. 挑战一：关键信息缺失

- **问题：** 数据里缺东西，或者有隐藏的变量（混杂因素）没被记录下来。

- **解法（研究成果1）：** 利用 **工具变量**。就像图中提到的“异质数据下隐组工具变量生成学习”，简单说就是通过一些技巧，在数据缺失的情况下“无中生有”或者“借力打力”来推断因果。

2. 挑战二：数据偏差多样

- **问题：** 数据来源不同，分布不一样（比如北京的数据和上海的数据分布不同），导致模型泛化能力差。
- **解法（研究成果2）：** **变量选择与协同表征**。也就是在复杂的偏差中，找到那些真正稳定、通用的特征变量。

3. 挑战三：干预变量复杂

- **问题：** 对应上一页的内容，干预不是简单的0/1，而是复杂的网络或高维数据。
- **解法（研究成果3）：** **平衡表征与异质对比学习**。通过机器学习的方法，把复杂的数据映射到一个空间里，让因果效应更容易被区分出来。

论文成果

- 1.因果推断的研究正在从理想化的“二选一”实验，转向处理现实中复杂的、连续的、组合式的干预措施。
- 2.因果推断不能只看当下，必须把 **时间滞后性** 和 **长期后果** 纳入考量，否则会被短期假象迷惑。
- 3.不要为了因果而因果，**因果推断的终极目标是辅助决策**。评估一个因果模型好坏的标准，不应仅仅是估计误差（PEHE/MSE），更应该是决策的准确率。

1.3结构因果模型

如何表示因果关系

如何形式化地表示因果关系？


因果的定义：在控制相关变量不变的前提下，当一个变量（因）的取值发生变化时，另一个变量（果）的取值也会发生相应的改变

- 用**因果图**来形式化地描述变量间的因果关系——谁是谁的因，谁是谁的果
- 用**结构方程**来量化变量间的因果效应——每个因变量对于该变量的因果效应
- 用**do算子**来刻画“控制相关变量不变，改变因变量取值”这一干预过程

因果图和结构方程

因果图和结构方程

- **因果图**：Judea Pearl 1995年提出。一般而言，因果图是一个由节点和带箭头的边（有向边）组成的**有向无环图(directed acyclic graphs, DAG)**。其中，节点表示我们研究中的变量（如A、B、C），有向边表示因果关系，从原因指向结果（如 $A \rightarrow B$ 表示A是B的一个原因）。**因果图能表示变量间因果关系的原因在于表示变量间的条件独立性**
- **结构方程**：结构方程描述了因果图中变量之间的确定性**生成机制**，由**变量**（如A、B、C）、**生成函数**（如 f_B 、 f_C ）和**随机误差**（如 ϵ_B 、 ϵ_C ）构成。例如，因果图 $A \rightarrow B \rightarrow C$ 对应的结构方程为 $B = f_B(A, \epsilon_B)$ ， $C = f_C(B, \epsilon_C)$



因果与关系

因果中的原因

- **因果图中的原因**：在因果图中，若变量 Y 是另一个变量 X 的孩子，则 X 是 Y 的直接原因；若 Y 是 X 的后代，则 X 是 Y 的潜在原因。
- **结构方程中的原因**：如果变量 X 出现在给变量 Y 赋值的函数中，如 $Y = f(X) + \varepsilon$ ，则 X 是 Y 的直接原因(direct cause)。如果 X 是 Y 的直接原因或者其他原因，均称 X 是 Y 的原因。

每个结构方程 M 都与一个因果图 G 相对应。因果图中的节点是结构因果模型中所包括的变量，节点之间的边表示函数 f 。在 M 中，若变量 X 的函数 f_z 包含了变量 Y （ X 的取值依赖于 Y ），则在 G 中有一条从 Y 到 Z 的有向边。

我们主要讨论**因果图为有向无环图的结构因果模型**。

$$Z = f(X, Y) = 2X + 5Y$$



商品销量 Z ，与其他商品的价格差 X 和广告费 Y 的因果图

117

基本结构：

1.链结构

链(chain)：链是因果图的一种基本结构。它包含三个节点两条边，其中一条边由第一个节点指向第二个节点，另一条边由第二个节点指向第三个节点。




链式因果图

链中的条件独立性：对于变量 X 和 Y ，若 X 和 Y 之间只有一条单向的路径，变量 Z 是截断(intercept)该路径的集合中的任一变量，则在给定 Z 时， X 和 Y 条件独立。

2.分连结构

分连(fork): 分连也是因果图的一种基本结构。它包含三个节点两条边，两条边分别由第一个节点指向第二个节点和第三个节点。

分连中的条件独立性: 若变量 Z 是变量 X 和 Y 的共同原因，且 X 到 Y 只有一条路径，则在给定 Z 时， X 和 Y 条件独立。



分连因果图

$$P(X, Y|Z) = P(X|Z)P(Y|Z)$$

在分连结构中，给定 Z 时， X 和 Y 的联合概率：


$$P(X, Y|Z) = \frac{P(X, Y, Z)}{P(Z)} = \frac{P(Z)P(X|Z)P(Y|Z)}{P(Z)} = P(X|Z)P(Y|Z)$$

即在分连图 $X \leftarrow Z \rightarrow Y$ 中， X 和 Y 在给定 Z 时条件独立。上式的第一步使用了条件概率的定义，第二步使用了乘积分解规则。

3. 汇连结构

汇连(collider): 汇连(又叫碰撞)也是因果图的一种基本结构。它包含三个节点两条边，两条边分别由第一个节点和第二个节点指向第三个节点。

汇连中的条件独立性: 若变量 Z 是变量 X 和 Y 的汇连节点，且 X 到 Y 只有一条路径，则 X 和 Y 相互独立，但在给定 Z 时， X 和 Y 是相关的。



汇连因果图

D-分离与条件独立性

d-分离与条件独立性

D-分离(directional separation, d -separation)，可用于判断任意两个节点的相关性和独立性。若存在一条路径将这两个节点（**直接**）连通，则称这两个节点是有向连接(d -connecte的，即这两个节点是相关的；若不存在这样的路径将这两个节点连通，则这两个节点不是有向连接的，则称这两个节点是有向分离的(d -separated)，即这两个节点相互独立。

D-分离: 路径 p 被限定集 Z 阻塞(block)当且仅当：

- (1) 路径 p 含有链结构 $A \rightarrow B \rightarrow C$ 或分连结构 $A \leftarrow B \rightarrow C$ 且中间节点 B 在 Z 中，**或**
- (2) 路径 p 含有汇连结构 $A \rightarrow B \leftarrow C$ 且汇连节点 B 及其后代都不在 Z 中。

若 Z 阻塞了节点 X 和节点 Y 之间的每一条路径，则称给定 Z 时， X 和 Y 是 D -分离，即给定 Z 时 X 和 Y 条件独立。

独立性例题：

例 分析如下因果图中节点的关系


不妨考虑 X 和 T 的关系：

(1)若限定集为 $\emptyset$ 时， X 和 T 相互独立。因为 X 和 T 之间含有一个汇连结构 $X \rightarrow Z \leftarrow Y$ ，且 Z 及其后代都不在限定集 $\emptyset$ 中，此时 X 和 T 是有向分离，即 X 和 T 相互独立；

(2)若限定集为 $\{W, Y\}$ 时， X 和 T 条件独立。因为 X 和 T 之间只有一条路径，且这条路径含有一个分连结构 $Z \leftarrow Y \rightarrow S$ ，且 Y 在限定集 $\{W, Y\}$ 中，因此 Y 阻塞了 X 和 T 之间的唯一路径， X 和 T 是有向分离，即限定集为 $\{W, Y\}$ 时， X 和 T 条件独立。

(3)若限定集为 $\{W\}$ 时， X 和 T 的关系是？

若限定集为 $\{W\}$ 时， X 和 T 是相关的。因为 X 和 T 之间含有一个链式结构 $Y \rightarrow S \rightarrow T$ (S 不在限定集中)，一个分连结构 $Z \leftarrow Y \rightarrow S$ (Y 不在限定集 $\{W\}$ 中)，一个汇连结构 $X \rightarrow Z \leftarrow Y$ (Z 的后代 W 在限定集 $\{W\}$ 中)，根据 D -分离的定义，这些结构都无法阻塞 X 和 T 之间的路径，因此 X 和 T 是有向连接的，即 X 和 T 是相关的；




包含链、分连和
汇连结构的因果图

重新解释结构因果模型下的偏差

结构因果模型下的偏差



(a) 混淆偏差



(b) 选择偏差

混淆偏差：

- 存在因未控制混淆变量 X 导致未阻塞的混淆路径 $T \leftarrow X \rightarrow Y$

选择偏差：

- 存在因控制了对撞变量 S 导致未阻塞的对撞路径 $T \rightarrow S \leftarrow Y$

do-算子


do-算子

观测数据分布 $P(Y|T)$ ：在自然状态下，在观察到原因变量 T 自然取值为 t 时结果变量 Y 的概率分布

- 没有控制混淆变量，混淆路径未被阻塞，包含了混淆偏差

do-算子： $do(T=t)$ 表示通过外部干预，强制将总体中每一个个体的原因变量 T 的值都设定为 t

- T 的取值就不再受其他变量影响，在因果图上相当于删除所有指向 T 的边




因此去除了混淆路径，没有偏差

E.G.

X 表示用药情况(1表示用药，0表示不用药)， Y 表示病人的恢复情况(1表示恢复，0表示未恢复)， Z 表示性别(1表示男性，0表示女性)。为了比较病人用药与否的恢复情况，可以对用药情况分别进行干预，即将病人都分别固定成用药病人和不用药病人。不妨设 $do(X=1)$ 和 $do(X=0)$ 分别表示这两种干预，并估计其中的差别：


$$P(Y=1|do(X=1)) - P(Y=1|do(X=0))$$



因果图

这被称为“因果效应差”(causal effect difference)或“平均因果效应”(average causal effect, ACE)。

对用药情况 X 进行干预并固定其值为 x 时，可将所有指向 X 的边均移除，则因果效应 $P(Y = y|do(X = x))$ 等价于图所示的引入干预的操纵图模型(manipulated model)中的条件概率 $P_m(Y = y|X = x)$ 。



引入干预的操纵图模型


$$P(Y = y|do(X = x)) = P_m(Y = y|X = x)$$

do-算子的效果可以通过修改图结构后在新图上计算普通条件概率来实现


do-算子计算因果效应差

操纵概率计算恒等式：

计算因果效应的关键在于计算操纵概率(manipulated probability) P_m 。 P_m 与正常(无干预)条件下的概率 P 有两个相同的重要性质：(1)边缘概率 $P(Z = z)$ 不随干预而变化，因为 Z 的取值不会因为去掉从 Z 到 X 的箭头而变化；(2)条件概率 $P(Y = y|X = x, Z = z)$ 不变，因为 Y 关于 X 和 Z 的函数 $f_Y = (X, Z, U_2)$ 并未改变。因此，有如下等式：



因果图



引入干预的操纵图模型

$$P_m(Y = y|X = x, Z = z) = P(Y = y|X = x, Z = z),$$

$$P_m(Z = z) = P(Z = z)$$

以及 X 垂直于 Z 因为d-分离，所以条件独立

最终推得调整公式

$$P(Y = y|do(X = x)) \xrightarrow{\text{do的定义}} P_m(Y = y|X = x) \xrightarrow{\text{全概率展开}} \sum_z P_m(Y = y|X = x, Z = z) \cdot P_m(Z = z|X = x)$$

$$\xrightarrow{\text{d-分离}} \sum_z P_m(Y = y|X = x, Z = z) \cdot P_m(Z = z) \xrightarrow{\text{机制不变性}} \sum_z P(Y = y|X = x, Z = z) \cdot P(Z = z)$$

$$P(Y = y|do(X = x)) = \sum_z P(Y = y|X = x, Z = z) \cdot P(Z = z)$$

得到如下正常(无干预)条件下的概率表示的因果效应：

$$P(Y = y|do(X = x)) = \sum_z P(Y = y|X = x, Z = z)P(Z = z)$$

这被称为调整公式(adjustment formula)，对于 Z 的每一个取值 z ，计算 X 和 Y 的条件概率并取均值。这个过程称之为“ **Z 调整**” (adjusting for Z)或“ **Z 控制**” (controlling for Z)。式2.4的右端只包含正常(无干预)条件下的概率 P ，即可用正常(无干预)条件下的条件概率来计算干预后的条件概率。

结构因果模型下的因果效应

个体因果效应： $\tau_i = y_i|do(T = 1) - y_i|do(T = 0)$

平均因果效应： $\tau = E[Y|do(T = 1)] - E[Y|do(T = 0)]$

条件平均因果效应： $\tau(x) = E[Y|do(T = 1), X = x] - E[Y|do(T = 0)|X = x]$

- 个体因果效应衡量的是单个个体在两种干预下结果的差异
- 平均因果效应是对整个总体取期望
- 条件平均因果效应则是在给定某些协变量取值下的因果效应

与潜在结果框架的区别：

- 采用do-算子而非潜在结果来定义因果效应，无需潜在结果框架下的可识别性假设
- 观测数据分布难以满足do-算子干预分布，需要对观测数据进行调整来模拟do-算子干预操作

二、因果推理

2.1因果发现

因果推断&因果发现

前者已知因果图 估计因果效应有多大

后者去学习因果图

因果发现三大方法

方法类别	核心思想	代表算法
基于约束	通过条件独立性检验推断因果结构	PC算法、FCI算法
基于评分	为每种可能的图打分，选最优图	GES、BIC评分搜索
基于函数模型	假设因果关系满足特定函数形式	LiNGAM、ANM

基于约束方法

建立在：因果结构和统计性质存在精确对应关系

两个关键假设

• **Markov条件（因果图 → 独立性）**

如果在因果图中，变量X和变量Y被一组变量Z在图上"d-分离"了，那么在数据中，X和Y在给定Z的条件下一定是统计独立的。

• **忠实性条件（独立性 → 因果图）**

反过来，如果在数据中发现X和Y在给定Z的条件下是统计独立的，那么在因果图中，X和Y一定被Z d-分离了。也就是说，数据中观察到的独立性不是"巧合"，而是图结构决定的。

• 这两个条件合在一起，就建立了一座桥梁：**条件独立 ⇔ d-分离**。有了这座桥，我们就可以通过对数据进行统计检验（检验条件独立性），来推断因果图的结构。

条件独立性检验

条件独立性检验

- 条件独立性检验是基于约束方法的基本"工具"。常用的检验方法包括：
- 对于连续数据，可以使用偏相关检验（基于Fisher-z变换），通过检查偏相关系数是否为零来判断两个变量在给定其他变量后是否独立；
- 对于离散数据，可以使用卡方检验（G-test或chi-square test），通过检查条件频率表是否满足独立性来判断；
- 对于非线性关系，可以使用核方法（如HSIC检验）或基于互信息的方法，这些方法不要求变量之间是线性关系，适用范围更广。

PC算法

核心策略非常直观：先从一个完全连接的图出发，通过不断"删边"得到骨架，再通过分离集信息确定边的方向

第一阶段：骨架学习 (Skeleton Learning)

- 目标是确定哪些变量之间有边（暂时不考虑方向），通过逐步删除"不该存在"的边来实现。
- **步骤0：初始化——从完全图开始**
 - 假设我们有4个变量 $\{X_1, X_2, X_3, X_4\}$ 。算法一开始非常"大方"，假设所有变量之间都有边。4个变量两两配对一共有 $C(4,2)=6$ 条边，所以初始图是一个完全无向图，每个变量都和其他所有变量相连。
 - 为什么从完全图开始？因为我们还不知道哪些边该删，所以采用"宁多勿少"的策略——先假设都有关系，然后逐步排除。
- **步骤1：无条件独立检验（条件集大小 $|S|=0$ ）**
 - 第一轮检验最简单：对每一对相邻的变量直接做独立性检验，不用控制任何其他变量。也就是直接问："X和Y之间有没有关联？"如果检验结果显示 X_1 和 X_4 是边际独立的（ $X_1 \perp X_4$ ），那就删除 X_1 和 X_4 之间的边，并记录分离集 $\text{Sep}(X_1, X_4) = \{\}$ （空集，表示不需要条件在任何变量上就能分离它们）。

• 步骤2：条件集大小 $|S|=1$

- 第二轮检验稍微复杂一些：对于仍然相连的每对变量，从它们各自的邻居中选出一个变量作为"条件"，然后检验在这个条件下，这对变量是否独立。
- 举例来说，如果 X_2 和 X_4 还相连， X_3 是它们的共同邻居，那就检验：在给定 X_3 的条件下， X_2 和 X_4 是否独立？如果是 $(X_2 \perp X_4 \mid X_3)$ ，就删除 X_2 - X_4 这条边，并记录 $\text{Sep}(X_2, X_4) = \{X_3\}$ 。

为什么要逐步增大条件集？

条件集从空集开始逐渐增大的策略有两个好处。首先，小条件集的检验统计效力更强（需要的样本更少），所以先做简单的检验可以尽早删掉明显不该有的边。其次，删边后图变得更稀疏，后续需要检验的条件集组合就更少，大大降低了计算量。这是一种"先易后难"的高效策略。

11

• 步骤3及以后：逐步增大条件集

- 继续增大条件集大小到 $|S|=2, 3, \dots$ ，重复同样的过程。每一轮对于仍然相邻的节点对，从它们的邻居中选取相应大小的子集进行条件独立检验。

• 终止条件

- 当对于每一对仍然相邻的节点，其邻居数量都不够组成当前大小的条件集时，第一阶段结束。此时得到的无向图就是因果图的骨架（skeleton）——它告诉我们哪些变量之间有直接的因果联系，但还不知道方向。

第二阶段：边的定向（Edge Orientation）

- 有了骨架之后，下一步是确定每条边的方向——也就是判断"谁导致了谁"。这个阶段分两步完成。

• 步骤A：识别V-结构（Collider Detection）

- 这是定向过程中最关键的一步。V-结构（也叫对撞结构）是一种形如 $X \rightarrow Z \leftarrow Y$ 的模式，其中 X 和 Y 都指向 Z ，且 X 和 Y 之间没有直接的边。
- 识别V-结构的方法是：在骨架中找到所有" $X - Z - Y$ "这样的三元组（其中 X 和 Y 不直接相连），然后检查第一阶段记录的分离集 $\text{Sep}(X, Y)$ 。如果 Z 不在 $\text{Sep}(X, Y)$ 中，那就说明 Z 是对撞节点，将其定向为 $X \rightarrow Z \leftarrow Y$ 。

- **步骤B：应用定向规则**
- V-结构只能定向一部分边。对于剩下的无向边，PC算法使用三条定向规则来尽可能多地确定方向，同时避免产生矛盾（新的V-结构或有向环）。
- **规则1——避免新V-结构：**如果已经知道 $X \rightarrow Z$ ，且Z和Y之间有无向边，而X和Y不相邻，那么必须定向为 $Z \rightarrow Y$ 。因为如果反过来定向为 $Z \leftarrow Y$ ，就会形成 $X \rightarrow Z \leftarrow Y$ ，这就产生了一个新的V-结构，与之前的检验结果矛盾。
- **规则2——避免有向环：**如果已经存在从X到Y的有向路径 ($X \rightarrow \dots \rightarrow Y$)，同时X和Y之间还有一条无向边，那么必须定向为 $X \rightarrow Y$ 。否则如果定向为 $Y \rightarrow X$ ，就会形成一个有向环（因果关系循环了），这在因果图中是不允许的。
- **规则3——利用不相邻性约束：**如果存在两条无向路径 $X - Z - Y$ 和 $X - W - Y$ ，且Z和W不相邻，通过d-分离的约束可以进一步推断方向。这条规则较为技术性，核心思想仍然是利用图结构的一致性约束。
- 反复应用这三条规则，直到没有新的边可以被定向为止。最终得到的图其中有些边是有向的（方向确定），有些边可能仍然是无向的（方向无法从数据中确定）。

PC 算法局限性

主要局限性

- **局限1——马尔可夫等价类：**PC算法只能识别到"马尔可夫等价类"（MEC），即具有相同骨架和相同V-结构的所有DAG的集合。在等价类中，有些边的方向是无法仅从观测数据中确定的。最终结果用CPDAG表示，其中未定向的边代表"两种方向都与数据兼容"。
- **局限2——对检验错误敏感：**算法的每一步删边决策都依赖于条件独立性检验的结果。如果某一步检验出错（在有限样本中这很常见），错误会"传播"到后续步骤，影响最终结果。后来的改进版本PC-stable算法通过并行化删边决策，减少了对检验顺序的依赖。
- **局限3——忠实性假设可能被违反：**在某些特殊情况下，不同因果路径的效应可能恰好"抵消"，导致虽然存在因果关系但数据中显示独立。例如X通过两条路径影响Y，一条正效应一条负效应，如果恰好大小相等，就会看到X和Y独立。
- **局限4——无法处理隐藏混杂：**标准PC算法假设所有相关变量都被观测到了。如果存在未观测的混杂变量（同时影响两个观测变量的隐藏原因），算法可能给出错误的结果。FCI算法是PC算法的扩展，通过引入双向边 ($\leftrightarrow$) 来表示潜在混杂的存在。

PC改进

算法变体	改进点	适用场景
PC-stable	并行删边，消除顺序依赖	标准场景（推荐默认使用）
FCI	允许隐藏混杂变量	不确定是否有未观测变量时
RFCI	FCI的快速近似版本	高维数据+潜在混杂
PC with majority/conservative	多数/保守投票确定V-结构	需要更稳健的V-结构判断时

对撞结构和叉式结构

$A \rightarrow B \leftarrow C$ 控制B AC相关

$A \leftarrow B \rightarrow C$ 控制B AC独立


2.2因果推断

什么是因果？一个实用的定义

定义：T 导致了 Y 当且仅当

保持其他所有变量不变的情况下，
改变 T 发现 Y 也发生了变化。

因果效应：T在改变一个单位时，Y的变化量。



两个关键条件: 保持其他所有变量不变，改变T

随机试验

随机实验的特点

在概率论中，随机实验通常具有以下几个典型特点：

(1) **可重复性**：随机实验可以在相同条件下多次重复进行，保证实验结果在多次试验中的可比性。

(2) **结果多样性**：每次实验可能出现多种不同结果，但可以事先确定所有可能的结果集合。

(3) **不可预知性**：在每次实验开始之前，无法提前确定具体会发生的结果，但通过分析结果分布，可以获得总体规律性认识。

随机实验的设计

随机对照实验的设计需要考虑多个关键因素：

(1) **样本选择**：样本选择需与研究目标相关，并能代表总体人群，以确保实验结果具有外推性。

(2) **随机化设计**：随机化是随机实验的核心，包括完全随机、随机区组和分层随机化等多种方法，研究者需根据具体情境选择。

(3) **对照组设计**：对照组的设计至关重要，其核心目的是提供参照以对比处理组的结果，且其选择和设置必须科学，以保证与处理组的可比性。

随机实验通过**随机分配**平衡干扰因素，有效避免选择偏倚，是可靠评估干预措施因果效应、进行因果推断的核心科研方法。当对照组和实验组中人群特征相同时，通过设计随机实验可以得到**无偏的RCT数据**。利用RCT数据的无偏性，可以直接对组间**直接**取平均计算ATE。

应用场景：

医药领域药物试验 互联网推荐算法比较测试

局限性：

成本高 样本有限

伦理问题

耗时

基于观测数据

基于观测数据进行因果推断


- 因果推断中的反事实问题：

$$ATE = E[Y(T = 1) - Y(T = 0)]$$

- 能否通过计算 $T=1$ 和 $T=0$ 两个群体的均值，并相减来计算平均因果效应ATE？
 - 能，如果数据来自于随机实验（因为随机化保证了两组的混杂变量 X 分布一致）
 - 不能，如果是观测数据/历史数据（两组的混杂变量 X 可能分布不同）

- 两个关键条件：

- 保持其他所有变量不变
- 改变 T



39

如何平衡实验组和对照组的协变量

经典因果推断方法

1. 匹配法

- 通过约束混杂变量 X 相似或一样，来匹配 $T=1$ 和 $T=0$ 的样本：

$$Distance(X_i, X_j) \leq \epsilon$$

- 匹配的样本对能够保证 $T=1$ 和 $T=0$ 两组样本的混杂变量近似或一样。
- 平均因果效应可以通过计算 $T=1$ 和 $T=0$ 两组样本结果变量平均值的差值来计算。
- 参数 ϵ 越小，因果评估的偏差越小，但是方差大。

当混杂变量高维时，就无法找到完全一样的个体，失效

2. 基于倾向得分的方法

- 倾向得分匹配法：先利用机器学习模型算出每个人接受干预的概率（倾向得分），然后基于这个概率值，把“相似概率”的干预组和对照组样本配对，从而模拟出随机实验的效果，进而准确评估因果效应。
- 倾向得分逆加权法：

倾向得分逆加权法

- 为什么利用倾向得分的逆对样本加权有用？
 - 倾向得分导致了混杂变量X在T=1和T=0两组样本之间的分布不一致

$$e(X) = P(T = 1|X)$$

样本	$e(X)$	$1 - e(X)$	样本数量	T=1组 样本数量	T=0组 样本数量	样本数量	T=1组 样本数量	T=0组 样本数量
A	0.7	0.3	10	7	3	A	10	10
B	0.6	0.4	50	30	20	B	50	50
C	0.2	0.8	40	8	32	C	40	40

分布不一致

样本通过倾向得分的逆来加权：

$$w_i = \frac{T_i}{e_i} + \frac{1 - T_i}{1 - e_i}$$

混杂变量的分布一致了！

倾向得分逆加权法

- 如果评估的倾向得分等于真实的倾向得分 $\hat{e}(X) = e(X)$ ，那么IPW方法是无偏的 (unbiased)

$$ATE_{IPW} = \frac{1}{n} \sum_{i=1}^n \frac{T_i Y_i}{\hat{e}(X_i)} - \frac{1}{n} \sum_{i=1}^n \frac{(1 - T_i) Y_i}{1 - \hat{e}(X_i)} = E(Y_1 - Y_0)$$

- IPW方法被广泛应用于各种实际场景中（经济学、社会学等）
- 但IPW方法对因果评估的无偏性依赖于倾向得分模型的准确性
- 且当倾向得分 e 接近于 0 或 1 时，因果评估的方差会很大

根据数量分布进行加权，保证变量分布一致（干预和不干预的数量相同）

- 双稳健算法：

双稳健算法

- 平均因果效应的定义： $ATE = E[Y(T = 1) - Y(T = 0)]$
- 简单的结果变量回归方法：
 - $m_1 = E(Y|T = 1, X)$ 以及 $m_0 = E(Y|T = 0, X)$
 - 如果结果变量回归模型是正确的，那么因果效应评估是无偏的
- 倾向得分逆加权方法：
 - 如果倾向得分回归模型是正确的，那么因果效应评估是无偏的
- 双稳健算法：将两者结合起来

59

双稳健算法

$$\begin{aligned} m_0 &= E(Y|T = 0, \\ m_1 &= E(Y|T = 1, \end{aligned}$$

- 双稳健算法：

$$\begin{aligned} ATE_{DR} &= \frac{1}{n} \sum_{i=1}^n \left[\frac{T_i Y_i}{\hat{e}(X_i)} - \frac{\{T_i - \hat{e}(X_i)\}}{\hat{e}(X_i)} \hat{m}_1(X_i) \right] \\ &\quad - \frac{1}{n} \sum_{i=1}^n \left[\frac{(1 - T_i) Y_i}{1 - \hat{e}(X_i)} + \frac{\{T_i - \hat{e}(X_i)\}}{1 - \hat{e}(X_i)} \hat{m}_0(X_i) \right] \end{aligned}$$

- 如果结果变量回归模型或者倾向得分回归模型是正确的，那么因果效应评估是无偏的
- 这种属性称之为双稳健

60


倾向得分模型 和结果回归模型 有一个正确就能准确预测

复杂因果推理

- 复杂数据偏差：工具变量的使用

说白了就是引入一个有一定关系但很随机的变量 用这个随机性消除其他混杂变量

评估教育对收入的影响---工具变量



- 工具变量 (Z) 的条件
- 相关性: $P(T|Z) \neq P(T)$
- 排他性: $P(Y|Z, T, U) = P(Y|T, U)$
- 无混杂性: $Z \perp U$

- 分析读书与收入之间的因果效应


- 生日可以作为工具变量

✓生日影响读书

✓生日不影响能力和家庭情况


✓生日不直接影响收入

评估教育对收入的影响---工具变量



- Z: 生日, 春季出生/冬季出生
- T: 是否高中毕业
- Y: 收入
- U: 能力, 家庭情况等



两阶段回归 { 第一阶段: 用Z去回归T $\hat{T} = \hat{g}(Z)$
 第二阶段: 用 $\hat{T}$ 去回归Y $\hat{Y} = \hat{f}(\hat{T})$



局限于线性假设
需要提前定义工具变量

70

非线性工具变量回归



非线性工具变量回归 (DeepIV, KernelIV et.al)

第一阶段: 用 Z 和 X 去回归 T $\hat{T} = \hat{g}(Z, X)$



第二阶段: 用 $\hat{T}$ 和 X 去回归 Y $\hat{Y} = \hat{f}(\hat{T}, X)$

第一阶段回归会给第二阶段回归
引入混杂偏差 (X)

混杂变量平衡 + 工具变量回归

71

混杂平衡的工具变量回归 (CB-IV)



CB-IV (Confounder Balanced IV regression):

第一阶段（干预回归）：用 Z 和 X 去回归 T $\hat{T} = \hat{g}(Z, X)$

混杂平衡：学习混杂平衡的表征 $\phi(X)$ ，使其满足 $\hat{T} \perp \phi(X)$

第二阶段（结果回归）：用 $\hat{T}$ 和 $\phi(X)$ 去回归 Y $\hat{Y} = \hat{f}(\hat{T}, \phi(X))$

如何解决

- 第一阶段（照常进行）：

依然用 Z 和 X 训练一个非线性模型来预测 T ，得到 $\hat{T}$ 。此时 $\hat{T}$ 里面依然混着 X 的信息。

- 核心创新步（表征学习 & 混杂平衡）：

在进入第二阶段之前，我们不再直接使用原始的 X 。而是通过神经网络（比如一个编码器），将原始的 X 映射/转换为一个新的特征表达（表征），记作 $\Phi(X)$ 。

在训练这个表征 $\Phi(X)$ 时，加入一个极其严格的数学约束条件： $\hat{T} \perp \Phi(X)$ （读作： $\hat{T}$ 与 $\Phi(X)$ 相互独立）。

- 这意味着什么？这意味着我们强制要求提取出来的环境特征 $\Phi(X)$ 中，**绝对不包含**任何能预测 $\hat{T}$ 的信息。这两者在统计学上被完全“剥离”了。


- 第二阶段（无偏的因果回归）：

现在，我们将第一阶段得到的 $\hat{T}$ ，以及刚刚经过净化、与 $\hat{T}$ 完全独立的表征 $\Phi(X)$ ，一起输入给第二阶段的网络来预测 Y ：

$\hat{Y} = \hat{f}(\hat{T}, \Phi(X))$ 。

如何寻找工具变量?

工具变量自动生成 (AutoIV)



工具变量 (Z) 的条件

相关性: $P(T|Z) \neq P(T)$

排他性: $P(Y|Z, T, U) \neq P(Y|T, U)$

无混杂性: $Z \perp U$



互信息约束
解耦表征学习


但是排他性可能不满足

Yuan J, Wu A, Kuang K, et al. Auto IV: Counterfactual Prediction via Automatic Instrumental Variable Decomposition[J]. TKDD, 2022.

将X分解为Z和C两个变量 Z只和T有关 C还和Y有关 Z就是我们需要的工具变量 但是不能保证Z和Y完全解耦

复杂偏差下的因果推断

选择偏差:



• 分析读书与收入之间的因果效应


- 随机对照实验: 做实验、发问卷
- 干预变量 $T=1/0$: 是否高中毕业
- 结果变量 Y: 收入

• 实际应用中, RCT也可能存在选择偏差

- 如高中毕业但收入低的受访者, 不愿意回答
- 而高中未毕业但收入高的, 非常愿意回答
- 选择变量 S, 由 T 和 Y (甚至 X) 同时影响
 - $S=1$: X, T, Y
 - $S=0$: X, T

碰撞偏差:

碰撞偏差 (Collider Bias)




- 问题：读书与收入之间的因果效应
 - 混杂变量 X ：能力
 - 干预变量 $T=1/0$ ：是否高中毕业
 - 结果变量 Y ：收入
 - 选择变量 S ：由 T, Y, X 同时影响
 - $S=1$ ： X, T, Y
 - $S=0$ ： X, T
- 挑战：
 - ✓ 分布偏移： $P(X, T, Y, S = 1) \neq P(X, T, Y)$
 - ✓ 不可识别：存在碰撞偏差，因果效应不可识别

82

S 是碰撞节点


解决方法——影子变量



- 影子变量 (Z) 的条件
- $Z \perp\!\!\!\perp S | X, Y, T$
- $Z \not\perp\!\!\!\perp Y | X, T, S = 1$

如何获得？不断从 X 中学习出一个影子变量，检验是否复合条件，（一个等式），满足就是我们需要的影子变量

两种偏差同时出现?



- 如何同时解决两种偏差:
- IV is all you need

Baohong Li, Anpeng Wu, Ruoxuan Xiong, Kun Kuang*. Two-Stage Shadow Inclusion Estimation: An IV Approach for Causal Inference under Latent Confounding and Collider Bias, ICML, 2024.

88



2SSI: 两阶段Shadow Variable回归

• 第一阶段

- 用 $S=1$ 和 $S=0$ 的 X 和 Z 回归 T , 根据 T 和 $\hat{T}$ 求残差 R
- 用 $S=1$ 和 $S=0$ 的 X , T 和 Z 回归 S , 同时学习解耦表征 ϕ
 - 用一个表征网络学习 $\phi = f(Z)$ 预测 S , 并约束其与 T 独立
 - 二值 T 时采用积分概率度量IPM, 连续 T 时用互信息

• 第二阶段

- 引入 ϕ , 将 R 视为 ϕ 的条件下的Shadow Variable
 - R 在 X, T, Y 和 ϕ 的条件下与 S 独立, 在 $X, T, S=1$ 和 ϕ 的条件下与 Y 相关



- 影子变量 (Z) 的条件
- $Z \perp\!\!\!\perp S | X, Y, T$
- $Z \not\perp\!\!\!\perp Y | X, T, S = 1$

利用工具变量 Z , 解耦成残差 R (混杂信息) 和影子变量 ϕ ,

如何用历史数据作为工具变量

当我们面对一个完全未知的、包含各种未观测混杂 (M_1) 和数据缺失 (M_2) 的复杂系统时, 我们不需要再去苦苦寻找外部的完美工具变量。

我们只需要收集这些变量随时间变化的连续数据, 利用“过去状态影响现在状态”这一天然属性, 将过去的变量转化为“条件工具变量”。然后利用这些提取出来的工具变量, 就能拨开混杂和偏差的迷雾, 自动“画”出事物之间真实的因果网络。

例子

1. 变量对应关系：

- T (现在)：今天的干预（比如今天的服药剂量 / 今天的压力水平）。
- Y (现在)：今天的结果（比如今天的病情 / 今天的收入）。
- P_T (过去)：前一天的干预状态（Past of T ）。
- M_1 和 M_2 ：隐藏在今天的混杂偏差和选择偏差（就是前面几页讲的恶心怪物）。

2. 为什么过去的自己（ P_T ）能成为工具变量？

作者提出：基于前序时间变量（把过去的背景状态 P_1, P_2, P_Y 作为条件控制住），那么干预变量的过去状态 P_T ，就是当前 T 和 Y 的条件工具变量 (Conditional IV)。

- 通俗解释：“你昨天的服药量（ P_T ）”绝对会深刻影响“你今天的服药量（ T ）”。但是，“你昨天的服药量”不会隔山打牛直接决定“你今天的最终病情（ Y ）”，它只能通过“今天的药量”来发挥作用。同时，因为昨天的事已经发生了，它不会被今天的那些未知混杂因素（ M_1, M_2 ）所干扰。
- 你看！完美满足了工具变量的三个苛刻条件（相关性、排他性、无混杂性）！

复杂干预变量

干预组变为多种离散值或者为连续变量

倾向得分方法扩展

方法扩展-倾向得分

- 倾向得分：倾向得分 $e(X)$ 定义为样本接受干预（ $T = 1$ ）的概率



$$e(X) = P(T = 1|X)$$

二分类任务，一般采用逻辑斯蒂回归模型建模

- 广义倾向得分：

- 多值： $e(X) = P(T = t|X), \forall t \in \{1, 2, \dots, m\}$

多分类任务，采用多项逻辑回归/多分类神经网络

- 连续： $e(t, X) = f_{T|X}(t|x)$

条件概率密度函数，采用回归模型（整态假设）或核密度估计（非参方法）

- 多维： $e_t(X) = P(T_1 = t_1, T_2 = t_2, \dots, T_m = t_m | X)$

联合条件下的分配概率，采用表征学习网络/生成模型

混杂变量平衡法

从之前的加权方法（由于干预空间过大，产生极端权重）转化为表征学习方法

目标从原本的 $T \perp wX$ （寻找权重 w 让干预和特征独立），变成了 $T \perp \phi(X)$ （学习一个新特征 $\phi(X)$ 让干预和它独立）。

- 经典的二元干预架构CFRNet：用原始特征 X 提取全新的高维特征 $\phi(X)$ ，然后学习出剥离干预影响的纯净特征，双预测头是防止一维干预变量被淹没，强行使其作用
- 多值干预：m个预测头，两两对齐
- 多维/连续：共享预测头，但是引入“互信息”，让提取的特征不能和 T 有任何关联，保持独立，因此被平衡。
- 连续干预另一解：先分类划分区间，再回归预测

连续干预效应估计

目标是在连续干预变量下让干预变量和协变量独立

- 随机打乱干预变量，伪造一个没有混杂偏差的数据集
- 给真实的数据集赋予权重，使其逼近完美数据集

• 我们的目标: $T \perp X$

• “校准” 分布的构造

• 在 “校准” 分布 $D_{cal} = \{T', X\}$ 中, 有 $T' \perp X$

• “校准” 分布的逼近

• 观测分布: $D_{obs} = \{T, X\}$

• 学习样本权重以逼近 “校准” 分布

$$D_{obs} = \{T, X\} \xrightarrow{\text{样本权重 } W} D_{cal} = \{T', X\}$$

• 使得: $W T \perp W X$

- 其实是用生成对抗式网络来进行权重的不断学习，最终排除混杂干扰。也即GAD

未来展望

- 待解决挑战：
 - 混杂变量的**异质性**：
 - 存在多个干预（多值/多维）时，不同干预对应不同的混杂变量
 - 大多数现有方法假设所有干预变量的混杂因素是统一的
 - 干预变量之间的**相互作用**（多维干预）：
 - 加性效应（ $1+1=2$ ）、协同效应（ $1+1>2$ ）、拮抗效应（ $1+1<2$ ）
 - 大多数现有方法暂未考虑干预变量之间的互相作用
 - 巨大干预空间下的数据**稀疏性**：
 - 数据只能覆盖所有可能干预中极小的一部分，可能违反overlap假设

高维混杂变量

所有的观测变量 X ，其实是由三类不同的变量混合而成的：

1. 工具变量 (I)：只影响干预 T ，不直接影响结果 Y 。
2. 混杂变量 (C)：既影响 T 又影响 Y （这是我们最想找的，必须调整）。
3. 调整变量 (A)：只影响结果 Y ，不影响干预 T （也叫纯预测变量）。

为什么要区分这三者？（右侧文字的关键点）

PPT右侧的文字指出了混用这些变量的后果，这也是这个方法的动机：

- 纳入工具变量 (I) 会带来偏差：
 - 这听起来反直觉，但确实如此。在非线性模型或有限样本中，如果把工具变量当作混杂变量去调整，反而会放大由隐藏混杂因素带来的偏差（这叫“工具变量偏差”）。所以，必须把 I 识别出来并排除在调整范围之外。
- 纳入调整变量 (A) 有助于降低方差：
 - 因为 A 能解释结果 Y 的变化，把 A 加进模型里，可以让对结果 Y 的预测更准，从而减少估计误差（方差）。所以，我们要把 A 识别出来并包含进去。

如何实现？

为了实现这种自动拆解，作者设计了一套深度学习框架：

1. 三个分解表示网络 ($I(X)$, $C(X)$, $A(X)$):

- 这就好比有三个“过滤器”，把原始数据 X 扔进去，分别提取出工具变量特征 I 、混杂特征 C 和调整变量特征 A 。

2. 三个分解与平衡正则项（这是核心约束）：

- 为了防止模型偷懒（比如三个网络都学一样的东西），必须加约束：
- 混杂变量识别：
 - $A(X) \perp T$ ：强制要求 A 和干预 T 独立（确保 A 不影响 T ）。
 - $I(X) \perp Y|T$ ：强制要求 I 在给定 T 的情况下和结果 Y 独立（确保 I 不直接影响 Y ）。
- 混杂变量平衡：
 - $w \cdot C(X) \perp T$ ：这是为了让提取出的混杂变量 C 在处理组和对照组之间分布平衡（消除偏差）。

3. 用于分解的正交正则项 ($\mathcal{L}_O$):

- 那个长长的公式 $\mathcal{L}_O = \bar{I}_W^T \cdot \bar{C}_W + \dots$ 是为了保证 I 、 C 、 A 这三部分互不重叠（正交）。比如 I 里不能有 C 的信息，确保拆解得干干净净。

之前的很多方法主要关注“干预前”的变量（比如用户的年龄、性别），但现实中还有很多“干预后”或“结果前”的变量（比如吃药后的身体反应）。

核心问题：对于这些复杂的变量，我们该如何处理？是全都要（Brute-force），还是有选择地要？

三种策略的对比（中间的三张图）

这部分通过因果图展示了三种处理变量的思路：

- **图(a) Brute-force（暴力法）：**

- 这是最传统的做法。它假设所有的协变量 UU （包括 XX ）都是混杂因素。
- **做法：**不管三七二十一，把所有观测到的变量 XX 都放进模型里去调整。
- **缺点：**如果 XX 里包含了“工具变量”（只影响 TT 不影响 YY ）或者“无关变量”，强行调整反而可能增加偏差或方差。

- **图(b) Separation（分离法）：**

- 这是更精细的做法（也是上一张PPT讲的内容）。它试图把变量

UU

拆分成三类：

- II （蓝色）：工具变量（只影响 TT ）。
- XX （黄色）：混杂变量（影响 TT 和 YY ）。
- ZZ （绿色）：调整变量（只影响 YY ）。
- **做法：**只调整 XX 和 ZZ ，排除 II 。

- 图(c) Ours（本文提出的方法）：

- 这是最复杂的情况，也是这篇论文（KDD 2023）的贡献。它认为变量之间可能有更复杂的关系，比如存在多层的工具变量（ I_1, I_2, I_1, I_2 ）或多层的调整变量（ Z_1, Z_2, Z_1, Z_2 ）。
- 附加假设：这里特别提到“不存在中介变量”（即 TT 到 YY 之间没有中间传导变量），这是为了简化问题。
- 理论结论：最优的特征组合应该是“混杂变量”+“与结果相关的协变量”。


高维因果推理

高维因果推断的总体思路（因果 × 机器学习）

高维因果推断的挑战不是因果定义变了，而是混杂控制与推断在高维下推断不稳定。

因此需要把因果推断的识别与机器学习的高维建模能力结合起来。

- 因果推断负责明确目标参数（ATE/ATT/CATE）、识别假设（混杂控制、重叠等）与推断目标
- 机器学习负责在高维协变量下进行表示、选择、估计（例如控制集、模型的选择）



122

高维—— p 与 n 的关系

高维的核心是维度 p 与样本量 n 的相对大小

- $p \ll n$ （低维）：传统回归/倾向得分估计相对稳定
- $p \approx n$ （中高维）：估计方差大、对模型设定更敏感
- $p \gg n$ （高维）：无正则化不可识别或过拟合，推断尤其困难

强相关与共线性：变量成簇，信息冗余，系数不稳定

高度敏感：删/加少量变量，估计与权重可能明显变化

在高维设定下，参数估计与效应推断的稳定性显著下降。

高维处理方法

三类处理思路（重点）

面对高维数据，我们有三种主流武器：

1. 变量选择 (Variable Selection) :

- 思路：做减法。从几千个变量里挑出那几十个真正影响因果关系的“关键变量”。
- 代表：LASSO（一种通过惩罚项让不重要变量系数归零的算法）。

2. 协变量平衡与加权 (Covariate Balancing) :

- 思路：做匹配。不给变量做减法，而是给样本做加权。让处理组和对照组在看起来尽可能像“双胞胎”。
- 代表：CBPS、熵平衡。

3. 正交化推断与双重机器学习 (DML) :

- 思路：做“去噪”。这是目前最火的方法。它允许我们使用任意的机器学习模型（随机森林、神经网络）来拟合数据，然后通过数学技巧（正交化）把机器学习带来的偏差剔除掉，只留下纯净的因果效应。

做减法时会遇到的问题：

- 漏掉混杂变量：
 - 有些变量对结果 Y 的影响很小（不显著），但对干预 T 的影响很大。如果仅凭统计显著性把它删了，就会漏掉混杂因素，导致结果偏差。
- 误控“对撞变量” (Collider) :
 - 左图（混杂）： X 是混杂因素，控制它是为了阻断后门路径（正确做法）。
 - 右图（对撞）： V 是 T 和 X 的共同结果（对撞因子）。如果你控制了 V ，反而会人为地打开一条非因果路径，制造出虚假的相关性（错误做法）。

核心冲突：预测好 $\neq$ 推断好

这是现代因果推断中最深刻的洞见之一：

- 目标不同：
 - 机器学习（预测）：目的是让 $\hat{Y}$ 尽可能接近 Y ，为了准，它可以使用正则化 (Shrinkage)，把系数往0压缩，甚至牺牲一点无偏性来换取低方差。
 - 因果推断（推断）：目的是算准 ATE （平均处理效应），它要求估计量必须是无偏的，且符合正态分布以便做假设检验。
- Plug-in 风险：
 - 如果你直接把机器学习预测出来的 $\hat{m}(x)$ 和 $\hat{e}(x)$ 代入公式去算因果效应 (Plug-in)，机器学习的“压缩偏差”会被传导进去，导致最终的因果效应算不准。↓

复杂环境：

当研究对象超出独立个体、单次处理、单一人群的经典设定时，因果推断需要在效应定义、识别条件与估计方法上进行结构性扩展，典型包括：干扰或网络效应、纵向动态过程、连续时间事件过程、跨人群外推与可迁移性。

干扰与网络效应

- 在标准因果推断假设中（SUTVA），通常假定无干扰：个体 i 的潜在结果仅取决于其自身处理 A_i ，而不依赖其他个体的处理分配 A_{-i} 。当该假设不成立时，标准的个体处理效应定义与识别策略将不再适用。

Social Network

干扰效应与机制分类

- 仅在存在干扰时，潜在结果写作 $Y_i(a_i, a_{-i})$ ，因此需要区分自身处理变化与他人处理分配变化，常用效应目标包括：
 - 直接效应：固定他人处理分配 a_{-i} ，比较 $Y_i(1, a_{-i})$ 与 $Y_i(0, a_{-i})$ ；
 - 间接/溢出效应：固定自身处理 a_i ，比较 $Y_i(a_i, a_{-i})$ 在不同 a_{-i} 下的差异；
 - 总效应：同时允许 a_i 与 a_{-i} 变化所产生的综合差异；
 - 总体效应：在给定分配机制或政策下，对总体结果的平均影响。
- 干扰的三类机制：
 - 直接干扰：他人处理直接进入 i 的结局机制；
 - 结局传播（contagion）：通过他人结局或状态的传播过程影响 i ；
 - 分配性干扰：处理改变资源、分组、匹配结构，从而间接影响结局。