

深度学习导论知识点整理（复习课框架版）

整理依据：复习课截图中的六大板块为框架，结合工作区内第 2 至 12 章 PPT/PDF/TXT 内容，并参考 `深度学习导论知识点整理.md` 的“定义-解释-考点”格式。

考试导向总览

- **核心复习方式**：先按复习课截图记住大框架，再对每个框架补充定义、公式、区别和典型问法。
- **概念题高频**：机器学习定义、可学习性、泛化、正则化、激活函数、损失函数、归一化、Dropout、ResNet、R-CNN 到 YOLO、Pretext、SimCLR、Word2Vec、VAE/GAN/Diffusion、N-gram、曝光偏差、三类 Transformer 架构、LoRA、RAG。
- **计算题高频**：线性回归闭式解、岭回归闭式解、PAC/VC 泛化界含义、PCA 方差保留率、卷积输出尺寸、感受野、IoU/mAP、VAE 的 KL 项、N-gram 概率与采样策略。
- **答题套路**：遇到“是什么”先给定义；遇到“为什么”说动机和解决的问题；遇到“比较”按输入、目标、结构、优缺点、适用任务展开；遇到“公式”写清变量含义。

全篇数学公式速查

机器学习基础

- **经验风险**： $\hat{R}_S(h) = \frac{1}{m} \sum_{i=1}^m \ell(h(x_i), y_i)$ 。
- **真实风险**： $R(h) = \mathbb{E}_{(x,y) \sim \mathcal{D}}[\ell(h(x), y)]$ 。
- **线性回归正规方程**： $X^\top X w = X^\top y$ ，若可逆， $w^* = (X^\top X)^{-1} X^\top y$ 。
- **岭回归闭式解**： $w^* = (X^\top X + \lambda I)^{-1} X^\top y$ 。
- **Lasso 回归**：目标常写为 $\min_w \|Xw - y\|_2^2 + \lambda \|w\|_1$ ，常导致稀疏解。
- **有限假设空间泛化界**： $R(h) \leq \hat{R}_S(h) + \sqrt{\frac{\ln |\mathcal{H}| + \ln(1/\delta)}{2m}}$ 。
- **VC 泛化界**： $|E(h) - \hat{E}(h)| \leq \sqrt{\frac{8k \ln(2em/k) + 8 \ln(4/\delta)}{m}}$ 。
- **Softmax**： $p_k = \frac{e^{z_k}}{\sum_j e^{z_j}}$ 。
- **K-Means 目标**： $\min_{\{c_i\}, \{\mu_k\}} \sum_i \|x_i - \mu_{c_i}\|_2^2$ 。
- **PCA 方差保留率**： $\frac{\sum_{i=1}^r \lambda_i}{\sum_{i=1}^d \lambda_i}$ 。

神经网络基础

- **MLP 层计算**： $z^\ell = W^\ell a^{\ell-1} + b^\ell$ ， $a^\ell = \sigma(z^\ell)$ 。
- **Sigmoid 及导数**： $\sigma(x) = \frac{1}{1+e^{-x}}$ ， $\sigma'(x) = \sigma(x)(1 - \sigma(x))$ 。
- **Tanh 导数**： $\tanh'(x) = 1 - \tanh^2(x)$ 。
- **ReLU 及导数**： $\text{ReLU}(x) = \max(0, x)$ ， $\text{ReLU}'(x) = 1(x > 0), 0(x < 0)$ 。
- **Leaky ReLU 导数**： $f(x) = \max(\alpha x, x)$ ， $f'(x) = 1(x > 0), \alpha(x < 0)$ 。
- **MSE 损失**： $L = \frac{1}{m} \sum_i \|\hat{y}_i - y_i\|_2^2$ 。
- **交叉熵损失**： $L = - \sum_c y_c \log p_c$ 。

- 梯度下降: $\theta_{t+1} = \theta_t - \eta \nabla_{\theta} L(\theta_t)$ 。

深度视觉模型

- 卷积输出尺寸: $O = \lfloor \frac{I+2P-K}{S} \rfloor + 1$ 。
- 感受野递推: $r_{\ell} = r_{\ell-1} + (k_{\ell} - 1)j_{\ell-1}$, $j_{\ell} = j_{\ell-1}s_{\ell}$ 。
- ResNet 残差连接: $y = F(x) + x$ 。
- IoU: $\text{IoU} = \frac{|B_p \cap B_g|}{|B_p \cup B_g|}$ 。
- Precision/Recall: $P = \frac{TP}{TP+FP}$, $R = \frac{TP}{TP+FN}$ 。

表征学习

- SimCLR / NT-Xent 损失: $\ell_{i,j} = -\log \frac{\exp(\text{sim}(z_i, z_j)/\tau)}{\sum_{k \neq i} \exp(\text{sim}(z_i, z_k)/\tau)}$ 。
- Skip-Gram 目标: $\max \sum_t \sum_{-c \leq j \leq c, j \neq 0} \log p(w_{t+j} | w_t)$ 。
- Skip-Gram Softmax: $p(o|c) = \frac{\exp(u_o^{\top} v_c)}{\sum_{w \in V} \exp(u_w^{\top} v_c)}$ 。

生成模型

- VAE ELBO: $\log p_{\theta}(x) \geq \mathbb{E}_{q_{\phi}(z|x)}[\log p_{\theta}(x|z)] - D_{\text{KL}}(q_{\phi}(z|x) \| p(z))$ 。
- VAE 损失: $\mathcal{L}_{\text{VAE}} = \mathcal{L}_{\text{recon}} + D_{\text{KL}}(q_{\phi}(z|x) \| p(z))$ 。
- VAE 重构误差: $\mathcal{L}_{\text{recon}} = \mathbb{E}_{z \sim q_{\phi}(z|x)} \|x - \hat{x}_{\theta}(z)\|_2^2$ 。
- VAE 高斯 KL 项: $D_{\text{KL}}(q \| p) = \frac{1}{2} \sum_j (\mu_j^2 + \sigma_j^2 - \log \sigma_j^2 - 1)$ 。
- VAE 重参数化: $z = \mu + \sigma \odot \epsilon$, $\epsilon \sim \mathcal{N}(0, I)$ 。
- GAN 目标: $\min_G \max_D \mathbb{E}_{x \sim p_{\text{data}}} \log D(x) + \mathbb{E}_{z \sim p_z} \log(1 - D(G(z)))$ 。
- GAN 最优判别器: $D^*(x) = \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_g(x)}$ 。
- GAN 与 JS 散度: $V(D^*, G) = -2 \log 2 + 2 \text{JSD}(p_{\text{data}} \| p_g)$ 。
- Diffusion 前向加噪: $q(x_t | x_{t-1}) = \mathcal{N}(\sqrt{1 - \beta_t} x_{t-1}, \beta_t I)$ 。
- Diffusion 合并加噪: $x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon$, $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$ 。
- Diffusion 训练损失: $\mathcal{L}_{\text{simple}} = \|\epsilon - \epsilon_{\theta}(x_t, t)\|_2^2$ 。

语言模型与大模型

- 语言模型链式法则: $P(w_1, \dots, w_T) = \prod_{t=1}^T P(w_t | w_1, \dots, w_{t-1})$ 。
- N-gram 近似: $P(w_t | w_1, \dots, w_{t-1}) \approx P(w_t | w_{t-n+1}, \dots, w_{t-1})$ 。
- N-gram 序列概率: $P_{n\text{-grams}}(w_{1:N}) = \prod_{i=n}^N P_{n\text{-grams}}(w_i | w_{i-n+1:i-1})$ 。
- N-gram 计数估计: $P_{n\text{-grams}}(w_i | w_{i-n+1:i-1}) = \frac{C(w_{i-n+1:i})}{C(w_{i-n+1:i-1})}$ 。
- 贪心搜索: $w_{i+1} = \arg \max_{w \in D} o_i[w]$ 。
- 束搜索候选条件: $\min\{o_i[w] \mid w \in B_i\} > \max\{o_i[w] \mid w \in D - B_i\}$ 。
- Temperature 采样: $P(w) = \text{softmax}(z_w/T)$ 。
- 注意力: $\text{Attention}(Q, K, V) = \text{softmax}(\frac{QK^{\top}}{\sqrt{d_k}})V$ 。

- 语言模型预训练损失: $L = -\sum_t \log p_\theta(w_t | w_{<t})$ 。
- LoRA 更新: $\Delta W = BA$, $B \in \mathbb{R}^{d \times r}$, $A \in \mathbb{R}^{r \times k}$ 。
- LoRA 前向传播: $h = W_0 x + \frac{\alpha}{r} BAx$ 。
- LoRA 权重合并: $W' = W_0 + \frac{\alpha}{r} BA$ 。
- Proxy-tuning logits 调整: $\tilde{s} = s_M + s_{M^+} - s_{M^-}$ 。
- Proxy-tuning 输出分布: $p_{\tilde{M}}(X_t | x_{<t}) = \text{softmax}(\tilde{s})$ 。
- TF-IDF: $\text{tfidf}(t, d) = \text{tf}(t, d) \cdot \text{idf}(t)$, 常见 $\text{tf}(t, d) = \frac{n_{t,d}}{\sum_{t'} n_{t',d}}$, $\text{idf}(t) = \log \frac{N}{\text{df}(t)}$ 。

一、机器学习基础

1.1 机器学习的定义

知识点定义：机器学习研究如何让程序从经验 E 中学习，在任务 T 上通过性能度量 P 获得改进。Tom Mitchell 的经典定义强调：经验、任务和性能度量三者缺一不可。

在某种学习范式下，基于训练数据（经验），利用学习算法，从受归纳偏置限制的假设类中选取可以达到学习目标的假设，该假设可以泛化到未知数据上。

知识点解释：机器学习不是单纯记忆训练样本，而是希望从有限数据中学习能泛化到未知数据的规律。课程中强调机器学习是一种通用方法论，与具体数据类型和模型类型无关。

可能考点：机器学习定义；经验 E 、任务 T 、性能度量 P 的含义；机器学习与深度学习的关系；为什么泛化是机器学习核心问题。

1.2 线性回归

知识点定义：线性回归用输入特征的线性组合预测连续值，模型可写为 $\hat{y} = x^\top w + b$ 。若把偏置并入特征，可写为 $\hat{y} = Xw$ 。

知识点解释：常用平方损失训练线性回归：

$$L(w) = \|Xw - y\|_2^2.$$

令梯度为 0，可得正规方程：

$$X^\top Xw = X^\top y.$$

当 $X^\top X$ 可逆时，闭式解为：

$$w^* = (X^\top X)^{-1} X^\top y.$$

可能考点：线性回归用于回归任务而不是分类任务；平方损失；正规方程推导； $X^\top X$ 不可逆时需要正则化或伪逆。

1.3 可学习性：假设空间、概念类与 PAC 理论

知识点定义：假设空间 $\mathcal{H}$ 是学习算法可能输出的所有预测函数集合；概念类 $\mathcal{C}$ 是可能的真实标记规则集合；PAC 学习研究能否以高概率学到近似正确的假设。

知识点解释：PAC 是 Probably Approximately Correct。 ϵ 表示允许的误差精度， δ 表示失败概率。若算法用足够样本后，以至少 $1 - \delta$ 的概率输出误差不超过 ϵ 的假设，则称相应概念类 PAC 可学习。

有限假设空间常见泛化界：

$$R(h) \leq \hat{R}_S(h) + \sqrt{\frac{\ln |\mathcal{H}| + \ln(1/\delta)}{2m}}.$$

可能考点： ϵ 和 δ 的含义；PAC 可学习和高效 PAC 可学习的区别；可实现 PAC 与不可知 PAC 的区别；样本复杂度为何与模型复杂度有关。

1.4 复杂度：VC 维与 Rademacher 复杂度

知识点定义：VC 维衡量二分类假设空间能打散的最大样本点数。若某 d 个点的任意 2^d 种标记都能被 $\mathcal{H}$ 中的假设实现，则称这 d 个点被打散。

知识点解释：VC 维越大，假设空间表达能力越强，但泛化界通常越松。 d 维空间中线性超平面分类器的 VC 维为 $d + 1$ 。Rademacher 复杂度衡量函数类拟合随机符号的能力，越能拟合随机标签，复杂度越高。

典型 VC 界：

$$|E(h) - \hat{E}(h)| \leq \sqrt{\frac{8k \ln(2em/k) + 8 \ln(4/\delta)}{m}},$$

其中 $k = \text{VCdim}(\mathcal{H})$ 。

可能考点：打散定义；VC 维不是简单等于参数个数；Rademacher 复杂度的直观含义；复杂度、样本量和泛化界的关系。

1.5 泛化性与经验风险最小化

知识点定义：真实风险 $R(h)$ 是模型在真实数据分布上的期望损失；经验风险 $\hat{R}_S(h)$ 是训练集上的平均损失。经验风险最小化选择训练集损失最小的假设：

$$\hat{h} = \arg \min_{h \in \mathcal{H}} \hat{R}_S(h).$$

知识点解释：学习的真正目标是低真实风险，但真实分布未知，只能用训练数据近似。泛化差距 $R(h) - \hat{R}_S(h)$ 反映训练表现和测试表现的差异。

可能考点：训练误差、验证误差、测试误差、泛化误差区别；为什么测试集不能反复调参；ERM 为什么可能过拟合。

1.6 过拟合和欠拟合

知识点定义：欠拟合指模型容量不足或训练不足，训练误差和测试误差都高；过拟合指训练误差低但测试误差高。

知识点解释：欠拟合通常对应高偏差，过拟合通常对应高方差。深度网络常处于过参数化状态，经典理论难以完全解释其泛化性能，实际还依赖数据规模、模型结构、SGD 隐式正则化、数据增强、归一化和预训练等因素。

可能考点：过拟合和欠拟合判断；如何缓解过拟合；双降现象；深度学习泛化为什么不能只看参数量。

1.7 没有免费午餐定理

知识点定义：没有免费午餐定理说明：若对所有可能任务平均，没有任何学习算法能普遍优于其他算法。

知识点解释：算法好坏依赖任务分布和先验假设。机器学习必须引入归纳偏置，例如线性模型偏好线性边界，CNN 偏好局部和平移结构，Transformer 偏好上下文交互。

可能考点：为什么不存在通用最优算法；归纳偏置的必要性；“没有免费午餐”与模型选择的关系。

1.8 正则化：岭回归与 Lasso 回归

知识点定义：正则化是在经验风险之外加入约束或惩罚项，以控制模型复杂度，缓解过拟合。

知识点解释：岭回归使用 L_2 正则：

$$\min_w \|Xw - y\|_2^2 + \lambda \|w\|_2^2,$$

闭式解为：

$$w^* = (X^\top X + \lambda I)^{-1} X^\top y.$$

Lasso 使用 L_1 正则：

$$\min_w \|Xw - y\|_2^2 + \lambda \|w\|_1,$$

常产生稀疏解，可用于特征选择。

可能考点：岭回归和 Lasso 的区别； L_2 使权重变小， L_1 更容易使部分权重为 0； λ 越大正则越强，但过大可能欠拟合。

1.9 监督学习：二分类、多分类、罕见类

知识点定义：监督学习使用带标签样本学习 $x \rightarrow y$ 的映射。二分类输出两个类别，多分类输出多个类别，罕见类问题中不同类别样本数量严重不均衡。

知识点解释：二分类可用线性分类器 $h(x) = \text{sign}(w^\top x + b)$ 。多分类常用 Softmax 输出类别概率：

$$p_k = \frac{e^{z_k}}{\sum_j e^{z_j}}.$$

交叉熵损失鼓励真实类别概率变大。类别不均衡时，准确率可能误导，需要关注 Precision、Recall、F1、AUC 等指标，可采用重采样、类别权重、Focal Loss 等方法。

可能考点：二分类与多分类形式；Softmax 与交叉熵；罕见类为什么不能只看 Accuracy；Precision 和 Recall 的含义。

1.10 无监督学习：PCA 与 K-Means

知识点定义：无监督学习不依赖人工标签，目标是发现数据内部结构。PCA 用低维线性子空间保留最大方差；K-Means 将样本划分为 K 个簇，使样本到簇中心距离平方和最小。

知识点解释：PCA 步骤包括中心化数据、计算协方差矩阵、求特征值和特征向量、选择最大特征值对应的主成分。K-Means 迭代执行样本分配和中心更新：

$$\min_{\{c_i\}, \{\mu_k\}} \sum_i \|x_i - \mu_{c_i}\|_2^2.$$

可能考点：PCA 主成分含义；方差保留率计算；K-Means 的两个迭代步骤；K 值和初始化对结果的影响。

二、神经网络基础

2.1 多层感知机基本结构

知识点定义：多层感知机（MLP）是由输入层、一个或多个隐藏层和输出层构成的前馈神经网络。

知识点解释：第 ℓ 层通常写为：

$$z^\ell = W^\ell a^{\ell-1} + b^\ell, \quad a^\ell = \sigma(z^\ell).$$

如果没有非线性激活函数，多层线性变换仍等价于单层线性变换，无法表达复杂非线性关系，例如 XOR 问题。

可能考点：MLP 的层次结构；为什么需要隐藏层和激活函数；通用近似定理说明宽度足够的单隐层网络理论上可逼近连续函数，但不代表容易训练。

2.2 激活函数

知识点定义：激活函数为神经网络引入非线性，使多层网络能够表示复杂函数。

知识点解释：常见激活函数包括 Sigmoid、Tanh、ReLU、Leaky ReLU。Sigmoid 输出在 $(0, 1)$ ，可解释为概率，但容易梯度消失；Tanh 输出在 $(-1, 1)$ ，中心化更好但仍可能饱和；ReLU 为 $\max(0, x)$ ，计算简单、缓解梯度消失，但可能出现死亡 ReLU；Leaky ReLU 在负半轴保留小斜率。

常见激活函数及导数：

- Sigmoid:

$$\sigma(x) = \frac{1}{1 + e^{-x}}, \quad \sigma'(x) = \sigma(x)(1 - \sigma(x)).$$

- Tanh:

$$\tanh'(x) = 1 - \tanh^2(x).$$

- ReLU:

$$\text{ReLU}(x) = \max(0, x), \quad \text{ReLU}'(x) = \begin{cases} 1, & x > 0, \\ 0, & x < 0. \end{cases}$$

在 $x = 0$ 处不可导，实践中通常取 0 或 1，不影响整体训练。

- Leaky ReLU:

$$f(x) = \max(\alpha x, x), \quad f'(x) = \begin{cases} 1, & x > 0, \\ \alpha, & x < 0. \end{cases}$$

可能考点：不同激活函数优缺点；常见激活函数导数；ReLU 为什么常用；没有激活函数的 MLP 为什么退化为线性模型。

2.3 损失函数

知识点定义：损失函数衡量模型预测与真实目标的差异，是训练优化的目标。

知识点解释：回归任务常用均方误差：

$$L = \frac{1}{m} \sum_i \|\hat{y}_i - y_i\|_2^2.$$

分类任务常用交叉熵：

$$L = - \sum_c y_c \log p_c.$$

损失函数是可优化的代理目标，真实评价指标如准确率、mAP、BLEU 不一定可导。

可能考点：回归和分类分别常用什么损失；交叉熵为什么适合分类；损失函数和评价指标的区别。

2.4 梯度计算与优化基础

知识点定义：梯度表示损失函数在参数空间中增长最快的方向，梯度下降沿负梯度方向更新参数：

$$\theta_{t+1} = \theta_t - \eta \nabla_{\theta} L(\theta_t).$$

知识点解释：学习率 η 控制每次更新步长。学习率过大可能震荡或发散，过小收敛慢。Hessian 矩阵包含二阶导数，可描述曲率，但深度网络参数量巨大，直接存储和求逆不现实。

可能考点：梯度下降更新公式；学习率影响；一阶优化和二阶优化区别；鞍点、局部极小、梯度消失和梯度爆炸。

2.5 反向传播与计算图

知识点定义：反向传播是用链式法则高效计算神经网络参数梯度的算法。

知识点解释：前向传播计算预测和损失，反向传播从输出层向输入层递推误差信号，并计算每层参数梯度。计算图是由变量和运算组成的有向无环图，反向传播本质上是在计算图上组织链式求导。

可能考点：反向传播不是新的求导规则，而是链式法则的高效实现；计算图节点和边含义；为什么深度学习框架能自动求导。

2.6 数据准备：归一化、数据增强、类型转换

知识点定义：数据准备包括归一化、数据增强和类型转换等步骤，用于改善训练稳定性和泛化能力。

知识点解释：归一化将输入特征调整到相近尺度，减少不同维度量纲差异；数据增强通过翻转、裁剪、旋转、颜色扰动等生成等价样本，提高模型对变化的鲁棒性；类型转换包括把标签转为 one-hot、把图像转为张量等。

可能考点：为什么要归一化；数据增强如何缓解过拟合；训练时增强和测试时增强的区别。

2.7 模型构建：Dropout

知识点定义：Dropout 在训练时以一定概率随机丢弃神经元或连接，测试时使用完整网络并进行尺度调整。

知识点解释：Dropout 可看作训练许多子网络的近似集成，减少神经元之间的共适应，提升泛化。训练和测试行为不同，是考试常见点。

可能考点：Dropout 的作用；训练阶段和测试阶段区别；为什么 Dropout 是正则化方法。

2.8 归一化层：BN、LN、IN、GN

知识点定义：归一化层对中间激活进行标准化，稳定训练并加速收敛。

知识点解释：批归一化 BN 主要沿 batch 维度统计均值和方差，训练时使用 mini-batch 统计量，测试时使用滑动平均统计量；层归一化 LN 对单个样本的特征维度归一化，不依赖 batch 大小，常用于 Transformer；实例归一化 IN 常用于风格迁移；组归一化 GN 将通道分组归一化，适合小 batch 场景。

可能考点：BN 和 LN 的区别；BN 测试阶段使用什么均值方差；Transformer 为什么常用 LN。

2.9 初始化

知识点定义：初始化决定训练起点，影响梯度传播和收敛速度。

知识点解释：不能把同一层所有权重初始化为相同值，否则神经元对称，学不到不同特征。Xavier 初始化适合 Tanh/Sigmoid 等近线性激活，He 初始化适合 ReLU，核心思想是控制前向和反向传播中的方差稳定。

可能考点：为什么不能全 0 初始化；初始化过大导致梯度爆炸，过小导致梯度消失；Xavier 与 He 初始化适用场景。

2.10 优化器、权重衰减与学习率技巧

知识点定义：优化器决定如何根据梯度更新参数。常见优化器包括 SGD、Momentum、AdaGrad、RMSProp、Adam、AdamW。

知识点解释：SGD 使用 mini-batch 梯度更新；Momentum 累积历史梯度方向，减少震荡；AdaGrad 为不同参数自适应学习率，但学习率可能过快衰减；RMSProp 用指数滑动平均改善 AdaGrad；Adam 结合一阶动量和二阶矩自适应；AdamW 将权重衰减与 Adam 更新解耦，实践中常用。

学习率技巧包括分段衰减、指数衰减、余弦衰减、Warmup、周期性学习率。Warmup 在训练初期逐步增大学习率，可稳定大模型训练。

可能考点：SGD、Momentum、Adam 的区别；权重衰减与 L_2 正则关系；AdamW 为什么常用；Warmup 的作用。

三、深度视觉模型

3.1 卷积计算

知识点定义：卷积层使用局部连接和权值共享，在图像上滑动卷积核提取局部特征。

知识点解释：卷积的核心归纳偏置是局部性和平移等变。局部连接减少参数量，权值共享使同一卷积核可在不同位置检测相同模式。多通道输入时，每个卷积核覆盖所有输入通道，并输出一个通道。

可能考点：卷积层和全连接层区别；局部连接、权值共享和平移等变；多通道卷积参数量计算。

3.2 步长、填充与输出尺寸

知识点定义：卷积输出尺寸由输入大小 I 、卷积核大小 K 、填充 P 和步长 S 决定：

$$O = \left\lfloor \frac{I + 2P - K}{S} \right\rfloor + 1.$$

知识点解释：Padding 可保留边缘信息并控制输出尺寸；Stride 越大，输出空间尺寸越小。Same convolution 常希望输出尺寸与输入相同，Valid convolution 不使用填充。

可能考点：给定 I, K, P, S 计算输出尺寸；为什么需要 padding；stride 对分辨率和计算量的影响。

3.3 感受野计算

知识点定义：感受野指特征图上某个单元对应原始输入图像中的区域大小。

知识点解释：感受野随层数增加而扩大。递推公式：

$$r_{\ell} = r_{\ell-1} + (k_{\ell} - 1)j_{\ell-1}, \quad j_{\ell} = j_{\ell-1}s_{\ell}.$$

其中 r_{ℓ} 为第 ℓ 层感受野大小, j_{ℓ} 为相邻特征点在输入上的间隔。

可能考点: 多层卷积/池化后的感受野计算; 大感受野有助于捕获全局上下文; 小卷积核堆叠可扩大感受野并增加非线性。

3.4 池化层

知识点定义: 池化层对局部区域进行下采样, 常见有最大池化和平均池化。

知识点解释: 最大池化保留局部最强响应, 平均池化保留区域平均信息。池化可降低空间分辨率和计算量, 提高一定平移不变性, 但也可能损失细节。

可能考点: 最大池化和平均池化区别; 池化与 stride convolution 的关系; 池化为何能降低计算量。

3.5 经典深度模型: VGGNet、GoogLeNet、ResNet

知识点定义: 经典 CNN 模型体现了视觉网络从浅层到深层、从直接堆叠到模块化设计的演进。

知识点解释: VGG 使用多个小卷积核堆叠, 结构规整; GoogLeNet 使用 Inception 模块, 在多个尺度上并行卷积; ResNet 引入残差连接:

$$y = F(x) + x.$$

残差连接让网络学习残差映射, 缓解深层网络退化和梯度传播困难。

可能考点: VGG 为什么用多个 3×3 卷积; Inception 的多尺度思想; ResNet 的残差结构和作用; 残差连接不是简单增加参数, 而是改善优化。

3.6 目标检测: IoU、mAP 与检测器演进

知识点定义: 目标检测同时预测目标类别和边界框。IoU 衡量预测框与真实框重叠程度:

$$\text{IoU} = \frac{|B_p \cap B_g|}{|B_p \cup B_g|}.$$

知识点解释: mAP 是检测任务常用指标, 先根据置信度排序预测框, 计算不同召回率下的 Precision, 再得到 AP, 对多个类别取平均得到 mAP。R-CNN 系列是两阶段检测器, YOLO 是单阶段检测器。

R-CNN 到 YOLO 的核心改进主线:

- **R-CNN**: 先用 Selective Search 等传统方法生成约 2000 个候选区域, 再把每个候选区域裁剪/缩放后分别送入 CNN 提特征, 最后用 SVM 分类并用边界框回归修正位置。改进点是把 CNN 特征引入目标检测; 主要问题是每个候选框都要单独跑 CNN, 重复计算严重, 训练流程也分成候选框、CNN、SVM、回归器多个阶段。
- **Fast R-CNN**: 先对整张图像只做一次 CNN 前向传播, 得到共享特征图, 再把候选区域映射到特征图上, 通过 RoI Pooling 得到固定尺寸特征, 最后用同一个网络同时做分类和边界框回归。改进方法是**共享卷积特征 + RoI Pooling + 多任务损失**; 效果是大幅减少重复 CNN 计算, 但候选区域仍依赖 Selective Search, 候选框生成仍是速度瓶颈。
- **Faster R-CNN**: 用 Region Proposal Network (RPN) 替代 Selective Search, 在共享特征图上直接预测候选框。RPN 基于 anchor 生成不同尺度和长宽比的候选框, 并同时预测 objectness 分数和边界框偏移。改进方法是**把候选框生成也变成可学习网络模块**; 效果是形成端到端的两阶段检测框架, 速度和精度都明显提升。
- **YOLO**: 取消候选区域生成, 把图像划分为网格, 由单个网络一次性预测边界框、置信度和类别概率。改进方

法是**将检测转化为单阶段回归问题**；效果是端到端、速度快、适合实时检测，但早期 YOLO 对小目标、密集目标和定位精度相对弱。

两阶段检测器先产生候选框，再对候选框分类和回归，代表是 Faster R-CNN，通常精度较高但速度较慢；单阶段检测器直接在图像或特征图上预测类别和位置，代表是 YOLO，通常速度更快但需要更好地处理正负样本不平衡、尺度变化和定位误差。

可能考点：IoU 计算；Precision/Recall/AP/mAP 含义；R-CNN、Fast R-CNN、Faster R-CNN、YOLO 的区别；单阶段与两阶段检测器优缺点。

3.7 类型转换与分割模型

知识点定义：分割任务从图像级分类或框级检测进一步到像素级预测。语义分割为每个像素预测类别，实例分割还区分同类不同实例。

知识点解释：FCN 将分类网络中的全连接层替换为卷积层，实现任意尺寸输入和像素级输出；上采样恢复空间分辨率；U-Net 使用编码器-解码器结构和跳跃连接，融合低层细节和高层语义。

可能考点：分类、检测、语义分割、实例分割区别；上采样技术；FCN 和 U-Net 核心思想。

3.8 视频视觉模型核心思想

知识点定义：视频视觉模型需要同时建模空间信息和时间动态。

知识点解释：视频任务包括动作识别、目标跟踪、视频分割等。常见思路包括 3D 卷积、双流网络、时序建模和时空注意力。与图像相比，视频多了时间维度，计算量更大，也需要处理帧间运动和长期依赖。

可能考点：视频模型与图像模型区别；为什么视频需要时序建模；2D CNN、3D CNN、Transformer 在视频中的思路。

四、表征学习

4.1 表征学习与 Pretext 任务

知识点定义：表征学习希望学习对下游任务有用的特征表示。Pretext 任务是自监督学习中人为设计的预训练任务，用数据自身构造监督信号。

知识点解释：典型 Pretext 任务包括旋转预测、颜色预测、拼图恢复、遮挡预测等。模型通过解决这些任务学习图像结构、语义和不变性。

可能考点：Pretext 任务定义；自监督与无监督、监督学习的关系；旋转预测和颜色预测为什么能学到视觉表示。

4.2 对比学习

知识点定义：对比学习通过拉近正样本对、推远负样本对来学习表示。

知识点解释：同一图像的两种增强视图通常构成正样本对，不同图像构成负样本对。好的表示应对数据增强保持不变，同时区分不同样本。

可能考点：正样本和负样本定义；对比学习为什么依赖数据增强；表征空间中“拉近/推远”的含义。

4.3 SimCLR 的网络结构和输入

知识点定义：SimCLR 是经典视觉对比学习方法，由数据增强、编码器、投影头 and 对比损失组成。

知识点解释：输入一批图像，每张图像经过两次随机增强得到两个视图；编码器 $f(\cdot)$ 提取表示 h ；投影头 $g(\cdot)$ 得到用于对比损失的向量 z ；训练完成后通常丢弃投影头，使用编码器表示。

可能考点：SimCLR 输入是增强后的成对视图；网络结构包括 encoder 和 projection head；为什么训练用投影空间、下游用表征空间。

4.4 SimCLR 损失函数

知识点定义：SimCLR 使用 NT-Xent 对比损失，对正样本对提高相似度，对其他样本降低相似度。

知识点解释：对正样本对 (i, j) ，损失可写为：

$$\ell_{i,j} = -\log \frac{\exp(\text{sim}(z_i, z_j)/\tau)}{\sum_{k \neq i} \exp(\text{sim}(z_i, z_k)/\tau)}.$$

τ 是温度系数，控制分布平滑程度。

可能考点：SimCLR 损失分子是正样本相似度，分母包括其他候选；温度参数作用；batch size 大通常提供更多负样本。

4.5 Word2Vec 与 Skip-Gram

知识点定义：Word2Vec 将词映射为稠密向量表示。Skip-Gram 用中心词预测上下文词，CBOW 用上下文预测中心词。

知识点解释：Skip-Gram 目标可写为：

$$\max \sum_t \sum_{-c \leq j \leq c, j \neq 0} \log p(w_{t+j}|w_t).$$

其中：

$$p(o|c) = \frac{\exp(u_o^\top v_c)}{\sum_{w \in V} \exp(u_w^\top v_c)}.$$

符号说明： w_t 表示序列中第 t 个词； c 在目标函数中表示上下文窗口半径，在概率公式 $p(o|c)$ 中表示中心词 center word； j 表示中心词左右的相对位置， $j \neq 0$ 表示不把中心词自己当作上下文词； w_{t+j} 是中心词 w_t 周围窗口内的上下文词； V 是词表； v_c 是中心词的输入词向量， u_o 是输出词 o 的输出词向量； $u_o^\top v_c$ 表示中心词和候选上下文词的相似度得分。分母对整个词表求和，因此原始 Softmax 计算代价高。

为降低计算量，常用负采样或层次 Softmax。

可能考点：Skip-Gram 和 CBOW 区别；中心词、上下文词、窗口大小；负采样为什么能降低计算量；词向量能捕获语义相似性。

4.6 语言自监督学习：掩码预测与 Next-Token Prediction

知识点定义：语言自监督学习通过文本自身构造训练目标。掩码预测要求根据上下文恢复被遮住的词；Next-Token Prediction 要求根据前文预测下一个 token。

知识点解释：BERT 使用 Masked Language Modeling，更适理解任务；GPT 使用自回归 Next-Token Prediction，更适合生成任务。掩码预测可利用双向上下文，自回归预测只能利用过去上下文。

可能考点：MLM 与 NTP 的区别；BERT 和 GPT 的预训练目标；为什么 Next-Token Prediction 能训练生成式语言模型。

五、生成模型

5.1 生成模型概述

知识点定义：生成模型学习数据分布 $p(x)$ 或条件分布 $p(x|c)$ ，用于生成新样本。

知识点解释：判别模型关注 $p(y|x)$ 或直接预测标签，生成模型关注数据本身如何产生。典型生成模型包括 VAE、GAN、Diffusion Models、Flow Matching。

可能考点：生成模型和判别模型区别；显式建模和隐式建模；无条件生成与条件生成。

5.2 VAE：变分自编码器的数学原理

知识点定义：VAE 是带概率潜变量的生成模型，用编码器近似后验 $q_\phi(z|x)$ ，用解码器建模 $p_\theta(x|z)$ 。

知识点解释：直接最大化 $\log p_\theta(x)$ 通常困难，VAE 优化证据下界 ELBO：

$$\log p_\theta(x) \geq \mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x|z)] - D_{\text{KL}}(q_\phi(z|x) \| p(z)).$$

第一项是重构项，第二项是正则项，使潜变量分布接近先验。

等价地，训练时常最小化负 ELBO，即 VAE 的损失函数：

$$\mathcal{L}_{\text{VAE}}(x) = D_{\text{KL}}(q_\phi(z|x) \| p(z)) - \mathbb{E}_{z \sim q_\phi(z|x)}[\log p_\theta(x|z)].$$

其中第一项是 **KL 散度正则项**，约束编码器输出的潜变量分布 $q_\phi(z|x)$ 尽量接近标准正态先验 $p(z) = \mathcal{N}(0, I)$ ；第二项是 **负重构似然**，约束解码器从采样得到的 z 中尽量还原输入 x 。若把解码器输出分布看作固定方差高斯分布，则最大化 $\log p_\theta(x|z)$ 等价于最小化重构误差，实践中常用 MSE：

$$\mathcal{L}_{\text{recon}} = \mathbb{E}_{z \sim q_\phi(z|x)} \|x - \hat{x}_\theta(z)\|_2^2.$$

因此常见实现可概括为：

$$\mathcal{L}_{\text{VAE}} = \mathcal{L}_{\text{recon}} + D_{\text{KL}}(q_\phi(z|x) \| p(z)).$$

可能考点：编码器、解码器、潜变量；ELBO 两项含义；VAE 为什么需要 KL 正则；VAE 损失由 **重构误差项 + KL 散度正则项** 组成；优化目标是最大化 ELBO 或等价地最小化负 ELBO。

5.3 VAE 正则项损失与重参数化技巧

知识点定义：当 $q(z|x) = \mathcal{N}(\mu, \text{diag}(\sigma^2))$ ， $p(z) = \mathcal{N}(0, I)$ 时：

$$D_{\text{KL}}(q \| p) = \frac{1}{2} \sum_j (\mu_j^2 + \sigma_j^2 - \log \sigma_j^2 - 1).$$

知识点解释：重参数化技巧将采样写为：

$$z = \mu + \sigma \odot \epsilon, \quad \epsilon \sim \mathcal{N}(0, I).$$

这样随机性从参数路径中分离，使梯度能反向传播到 μ 和 σ 。

可能考点：KL 项公式；重参数化技巧目的；VAE 生成样本时从先验采样 z 再解码。

5.4 GAN：模型架构、生成器与判别器

知识点定义：GAN 由生成器 G 和判别器 D 构成，二者进行极小极大博弈。

知识点解释：生成器把随机噪声 z 映射为样本 $G(z)$ ，试图骗过判别器；判别器判断输入是真实样本还是生成样本。
经典目标：

$$\min_G \max_D \mathbb{E}_{x \sim p_{data}} \log D(x) + \mathbb{E}_{z \sim p_z} \log(1 - D(G(z))).$$

可能考点：生成器和判别器职责；GAN 为什么是对抗训练；GAN 不需要显式似然但训练不稳定。

5.5 GAN 理论最优解与局限

知识点定义：给定生成器 G 时，最优判别器为：

$$D^*(x) = \frac{p_{data}(x)}{p_{data}(x) + p_g(x)}.$$

当 $p_g = p_{data}$ 时，判别器无法区分真假，输出趋于 $\frac{1}{2}$ 。

知识点解释：若把最优判别器 D^* 代回 GAN 的价值函数，生成器实际优化的是：

$$\min_G V(D^*, G) = \min_G \int_x p_{data}(x) \log \frac{p_{data}(x)}{p_{data}(x) + p_g(x)} + p_g(x) \log \frac{p_g(x)}{p_{data}(x) + p_g(x)} dx.$$

该目标可改写为：

$$V(D^*, G) = -2 \log 2 + 2 \text{JSD}(p_{data} \| p_g).$$

其中 $\text{JSD}(p_{data} \| p_g)$ 是 Jensen-Shannon 散度，用来衡量真实数据分布 p_{data} 与生成器分布 p_g 的差异。JSD 越小，两个分布越相似。因此，**生成器的理论最优解是让 $p_g = p_{data}$** ，此时 $\text{JSD}(p_{data} \| p_g) = 0$ ，判别器无法区分真实样本和生成样本， $D^*(x) = \frac{1}{2}$ 。

直观理解：判别器最优时，它会尽可能准确地地区分真图像和假图像；生成器再优化时，本质上是在让自己生成的分布不断逼近真实数据分布。理论上 GAN 优化可看作最小化 p_{data} 与 p_g 之间的 JS 散度，但实践中仍存在模式崩塌、训练不稳定、梯度消失和评价困难等问题。

可能考点：最优判别器公式；固定 D^* 后生成器优化目标等价于最小化 JS 散度；生成器理论最优解是 $p_g = p_{data}$ ；GAN 收敛时判别器输出 $\frac{1}{2}$ ；模式崩塌含义。

5.6 Diffusion Models：去噪模型设计

知识点定义：扩散模型通过逐步向数据加噪得到简单分布，再学习反向去噪过程生成样本。

知识点解释：前向过程逐步加高斯噪声。令 $\alpha_t = 1 - \beta_t$ ，其中 β_t 是第 t 步加入的噪声强度，则：

$$q(x_t | x_{t-1}) = \mathcal{N}(\sqrt{1 - \beta_t} x_{t-1}, \beta_t I).$$

等价地，可写成采样形式：

$$x_t = \sqrt{\alpha_t} x_{t-1} + \sqrt{1 - \alpha_t} \epsilon_t, \quad \epsilon_t \sim \mathcal{N}(0, I).$$

噪声合并的关键结论是：不需要一步步从 x_0 加噪到 x_t ，可以直接采样 x_t 。定义：

$$\bar{\alpha}_t = \prod_{s=1}^t \alpha_s.$$

则有：

$$q(x_t|x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)I),$$

采样形式为：

$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon, \quad \epsilon \sim \mathcal{N}(0, I).$$

简单推导思路：先看两步加噪，

$$x_1 = \sqrt{\alpha_1}x_0 + \sqrt{1 - \alpha_1}\epsilon_1,$$

$$x_2 = \sqrt{\alpha_2}x_1 + \sqrt{1 - \alpha_2}\epsilon_2.$$

代入 x_1 得：

$$x_2 = \sqrt{\alpha_1\alpha_2}x_0 + \sqrt{\alpha_2(1 - \alpha_1)}\epsilon_1 + \sqrt{1 - \alpha_2}\epsilon_2.$$

由于两个独立高斯噪声的线性组合仍是高斯噪声，噪声项方差为：

$$\alpha_2(1 - \alpha_1) + (1 - \alpha_2) = 1 - \alpha_1\alpha_2.$$

所以：

$$x_2 = \sqrt{\alpha_1\alpha_2}x_0 + \sqrt{1 - \alpha_1\alpha_2}\epsilon.$$

推广到 t 步，就得到 $x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon$ 。这就是扩散模型训练时可以随机采样任意时间步 t 并一次性构造 x_t 的原因。

训练时常让网络预测噪声 ϵ ，目标是：

$$\mathbb{E}_{t, x_0, \epsilon} \|\epsilon - \epsilon_\theta(x_t, t)\|_2^2.$$

可能考点：前向加噪和反向去噪； α_t 、 β_t 、 $\bar{\alpha}_t$ 的含义；为什么可以从 x_0 直接采样 x_t ；网络输入包括噪声样本 x_t 和时间步 t ；为什么扩散模型生成质量高但采样较慢。

5.7 Diffusion 的训练和推理流程

知识点定义：训练阶段学习去噪网络，推理阶段从随机噪声开始逐步去噪得到样本。

知识点解释：训练流程和推理流程方向相反。训练时从真实图像 x_0 出发，随机构造某个噪声版本 x_t ，让网络学习“这个 x_t 中加了什么噪声”；推理时没有真实图像，只能从纯噪声 x_T 开始，反复用网络估计噪声并去除噪声。

训练流程：

1. 从训练集采样真实图像 x_0 。
2. 随机采样时间步 $t \sim \{1, \dots, T\}$ 。
3. 采样高斯噪声 $\epsilon \sim \mathcal{N}(0, I)$ 。
4. 用合并加噪公式一次性构造：

$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon.$$

5. 将 x_t 和时间步 t 输入去噪网络 $\epsilon_\theta(x_t, t)$, 预测噪声。

6. 用 MSE 训练网络:

$$\mathcal{L}_{\text{simple}} = \|\epsilon - \epsilon_\theta(x_t, t)\|_2^2.$$

推理流程:

1. 从标准高斯分布采样初始噪声:

$$x_T \sim \mathcal{N}(0, I).$$

2. 对 $t = T, T-1, \dots, 1$ 逐步反向去噪。网络先预测当前噪声:

$$\hat{\epsilon} = \epsilon_\theta(x_t, t).$$

3. 根据预测噪声估计较干净的图像方向。DDPM 常见一步更新可写成:

$$x_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta(x_t, t) \right) + \sigma_t z,$$

其中 $z \sim \mathcal{N}(0, I)$, $\sigma_t z$ 表示采样时保留的随机性; 当 $t = 1$ 时通常不再额外加噪。

4. 循环结束后得到 x_0 , 即生成样本。

直观理解: 训练是在“给干净图像加噪后, 让模型猜噪声”; 推理是在“从纯噪声开始, 让模型一步步猜出并减掉噪声”。因为推理需要迭代很多步, 所以扩散模型通常生成质量高但采样较慢。

可能考点: 训练和推理方向相反; 训练时真实图像已知, 推理时从纯噪声开始; 训练目标常是预测噪声的 MSE; 合并加噪公式 $x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon$; DDPM、DDIM 的基本区别。

5.8 隐空间扩散如何实现

知识点定义: 隐空间扩散先用自编码器把图像压缩到潜空间, 在潜空间中进行扩散和去噪, 最后解码回图像。

知识点解释: Stable Diffusion 是典型隐空间扩散方法。相比像素空间扩散, 潜空间维度更低, 计算成本更小。文本条件通常通过文本编码器得到条件向量, 并用交叉注意力注入 U-Net。

可能考点: 隐空间扩散为什么省算力; VAE/Autoencoder、U-Net、文本编码器的作用; 条件扩散如何根据文本生成图像。

5.9 Flow Matching 基本概念

知识点定义: Flow Matching 通过学习一个连续时间速度场, 把简单分布逐步变换为数据分布。

知识点解释: 它关注从噪声到数据的连续路径及其速度, 而不是显式模拟逐步加噪去噪。复习课截图标注“只考基本概念”, 掌握定义、动机和与扩散模型的关系即可。

可能考点: Flow Matching 是学习分布变换的速度场; 与扩散模型同属生成建模路线; 不要求复杂推导。

六、大语言模型

6.1 基于统计的语言模型：N-gram 与曝光偏差

知识点定义：语言模型为词序列分配概率。链式法则：

$$P(w_1, \dots, w_T) = \prod_{t=1}^T P(w_t | w_1, \dots, w_{t-1}).$$

N-gram 使用 $n - 1$ 阶上下文近似：

$$P(w_t | w_1, \dots, w_{t-1}) \approx P(w_t | w_{t-n+1}, \dots, w_{t-1}).$$

N-gram 的统计估计依赖语料库中的相对频率。对文本序列 $w_{1:N} = \{w_1, w_2, \dots, w_N\}$, n-gram 模型可写为：

$$P_{n\text{-grams}}(w_{1:N}) = \prod_{i=n}^N P_{n\text{-grams}}(w_i | w_{i-n+1:i-1}).$$

其中条件概率用计数频率估计：

$$P_{n\text{-grams}}(w_i | w_{i-n+1:i-1}) = \frac{C(w_{i-n+1:i})}{C(w_{i-n+1:i-1})}.$$

也可把 $w_{i-n+1:i}$ 理解为长度为 n 的词序列 $\{w_{i-n+1}, \dots, w_i\}$, $w_{i-n+1:i-1}$ 是它前面的长度为 $n - 1$ 的上下文。 $C(w_{i-n+1:i})$ 表示该 n-gram 在语料库中出现的次数, $C(w_{i-n+1:i-1})$ 表示对应上下文在语料库中出现的次数。

常见特例：

- **Unigram**: $P(w_{1:N}) \approx \prod_i P(w_i)$, 不考虑上下文。
- **Bigram**: $P(w_{1:N}) \approx \prod_i P(w_i | w_{i-1})$, 只看前 1 个词。
- **Trigram**: $P(w_{1:N}) \approx \prod_i P(w_i | w_{i-2}, w_{i-1})$, 看前 2 个词。

知识点解释： n 越大，上下文更丰富，但数据稀疏更严重，因为长词序列在语料中更难重复出现，所以需要平滑方法处理零概率问题。曝光偏差指训练时模型看到真实前缀，推理时模型看到自己生成的前缀，错误会累积。

可能考点：N-gram 概率计算； $C(n\text{-gram})/C(\text{context})$ 的相对频率公式；unigram、bigram、trigram 区别；马尔科夫假设；数据稀疏和平滑；曝光偏差定义。

6.2 语言模型采样：贪心、束搜索、Top-k

知识点定义：语言模型采样决定如何从预测分布中选择下一个 token。

知识点解释：贪心搜索每步选概率最大 token，简单但容易局部最优和重复。若 $o_i[w]$ 表示第 i 轮模型对候选词 w 的输出概率或得分， D 表示词表，则贪心搜索为：

$$w_{i+1} = \arg \max_{w \in D} o_i[w].$$

束搜索每轮保留 b 个可能性最高的候选词或候选序列，形成候选集合 $B_i = \{w_{i+1}^1, w_{i+1}^2, \dots, w_{i+1}^b\}$, 满足：

$$\min\{o_i[w] \mid w \in B_i\} > \max\{o_i[w] \mid w \in D - B_i\}.$$

结束搜索时会得到 M 个候选序列集合 $\{B_i\}_{i=1}^M$, 再选择联合概率最大的序列。束搜索整体概率通常比贪心更好，但仍偏确定性，生成结果可能保守、重复，缺少多样性。

Top-k 采样只保留概率最高的 k 个 token，将其他 token 概率置零后重新归一化，再随机采样。它的候选集合大小固定， k 太小会保守， k 太大可能采到低质量词。

Top-p 采样也叫 nucleus sampling，先按概率从高到低排序，选择累计概率达到 p 的最小候选集合，再在集合内随机采样。它的候选集合大小是动态的：模型很确定时集合小，模型不确定时集合大。

Temperature 用来调节分布尖锐程度，常见形式为：

$$P(w) = \text{softmax}(z_w/T).$$

T 越小分布越尖锐，输出更确定； T 越大分布越平滑，随机性和多样性更强。

可能考点：贪心和束搜索都偏概率最大化，Top-k 与 Top-p 属于随机采样；束搜索公式和 beam size 含义；Top-k 固定候选数，Top-p 固定累计概率阈值；Temperature 大小对多样性的影响。

6.3 语言模型预训练：Scaling Law 与损失函数

知识点定义：语言模型预训练通常采用大规模文本和自监督目标，最常见是 next-token prediction 的交叉熵损失。

知识点解释：Scaling Law 描述模型性能随参数量、数据量和计算量增加呈现可预测改善。损失函数通常是对真实下一个 token 的负对数似然：

$$L = - \sum_t \log p_{\theta}(w_t | w_{<t}).$$

可能考点：预训练目标；Scaling Law 的三个关键因素：模型规模、数据规模、计算量；损失下降不完全等同于真实任务能力提升。

6.4 语言模型后训练：价值对齐、RLHF、GRPO

知识点定义：后训练是在预训练模型基础上进一步让模型更符合人类指令、偏好和安全要求。

知识点解释：SFT 使用高质量指令数据微调；RLHF 先训练奖励模型，再用强化学习优化模型输出；PPO 是常见强化学习优化算法；GRPO 是面向推理训练的相对偏好优化方法，减少对单独价值函数的依赖。

可能考点：预训练、SFT、RLHF 的区别；价值对齐含义；PPO/GRPO 只需掌握基本作用和位置。

6.5 大语言模型三类架构

知识点定义：Transformer 大模型常分为 Encoder-only、Decoder-only、Encoder-Decoder 三类。

知识点解释：

- **Encoder-only**：双向编码上下文，代表 BERT、RoBERTa，适合理解、分类、匹配、抽取。
- **Decoder-only**：自回归单向生成，代表 GPT、LLaMA，适合文本生成、对话和通用大模型。
- **Encoder-Decoder**：编码器理解输入，解码器生成输出，代表 T5、BART，适合翻译、摘要、条件生成。

可能考点：三类架构的注意力方向、训练目标、代表模型和适用任务；为什么当前通用 LLM 多为 Decoder-only。

6.6 Transformer 核心结构

知识点定义：Transformer 由注意力层、前馈网络、残差连接、层归一化和位置编码组成。

知识点解释：自注意力让每个 token 与序列中其他 token 交互：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V.$$

多头注意力在多个子空间学习不同关系。位置编码弥补注意力本身不含顺序信息的问题。残差连接和 LayerNorm 稳定深层训练。

考点答案：

- **Q/K/V 含义**： Q 是 Query，表示当前 token 想要查询什么信息； K 是 Key，表示每个 token 可被匹配的索引特征； V 是 Value，表示真正被加权汇总的信息内容。注意力先用 QK^T 计算 token 之间的相关性，再用 softmax 得到权重，最后对 V 加权求和。
- **为什么除以 $\sqrt{d_k}$** ：当 d_k 较大时， Q 和 K 的点积方差会随维度增大而变大，导致 softmax 输入过大，分布过尖，梯度容易变小。除以 $\sqrt{d_k}$ 可以稳定点积尺度，使 softmax 不至于过度饱和。
- **多头注意力作用**：多头注意力把表示拆到多个子空间中并行计算注意力，不同头可以关注不同关系，例如局部依赖、长距离依赖、语法关系、实体关系等。最后将多个头的结果拼接并线性变换，从而增强模型表达能力。
- **位置编码必要性**：自注意力本身对输入顺序不敏感，如果没有位置编码，模型只能看到 token 集合，难以区分“我喜欢你”和“你喜欢我”这类顺序不同的句子。位置编码向 token 表示中加入位置信息，使模型能够建模词序和相对/绝对位置。
- **LayerNorm 作用**：LayerNorm 对每个样本内部的特征维度进行归一化，稳定激活分布，缓解训练不稳定，加快收敛。它不依赖 batch 大小，因此比 BatchNorm 更适合变长序列和大语言模型。
- **残差连接作用**：残差连接把子层输入直接加到输出上，使信息和梯度更容易跨层传播，缓解深层网络训练中的梯度消失和退化问题。Transformer 中常见形式是 $x + \text{Sublayer}(x)$ ，再配合 LayerNorm 使用。

可能考点：Q/K/V 含义；为什么除以 $\sqrt{d_k}$ ；多头注意力作用；位置编码必要性；LN 和残差连接作用。

6.7 参数高效微调：Adapter 与 LoRA

知识点定义：参数高效微调（PEFT）冻结大部分预训练模型参数，只训练少量新增参数以适配下游任务。

知识点解释：主流 PEFT 方法可分为三类：

- **参数附加方法**：冻结原模型参数，通过增加并训练新的附加参数或模块来适配任务。按附加位置可分为三类：
 - **加在输入**：把额外参数附加到输入嵌入中，代表方法是 Prompt-tuning。它学习一段可训练的连续嵌入，称为软提示（Soft Prompt），并与真实文本 embedding 一起输入模型。不同于人工写的硬提示（Hard Prompt），软提示会在训练中动态更新。通常只训练软提示参数，关键在于软提示长度和初始化。优势是对模型结构改动小、灵活性好、内存效率高、适合多任务，且模型规模越大时效果通常越明显。
 - **加在模型**：把额外模块插入预训练模型隐藏层，代表方法包括 Prefix-tuning 和 Adapter-tuning。Adapter-tuning 通常在多头注意力层或前馈层后插入适配器模块，适配器多采用瓶颈结构，即下投影、非线性映射、上投影。训练时冻结原模型，只更新 Adapter、LayerNorm 或最后分类层等少量参数。优势是保留原始预训练模型参数，能更好保持预训练知识，同时在泛化能力和任务适应性上通常表现更稳。
 - **加在输出**：在解码时调整模型输出分布，代表思路是 Proxy-tuning。它适合大模型难以全量微调或只能访问黑盒模型输出分布的场景。设代理模型为 M ，反专家模型为 M^- ，微调后的专家模型为 M^+ ，三者需要共享词表。在每个自回归时间步，先取三者 logits 分布 s_M, s_{M^+}, s_{M^-} ，调整后的 logits 为：

$$\tilde{s} = s_M + s_{M^+} - s_{M^-}.$$

再用 softmax 得到下一个词分布：

$$p_{\tilde{M}}(X_t|x_{<t}) = \text{softmax}(\tilde{s}).$$

直观上, $s_{M^+} - s_{M^-}$ 表示“微调带来的方向”, 把这个方向加到大模型或代理模型输出上, 就能在不直接微调目标大模型全部参数的情况下改变生成偏好。优势是能以更小代价驱动大参数量或黑盒模型, 在无法访问模型内部参数时仍可通过输出分布调整适配实际应用场景。

- **参数选择方法**: 不新增或少新增参数, 而是从原模型参数中选择一小部分进行更新, 其余参数冻结。它可分为两类:
 - **基于规则的方法**: 根据人工规则、专家经验或模型结构预先指定哪些参数可训练。代表方法是 **BitFit**, 它只优化神经网络每一层的偏置项 (biases) 以及任务特定分类头。优点是参数效率极高, 偏置项占总参数比例很小, 微调成本低; 训练过程通常较稳定, 甚至在部分 BERT/RoBERTa 任务上接近全量微调。缺点是依赖人工规则, 表达能力有限, 主要在较小规模模型上验证较多, 在更大模型上的效果不一定稳定。其它规则方法还包括只微调最后若干层、只微调 LayerNorm 或选择绝对值较小/较重要的参数, 如 PaFi 等。
 - **基于学习的方法**: 在训练过程中由算法自动识别应更新的参数子集。代表方法是 **Child-tuning**, 它通过梯度掩码矩阵只更新被选中的子网络参数, 屏蔽其它参数梯度, 从而实现参数选择。优点是选择策略更自适应, 适合资源受限且需要快速适配新任务的场景; 缺点是需要额外计算资源学习或更新参数选择策略, 且“选多少、选哪些”会影响性能。其它学习式方法包括 Fish-Dip、LT-SFT、SAM 等。

总体优点: 显著减少需要更新的参数, 降低计算成本和内存需求, 适合资源受限或快速迁移场景。总体难点: 如何选择最佳参数子集, 以及如何平衡参数更新数量和模型性能。

- **低秩适配方法**: 通过低秩矩阵近似原始权重更新矩阵, 并只微调低秩矩阵, 以大幅降低可训练参数量。其理论动机来自 **本征维度假设**: 预训练语言模型微调时, 即使只在一个低维子空间中更新参数, 也可能达到接近全量参数更新的性能。代表方法是 **LoRA**。

LoRA 的数学原理: 对原始线性层 $h = W_0x$, 冻结预训练权重 W_0 , 只学习低秩更新 ΔW 。若 $W_0 \in \mathbb{R}^{d \times k}$, 则完整更新矩阵 ΔW 也为 $d \times k$ 。LoRA 将其低秩分解为:

$$\Delta W = BA, \quad B \in \mathbb{R}^{d \times r}, \quad A \in \mathbb{R}^{r \times k}, \quad r \ll \min(d, k).$$

因此前向传播变为:

$$h = W_0x + \Delta Wx = W_0x + BAx.$$

实践中常加入缩放系数:

$$h = W_0x + \frac{\alpha}{r}BAx,$$

其中 r 是 LoRA 秩, α 是缩放超参数。LoRA 通常加在 Attention 层或 FFN 层的投影矩阵上, 例如 W_q, W_k, W_v, W_o 或 MLP 投影矩阵。

初始化与微调: 常见做法是随机初始化 A , 将 B 初始化为 0, 使训练开始时 $\Delta W = BA = 0$, 模型初始输出与原预训练模型完全一致, 避免一开始破坏模型能力。微调时冻结 W_0 , 只更新 A, B 。推理时可将 LoRA 权重合并回原权重:

$$W' = W_0 + \frac{\alpha}{r}BA,$$

这样推理阶段无需额外计算分支, 几乎不增加推理延迟。

从显存占用看, 训练大模型主要消耗四部分: **权重、激活、梯度、优化器状态**。LoRA 的优化重点如下:

- **权重**: 原模型权重仍需加载, 但被冻结; 新增可训练权重只有小矩阵 A, B 。

- **梯度**：不需要保存原模型大部分参数的梯度，只保存 LoRA 参数梯度，显著降低梯度显存。
- **优化器状态**：Adam 等优化器只为可训练的 A, B 保存一阶/二阶动量，不再为全部大模型参数保存优化器状态，这是 LoRA 节省训练显存的关键来源。
- **激活**：反向传播仍需要部分激活用于计算 LoRA 参数梯度，因此 LoRA 对激活显存的降低不如对梯度和优化器状态明显；实际可结合 checkpointing、量化等进一步省显存。

LoRA 的主要优势：

- **参数效率**：训练参数量从 $d \times k$ 降为 $r(d + k)$ ，当 r 很小时节省明显。
- **插件化特性**：不同任务可保存不同 LoRA 插件，原模型共享不变，切换任务只需加载不同 LoRA 权重。
- **跨任务泛化**：低秩更新可捕获任务相关变化，一些 LoRA 模块可组合、迁移或作为多任务适配基础。

LoRA 变体常从四个方向改进：

- **性能改进**：动态选择秩或分配秩，如 AdaLoRA；改进初始化、缩放和正则化，使低秩更新表达能力更强。
- **任务泛化**：研究多个 LoRA 的组合、融合和路由，让不同任务共享或复用 LoRA 模块，如 LoRAHub 一类方法。
- **训练改进**：结合量化、低精度训练、梯度检查点等降低训练显存和计算成本，如 QLoRA 用量化基座模型配合 LoRA 训练。
- **推理改进**：将 LoRA 合并回原权重，或设计高效 LoRA 切换、缓存和多 LoRA 服务机制，减少推理延迟和部署成本。

可能考点：PEFT 三类方法：参数附加、参数选择、低秩适配；参数附加方法按位置分为加在输入、加在模型、加在输出；Soft Prompt 与 Hard Prompt 区别；Adapter 的瓶颈结构；Proxy-tuning 的 logits 调整公式；参数选择方法分为基于规则和基于学习；BitFit 只微调 bias 和分类头；Child-tuning 用梯度掩码选择子网络更新；LoRA 的公式 $\Delta W = BA$ ；LoRA 初始化为什么常令 $B = 0$ ；LoRA 主要节省梯度和优化器状态显存；LoRA 推理时可合并权重；LoRA 变体的性能、泛化、训练、推理四类改进方向。

6.8 检索增强生成：幻觉、RAG 架构、编码器与检索器

知识点定义：RAG 将外部知识检索与语言模型生成结合，缓解模型幻觉和知识过时问题。

幻觉定义：大语言模型生成的内容看似合理，但可能逻辑混乱、与事实相悖，或超出模型真实知识范围。第十二章 PPT 将幻觉来源分为训练数据和模型本身两大类，共 7 种：

- **知识过时**：训练数据存在时间滞后，模型训练后现实知识发生更新，导致模型内部知识落后于当前事实。
- **知识边界**：训练数据有限，无法覆盖所有知识；训练数据采集后还会不断产生新知识，模型对边界外问题容易编造。
- **知识偏差**：训练数据中包含错误、偏见或不均衡信息，模型会继承这些偏差并在生成中放大。
- **对齐不当**：人类偏好对齐阶段的标注或偏好数据有问题，可能引入不良偏好，使模型为了迎合回答而牺牲事实性。
- **知识长尾**：训练数据中某些知识出现频率低，模型学习不充分，面对低频事实、冷门实体或专业问题时更容易出错。
- **曝光偏差**：训练时常使用 teacher forcing，模型看到真实前缀；推理时使用自己生成的前缀，一旦前面出错，错误会逐步累积。
- **解码偏差**：解码策略中的随机性或搜索偏好会影响输出，例如采样温度过高、Top-k/Top-p 设置不当，可能生成不符合常理的内容。

知识点解释：典型 RAG 流程包括：文档切分、向量化编码、建立索引、查询改写或编码、检索相关片段、重排、把检索结果放入提示词、生成答案。编码器用于把文档和查询映射为向量，检索器负责从知识库中找出与查询相关的知识文本。检索质量会直接影响生成答案的准确性、覆盖率和幻觉程度，检索效率会影响整个 RAG 系统的响应速度。

检索器部分：

- **知识检索四阶段**：PPT 将知识检索概括为 **知识库构建、查询构建、文本检索、检索结果重排**。知识库构建负责清洗、切分、编码和索引文档；查询构建负责把用户问题改写、扩展或编码成适合检索的形式；文本检索负责召回相关候选文档；重排负责对候选文档进一步排序精选。
- **检索质量与效率**：检索质量包括召回率、精度、多样性等，质量差会导致生成器拿不到关键证据或拿到错误证据；检索效率决定用户等待时间和系统吞吐量，尤其在大规模向量库中需要高效索引。
- **三类文本检索器**：
 - **判别式检索器**：对查询和文档提取特征表示，并计算相关性分数，是 RAG 中最常见的检索器类型，包括稀疏编码器、双编码器和交叉编码器。
 - **生成式检索器**：把文档信息记忆在模型参数中，查询时直接生成相关文档的标识符（Doc ID）。训练通常包括索引任务和检索任务，优点是只需存储模型参数和文档标识符、生成速度快，缺点是知识更新和大规模训练更复杂。
 - **图检索器**：以图数据库或知识图谱为知识库，通常由〈主体，谓词，客体〉三元组构成，适合需要结构化关系、全局信息和复杂推理的任务。其流程可分为图索引构建、子图召回和生成。
- **判别式检索器的三种结构**：
 - **稀疏检索器**：使用 TF-IDF、BM25 等稀疏表示进行关键词匹配。TF-IDF 用词频和逆文档频率衡量词语重要性： $\text{tfidf}(t, d) = \text{tf}(t, d) \text{idf}(t)$ 。优点是简单、高效、可解释，适合关键词精确匹配；缺点是语义泛化能力弱，难处理同义表达。
 - **双编码器检索器**：查询和文档分别经过独立编码器得到向量 $u = \text{Encoder}(query)$ 、 $v = \text{Encoder}(doc)$ ，再用点积或余弦相似度计算相关性。文档向量可离线预计算并存入向量数据库，因此召回效率高；缺点是查询和文档在编码阶段缺乏深度交互。ColBERT 通过 token 级 late interaction 缓解浅交互问题。
 - **交叉编码器检索器**：将查询和文档拼接后一起输入模型，直接输出相关性分数。优点是查询和文档可以深度交互，相关性判断更准确；缺点是计算量大，不适合直接对海量文档做第一阶段召回，更常用于 **重排阶段**。
- **向量索引与向量数据库**：大规模知识库中不能逐一比较所有文档向量，需要用高效向量索引提升检索效率。PPT 提到索引方法可分为基于量化、哈希、树和图的方法；常见向量数据库包括 Milvus、Qdrant、Chroma、Weaviate、Pinecone 等。
- **检索结果重排**：第一阶段检索为了速度可能召回低质量文档，因此需要重排器进一步精选。重排方法包括：基于交叉编码器的重排，利用深度交互重新评估查询-文档相关性；基于上下文学习的重排，例如 RankGPT，通过设计 Prompt 让大模型对候选文档排序。
- **检索器是否微调**：在黑盒增强中，检索器和大模型可直接组合不微调，如 In-Context RALM；也可固定大模型、根据大模型输出反馈微调检索器，如 REPLUG，用困惑度作为监督信号训练检索器。白盒增强中，检索器可固定而微调语言模型，如 RETRO；也可检索器与语言模型协同微调，如 ATLAS，使检索器输出的文档相关性分布与文档对语言模型的贡献分布一致。

可能考点：幻觉定义；幻觉 7 种来源：知识过时、知识边界、知识偏差、对齐不当、知识长尾、曝光偏差、解码偏差；RAG 基本架构；知识检索四阶段；检索器、重排器、生成器的作用；稀疏检索器、双编码器、交叉编码器的区别；TF-IDF/BM25、向量检索、图检索器分别适合什么场景；为什么交叉编码器常用于重排；检索器微调与协同微调的区别；编码器在 RAG 中负责向量表示。

6.9 何时增强、何处增强、何处检索

知识点定义：RAG 不一定每次都检索，也不一定只在生成前增强。需要判断何时增强、何处增强和如何增强。

知识点解释：

- **何时增强**：决定是否触发检索。核心问题是判断大语言模型是否已经具有回答该问题所需的 **内部知识**：若内部知识足够，可以不增强；若问题涉及实时信息、私有知识、专业知识、长尾事实、模型知识边界外内容，或模型表现出不确定性，则应触发检索增强。PPT 中把判断方法分为两类：
 - **外部观测法**：不访问或不修改模型内部参数，只通过训练数据、输入输出行为等外部现象判断模型是否掌握知识。典型方法包括：直接用 Prompt 询问模型是否知道相关事实；观察知识在训练数据中出现的频率，因为知识出现频率通常与模型记忆程度正相关；在无法获得训练数据时，构造伪训练数据统计量，例如用维基百科访问量、谷歌搜索热度、实体流行度等作为知识流行度指标，并设定阈值判断是否需要增强。局限是模型可能过度自信，训练数据常不可见，流行度只能近似反映模型是否真正掌握知识。
 - **内部观测法**：在模型参数或中间状态可访问时，观测模型生成时的隐藏状态变化，更精确地评估模型是否掌握某类知识。典型做法是分析 Attention、MLP 等中间层表示对已知问题和未知问题的差异，或训练探针（如线性分类器）根据问题的内部表示预测该问题属于“模型已知”还是“模型未知”。优点是判断更直接，缺点是需要访问模型内部，通常不适用于黑盒大模型。
- **何处检索**：决定从哪里取知识。常见知识源包括公开网页、搜索引擎、企业内部文档库、数据库、知识图谱、多模态资料库和历史对话记忆。检索方式包括稀疏检索（如 BM25，适合关键词精确匹配）、稠密检索（向量检索，适合语义相似）、混合检索（关键词 + 向量）以及重排模型。工程流程通常是：文档切分、清洗、向量化、建立索引；查询时进行 query rewrite 或 query expansion，再检索 Top-k 文档并重排。
- **何处增强**：决定检索结果在生成模型中如何使用。PPT 将其分为输入端、中间层和输出端三类：

增强位置	方法含义	优点	缺点
输入端增强	将用户问题与检索到的外部知识直接拼接到 Prompt 中，再输入大语言模型生成答案。	直观且易于实现；模型可直接从输入上下文提取所需信息；无需复杂处理或转换；是当前最主流的方法。	检索文本过长时会占用上下文窗口，增加推理计算成本和计算负担，并可能引入噪声。
中间层增强	先将外部知识转换为向量表示，再通过交叉注意力或融合模块注入模型隐藏状态；代表方法如 RETRO。	能更深入地影响模型内部表示，减少对输入长度的依赖，适合把检索知识与模型表示进行细粒度融合。	需要复杂的模型结构设计、训练和调整，通常无法直接应用于黑盒模型。
输出端增强	在模型生成后，利用外部知识对生成文本进行比对、校准和后矫正。	可提高生成文本与外部知识的一致性，增强答案准确性和可靠性。	效果依赖检索到的外部知识质量和相关性，若证据错误或不完整，校准结果也更容易受影响。

其中，输入端增强最容易落地；中间层增强更像“模型结构级融合”；输出端增强属于后处理方法。

- **多次增强**：复杂问题往往一次检索不够。多跳问答、链式推理、复杂报告生成中，可采用“检索-生成-再检索-再生成”的迭代流程；也可以先把问题拆成子问题，分别检索证据，再汇总回答。多次增强能提高覆盖率，但也会增加延迟，并带来证据冲突和噪声累积问题。

三者关系：**何时增强** 决定要不要检索，**何处检索** 决定从哪个知识源和用什么检索器取信息，**何处增强** 决定检索到的信息以什么方式进入生成过程。

可能考点：为什么不是所有问题都需要 RAG；何时增强的核心是判断模型是否具有内部知识；外部观测法与内部观测法的区别；Prompt 直接询问、训练数据频率、伪训练数据统计量、流行度阈值、探针分类器分别如何判断是否增强；何处检索的知识源和检索方式；输入端增强、中间层增强、输出端增强的定义和优缺点；多跳问题为什么需要多次增强。

6.10 降本增效：KV-cache 与 RAGCache

知识点定义：降本增效关注在保证效果的同时降低推理延迟、显存和计算成本。

知识点解释：KV-cache 缓存 Transformer 解码时历史 token 的 Key/Value，避免每步重复计算历史上下文。

RAGCache 等缓存方法复用检索结果或中间表示，减少重复检索和重复编码。其他方法包括模型量化、蒸馏、裁剪、批处理、短上下文压缩和高效索引。

可能考点：KV-cache 为什么能加速自回归解码；RAG 系统成本来源；缓存、量化、重排和索引优化的作用。

七、按截图快速背诵清单

机器学习基础

- 机器学习定义：经验 E 、任务 T 、性能 P 。
- 线性回归：平方损失、正规方程、闭式解。
- 可学习性：假设空间、概念类、PAC、 ϵ 、 δ 。
- 复杂度：VC 维、打散、Rademacher 复杂度。
- 泛化性：经验风险、真实风险、泛化差距。
- 过拟合/欠拟合：训练误差与测试误差关系。
- 没有免费午餐：无通用最优算法，必须有归纳偏置。
- 正则化：岭回归 L_2 ，Lasso L_1 。
- 监督学习：二分类、多分类、罕见类。
- 无监督学习：PCA、K-Means。

神经网络基础

- 多层感知机：输入层、隐藏层、输出层。
- 激活函数：Sigmoid、Tanh、ReLU、Leaky ReLU。
- 损失函数：MSE、交叉熵。
- 梯度计算：梯度下降、链式法则、反向传播。
- 数据准备：归一化、数据增强、类型转换。
- 模型构建：Dropout、BN、LN、初始化。
- 训练优化：SGD、Momentum、Adam、AdamW、权重衰减、学习率技巧。

深度视觉模型

- 卷积计算：局部连接、权值共享。
- 步长、填充、输出尺寸。
- 感受野计算。
- 池化层。
- 经典模型：VGGNet、GoogLeNet、ResNet。
- 目标检测：IoU、mAP、R-CNN 到 YOLO。
- 分割模型：上采样、FCN、U-Net。
- 视频视觉：空间和时间共同建模。

表征学习

- Pretext 任务：旋转预测、颜色预测。
- 对比学习：正样本、负样本、拉近推远。
- SimCLR：增强视图、编码器、投影头、NT-Xent。
- Word2Vec：Skip-Gram 公式。
- 语言自监督：掩码预测、Next-Token Prediction。

生成模型

- VAE：编码器、解码器、ELBO、KL 正则、重参数化。
- GAN：生成器、判别器、极小极大目标、最优判别器。
- Diffusion：前向加噪、反向去噪、训练预测噪声、推理从噪声开始。
- 隐空间扩散：先压缩到潜空间再扩散。
- Flow Matching：学习从简单分布到数据分布的速度场。

大语言模型

- N-gram：马尔科夫假设、数据稀疏、曝光偏差。
- 采样：贪心、束搜索、Top-k、Top-p、Temperature。
- 预训练：Next-Token Prediction、交叉熵、Scaling Law。
- 后训练：SFT、RLHF、PPO、GRPO。
- 架构：Encoder-only、Decoder-only、Encoder-Decoder。
- PEFT：Adapter、LoRA。
- RAG：幻觉、架构、编码器、何时增强、何处增强、降本增效。