

第二章 精度分析和误差分析

§2.1 向量范数和矩阵范数

(一) 向量范数 (I) 定义 (II) 性质

(二) 矩阵范数 (I) 定义 (II) 性质 (III) 诱导范数

(IV) 谱半径和矩阵范数的关系 (V) 收敛性

§2.2 精度分析

§2.3 误差分析

(一) 精度估计

(二) 舍入误差分析

(I) 浮点数

计算机中的浮点数可表示为：

$$x = \pm w \times \beta^J \quad L \leq J \leq U$$

↙ 尾数
↓ 基数
↗ 阶

$$w = d_0.d_1d_2\cdots d_{t-1}, \quad t \text{ 为尾数位数} \quad 0 \leq d_i < \beta$$

若 $d_0 \neq 0$ ，则称为规范化浮点数。

记浮点数的全体构成的集合为 F ，即

$$F = \{0\} \cup \{x = \pm d_0.d_1\cdots d_{t-1} \times \beta^J, 0 \leq d_i < \beta, d_0 \neq 0, L \leq J \leq U\}$$

F 可用四元数组来刻画。 (β, t, L, U)

• 它是一个有限集 $2(\beta-1)\beta^{t-1}(U-L+1)+1$

• 对称分布在 $[-M, -m]$ 和 $[m, M]$ (不对称)

$$m = \beta^L \quad M = \left(\beta - 1 + \frac{\beta-1}{\beta} + \dots + \frac{(\beta-1)}{\beta^{t-1}} \right) \times \beta^U$$
$$= (\beta-1) \frac{1-\beta^{-t}}{1-\frac{1}{\beta}} \times \beta^U = \beta^{U+1}(1-\beta^{-t})$$

IEEE 标准: 单精度 (2, 24, -126, 127)

双精度 (2, 53, -1022, 1023) $\rightarrow m \approx 10^{-308} \quad M \approx 10^{308}$

(II) 实数表示成浮点数的相对误差.

记实数 x 的浮点数表示 $f(x)$

若 $x=0$, $f(x)=0$

若 $m \leq |x| \leq M$, $f(x)$ 为浮点中最接近于 x 的数 (舍入法)

若 $|x| > M$, $f(x) = \text{NaN}$ (not-a-number) (上溢)

若 $0 < |x| < m$, $f(x) = 0$ (下溢)

引理: $x_1, x_2 \in \mathbb{F}$ 且相邻. 则 $\beta^{-t} < \frac{|x_1 - x_2|}{|x_1|} \leq \beta^{1-t}$
 $|x_1| < |x_2|$

证明: 不妨设 $0 < x_1 < x_2$.

$$x_1 = d_0.d_1 \dots d_{t-1} \times \beta^J = \left(d_0 + \frac{d_1}{\beta} + \dots + \frac{d_{t-1}}{\beta^{t-1}} \right) \times \beta^J$$
$$1 \leq d_0.d_1 \dots d_{t-1} \leq \beta(1-\beta^{-t}) < \beta^{J+1}$$

若 $\beta^J \leq x_1 < \beta(1-\beta^{-t})\beta^J$, 则

$$x_2 - x_1 = \frac{1}{\beta^{t-1}} \cdot \beta^J$$

若 $x_1 = \beta(1-\beta^{-t})\beta^J$, $x_2 = \beta^{J+1} \Rightarrow x_2 - x_1 = \beta^{-t} \cdot \beta^{J+1} = \beta^{1-t} \cdot \beta^J$.

$$\beta^{-t} < \frac{|x_0 - x_1|}{|x_1|} \leq \beta^{1-t} \quad (3)$$

定义: 机器精度 $u = \frac{1}{2} \times (1 \text{ 与大于 } 1 \text{ 的最小可表示浮点数的距离})$
 $= \frac{1}{2} \beta^{1-t}$


单精度: $2^{-23} \approx 1.1920929 \times 10^{-7}$

双精度: $2^{-52} \approx 2.220446049250313 \times 10^{-16}$

定理: 设 $m \leq |x| \leq M$, 则 $f_l(x) = x(1+\delta)$, $|\delta| < u = \frac{1}{2} \beta^{1-t}$.

证明: $x=0$, $f_l(x)=0$ 显然成立.

不妨设 $x > 0$, 存在 x_L, x_R 使得 $x_L \leq x \leq x_R$



$$\frac{|f_l(x) - x|}{|x|} \leq \frac{|f_l(x) - x|}{|x_L|} \leq \frac{1}{2} \frac{|x_R - x_L|}{|x_L|} \leq \frac{1}{2} \beta^{1-t} \quad (3)$$

(III) 基本运算的舍入误差

。表示 $+$, $-$, $\times$, $/$ 中任意一种运算, 在不发生溢出的情形.

定理: 设 $a, b \in \mathbb{F}$, $f_l(a \circ b) = (a \circ b)(1+\delta)$, $|\delta| \leq u$ (练习)

(IV) 向量点积的舍入误差

引理: 若 $|\delta_i| \leq u$ 且 $nu \leq 0.01$, 则

$$1 - nu \leq \prod_{i=1}^n (1 + \delta_i) \leq 1 + 1.01 nu \text{ 或 } \prod_{i=1}^n (1 + \delta_i) = 1 + \delta, \quad |\delta| \leq 1.01 nu.$$

$$\text{证明: } |\delta_i| \leq u, \quad (1-u)^n \leq \prod_{i=1}^n (1 + \delta_i) \leq (1+u)^n$$

$0 < x < 1$

$$\text{由 Taylor 展开: } (1-x)^n = 1 - nx + \frac{n(n-1)}{2} (1-\theta x)^{n-2} x^2, \quad 0 < \theta < 1.$$

$$\Rightarrow 1 - nx \leq (1-x)^n \Rightarrow 1 - 1.01nu \leq 1 - nu \leq (1-u)^n.$$

$$\text{另证: 利用 } e^x = 1 + x + \frac{x^2}{2!} + \frac{x^3}{3!} + \dots = 1 + x + \frac{1}{2}x \cdot x \left(1 + \frac{x}{3} + \frac{x^2}{4!} + \dots \right) \leq e^x$$

$$\text{当 } 0 \leq x \leq 0.01 \text{ 时 } 1 + x \leq e^x \leq 1 + x + \frac{1}{2} \cdot 0.01 x e^{0.01} \leq 1 + 1.01x$$

$$e^{0.01} < 2$$

$$\Rightarrow (1+u)^n \leq e^{nu} \leq 1 + 1.01nu. \quad (3)$$

给定 $x, y \in \mathbb{R}^n$, 估计 $|f_l(x^T y) - x^T y|$ 的上界.

$$\text{证: 令 } S_k = f_l\left(\sum_{i=1}^k x_i y_i\right)$$

$$\text{由基本运算对应 } \tilde{m} \text{ (定理): } S_1 = x_1 y_1 (1 + r_1) \quad |r_1| \leq u.$$

$$S_k = f_l(S_{k-1} + f_l(x_k y_k))$$

$$= (S_{k-1} + x_k y_k (1 + r_k)) (1 + \delta_k), \quad |r_k|, |\delta_k| \leq u.$$

$$\Rightarrow f_l(x^T y) = S_n = \sum_{i=1}^n x_i y_i (1 + r_i) \prod_{j=i}^n (1 + \delta_j) \quad (\text{练习})$$

$$= \sum_{i=1}^n x_i y_i (1 + \varepsilon_i)$$

$$\text{其中 } 1 + \varepsilon_i = (1 + r_i) \prod_{j=i}^n (1 + \delta_j) \quad \text{定义 } \delta_1 = 0.$$

$$\text{由引理: } |f_l(x^T y) - x^T y| \leq \sum_{i=1}^n |\varepsilon_i| |x_i| |y_i| \leq 1.01nu \sum_{i=1}^n |x_i| |y_i|.$$

(v) 矩阵基本运算的舍入误差.

$$\text{引入记号: } |E| = (|e_{ij}|) \text{ 且 } |E| \leq |F| \Leftrightarrow |e_{ij}| \leq |f_{ij}|, \quad i, j = 1, 2, \dots, n$$

设 $A, B \in \mathbb{R}^{n \times n}$, 且 $\alpha \in \mathbb{R}$.

$$f_l(\alpha A) = \alpha A + E \quad |E| \leq u |\alpha A| \quad f_l(\alpha a_{ij}) = \alpha a_{ij} (1 + \delta) \quad |\delta| < u$$

$$f(A+B) = A+B+E \quad |E| \leq U |A+B| \quad f(a_{ij}+b_{ij}) = (a_{ij}+b_{ij})(1+b)$$

$$f(AB) = AB+E \quad |E| \leq 1.01nU |A||B|$$

向前误差分析: 通过估计计算解与准确解之间的误差得到.

(舍入误差的界与准确解有关).

向后误差分析: 把计算过程产生的误差归结成具有误差的

原始数据的精确计算.

$$\cancel{AB} = f(AB) = AB+E \quad (A+\delta A)(B+\delta B) = f(AB)$$

(VI) 列主元高斯消元法的舍入误差分析

思想: 利用浮点数的基本运算的舍入误差理论对列主元消元法进行向后误差分析.

即证明用列主元消元法求解 $Ax=b$ 时, 它的计算解 $\tilde{x}$ 满足

$$(A+E)\tilde{x}=b \text{ 并给出误差矩阵 } E \text{ 的上界估计.}$$

1. A 的三角分解的舍入误差.

引理: $A \in \mathbb{R}^{n \times n}$ 有三角分解且 $1.01nU \leq 0.01$, 则高斯消元法

得到的单位下三角矩阵 $\tilde{L}$ 和上三角矩阵 $\tilde{U}$ 满足

$$\tilde{L}\tilde{U} = A+E, \text{ 其中 } |E| \leq 2.05nU |\tilde{L}||\tilde{U}|$$

证明: 设 $\tilde{L}=(\tilde{l}_{ij})$, $\tilde{U}=(\tilde{u}_{ij})$

由高斯消元法可知

$$a_{ij}^{(0)} = a_{ij}$$

$$\begin{pmatrix} a_{11}^{(0)} & a_{12}^{(0)} & \cdots & a_{1n}^{(0)} \\ & a_{22}^{(1)} & \cdots & a_{2n}^{(1)} \\ & & \ddots & \\ & & & a_{kk}^{(k-1)} & \cdots & a_{kn}^{(k-1)} \\ & & & & \ddots & \\ & & & & & a_{nn}^{(k-1)} \end{pmatrix}$$

$$a_{ij}^{(k+1)} = fl(a_{ij}^{(k)} - fl(\tilde{l}_{ik} \tilde{u}_{kj})), i, j = k+1, \dots, n.$$

$$\tilde{u}_{ij} = a_{ij}^{(i)} = fl(a_{ij}^{(i)} - fl(\tilde{l}_{i,i} \tilde{u}_{i,i}))$$

由基本运算的舍入误差分析结果可得

$$a_{ij}^{(k+1)} = (a_{ij}^{(k)} - (\tilde{l}_{ik} \tilde{u}_{kj})(1+\gamma_k))(1+\epsilon_k) \quad |\gamma_k|, |\epsilon_k| \leq u$$

由向量点积的分析结果, 可得

$$\tilde{u}_{ij} = a_{ij}^{(i)} = a_{ij}(1+\delta_i) - \sum_{k=1}^{i-1} (\tilde{l}_{ik} \tilde{u}_{kj})(1+\delta_k)$$

$$\text{其中 } |\delta_k| \leq 1.01 nu$$

$$\Rightarrow a_{ij} = \frac{\tilde{u}_{ij}}{1+\delta_i} + \sum_{k=1}^{i-1} (\tilde{l}_{ik} \tilde{u}_{kj}) \frac{1+\delta_k}{1+\delta_i}$$

$$\stackrel{\Delta}{=} \sum_{k=1}^i \tilde{l}_{ik} \tilde{u}_{kj} - e_{ij}$$

$$e_{ij} = (\tilde{l}_{ii} \tilde{u}_{ij}) \frac{\delta_i}{1+\delta_i} + \sum_{k=1}^{i-1} (\tilde{l}_{ik} \tilde{u}_{kj}) \frac{\delta_i - \delta_k}{1+\delta_i}$$

$$\because |\delta_k| \leq 1.01 nu \leq 0.01 \text{ 有}$$

$$|e_{ij}| \leq \frac{2.02 nu}{1-0.01} \sum_{k=1}^i (\tilde{l}_{ik} \tilde{u}_{kj}) \leq 2.05 nu \sum_{k=1}^i (\tilde{l}_{ik} \tilde{u}_{kj}),$$

$$\text{即 } |E| \leq 2.05 nu \|L\| \|\tilde{U}\|. \quad \square$$

推论: 设 $A \in \mathbb{R}^{n \times n}$, 非奇异, 且 $1.01 nu \leq 0.01$, 则用列主元

消元法得到的单位下三角阵 $\tilde{L}$, 上三角阵 $\tilde{U}$ 以及排列

矩阵 $\tilde{P}$ 满足 $\tilde{L} \tilde{U} = \tilde{P} A + E$, 其中 $|E| \leq 2.05 nu \|\tilde{L}\| \|\tilde{U}\|$.

交换矩阵的行或列不引入舍入误差.

2. 求解三角形方程组的舍入误差

定义: $Sx=b$ 为浮点三角形方程组, S 非奇异且 $1.01nU \leq 0.01$.

$Sx=b$ 的计算解满足 $(S+\tilde{H})\tilde{x}=b$ 且 $|\tilde{H}| \leq 1.01nU|S|$.

证明: 数学归纳法

3. 列主元消元法的误差分析

列主元分解: $\tilde{P}A+E=\tilde{L}\tilde{U}$, $|E| \leq 2.05nU|\tilde{L}||\tilde{U}|$

求解三角形方程组: $\tilde{L}y=\tilde{P}b$, $\tilde{U}x=y$

得到的计算解 $\tilde{x}$ 应满足:

$$(\tilde{L}+F)(\tilde{U}+G)\tilde{x}=\tilde{P}b \quad |F| \leq 1.01nU|\tilde{L}|$$

$$|G| \leq 1.01nU|\tilde{U}|$$

即

$$(\tilde{L}\tilde{U} + \tilde{L}G + F\tilde{U} + FG)\tilde{x} = \tilde{P}b$$

代入 $\tilde{P}A+E=\tilde{L}\tilde{U}$ 得 $(A+\delta A)\tilde{x}=b$

$$\delta A = \tilde{P}^T(E + F\tilde{U} + \tilde{L}G + FG)$$

$$\Rightarrow |\delta A| \leq (2.05nU + 1.01nU + 1.01nU + 1.01nU \cdot \overset{0.01}{1.01nU})|\tilde{L}||\tilde{U}|$$

$$\leq 4.09nU|\tilde{L}||\tilde{U}|$$

由于 $\tilde{L}$ 的元素绝对值 ≤ 1 , $\Rightarrow \|\tilde{L}\|_{\infty} \leq n$

定义列主元消元法的增长因子 $\rho = \max_{i,j} |\tilde{u}_{ij}| / \max_{i,j} |a_{ij}|$

$$\Rightarrow \|\tilde{U}\|_{\infty} \leq n \max_{i,j} |\tilde{u}_{ij}| = n \rho \max_{i,j} |a_{ij}| \leq n \rho \|A\|_{\infty}$$

定理: $A \in \mathbb{R}^{n \times n}$, 奇异且 $1.01n\rho \leq 0.01$, 则利用列主元消

元法解 $AX=b$ 得到的计算解 $\tilde{x}$ 满足

$$(A+\delta A)\tilde{x}=b, \text{ 其中 } \|\delta A\|_{\infty} \leq 4.09n^3\rho\|A\|_{\infty}$$