


第四讲 向量范数和矩阵范数

2026年3月25日 星期三

13:25



第二章 敏感度分析和误差分析

§2.1 向量范数和矩阵范数

(一) 向量范数.

(I) 定义：函数 $\|\cdot\|: \mathbb{R}^n \rightarrow \mathbb{R}$ 满足

1° 正定性： $\forall x \in \mathbb{R}^n$ 有 $\|x\| \geq 0$ 而且 $\|x\| = 0$ 当且仅当 $x = 0$

2° 齐次性： $\forall x \in \mathbb{R}^n, \alpha \in \mathbb{R}$ 有 $\|\alpha x\| = |\alpha| \|x\|$

3° 三角不等式： $\forall x, y \in \mathbb{R}^n$ 有 $\|x+y\| \leq \|x\| + \|y\|$

称 $\|\cdot\|$ 为 $\mathbb{R}^n$ 上的向量范数.

最常用的向量范数为 p 范数 (Hölder 范数)

$$x = (x_1, x_2, \dots, x_n)^T, \quad \|x\|_p = (|x_1|^p + |x_2|^p + \dots + |x_n|^p)^{\frac{1}{p}}, \quad p \geq 1.$$

可证明 $\|\cdot\|_p$ 满足范数定义. (练习)

其中更常见的 $p=1, 2$, 分别

$$\|x\|_1 = |x_1| + |x_2| + \dots + |x_n|$$

$$\|x\|_2 = \sqrt{|x_1|^2 + \dots + |x_n|^2} = \sqrt{x^T x}$$

$$\|x\|_{\infty} = \max_{1 \leq i \leq n} |x_i|$$

例: $x = (1, -2, 4)^T \in \mathbb{R}^3$. $\|x\|_1 = 1 + 2 + 4 = 7$
 $\|x\|_2 = \sqrt{1+4+16} = \sqrt{21}$
 $\|x\|_{\infty} = 4$

(II) 性质

1° (连续性) 定理: $\|\cdot\|$ 作为 $\mathbb{R}^n$ 上的向量范数, 是其 n 个分量的连续函数.

证明: $|\|x\| - \|y\|| \stackrel{3^\circ}{\leq} \|x - y\| = \left\| \sum_{i=1}^n (x_i - y_i) e_i \right\|$ 单位阵的某列.

$$\leq \sum_{i=1}^n \|(x_i - y_i) e_i\|$$

$$= \sum_{i=1}^n |x_i - y_i| \|e_i\|$$

$$\leq \max_{1 \leq i \leq n} |x_i - y_i| \left[\sum_{i=1}^n \|e_i\| \right] \stackrel{\triangle N}{\leq}$$

$$\forall \varepsilon > 0, \exists \delta = \frac{\varepsilon}{N} > 0, \text{ 当 } |x_i - y_i| < \delta, \forall i \text{ 时}$$

$$\text{有 } \|\|x - y\|\| \leq \frac{\varepsilon}{N} \cdot N = \varepsilon. \quad \square$$

2° 等价性: $\mathbb{R}^n$ 中任意范数都是等价的. 即

若 $\|\cdot\|_{\alpha}$ 和 $\|\cdot\|_{\beta}$ 为 $\mathbb{R}^n$ 中任意两个范数, 则存在 $m, M > 0$, 使得

$$\forall x \in \mathbb{R}^n \quad m \|x\|_{\alpha} \leq \|x\|_{\beta} \leq M \|x\|_{\alpha}$$

证明: 记 $S = \{x \in \mathbb{R}^n \mid \|x\|_{\alpha} = 1\}$. S 为有界闭集.

设 $\|\cdot\|_{\beta}$ 为 $\mathbb{R}^n$ 任意向量范数, 则 $\|\cdot\|_{\beta}$ 为 S 上连续函数.

例 $\|\cdot\|_\alpha$ 在 S 上可取最大最小值.

$$\text{记 } m = \min_{x \in S} \|x\|_\alpha, \quad M = \max_{x \in S} \|x\|_\alpha$$

$\forall x \in \mathbb{R}^n, \quad \frac{x}{\|x\|_2} \in S$. 则有

$$m \leq \left\| \frac{x}{\|x\|_2} \right\|_\alpha \leq M \left\| \frac{x}{\|x\|_2} \right\|_\alpha.$$

齐次性 $\Rightarrow m \|x\|_2 \leq \|x\|_\alpha \leq M \|x\|_2$

即任意范数都与 $\|\cdot\|_2$ 等价. $\square$

例: $\|x\|_2 \leq \|x\|_1 \leq \sqrt{n} \|x\|_2$

$$\|x\|_\infty \leq \|x\|_2 \leq \sqrt{n} \|x\|_\infty$$

$$\|x\|_\infty \leq \|x\|_1 \leq n \|x\|_\infty$$

3° 收敛性. 记 $x^{(m)} = (x_1^{(m)}, x_2^{(m)}, \dots, x_n^{(m)})^T$

$\{x^{(m)}\}_{m=1}^\infty$ 为 $\mathbb{R}^n$ 上向量序列. 若存在 $x = (x_1, \dots, x_n)^T$, 使得

$$\lim_{m \rightarrow \infty} \|x^{(m)} - x\| = 0. \text{ 称 } x^{(m)} \text{ 收敛于 } x, \text{ 记作 } \lim_{m \rightarrow \infty} x^{(m)} = x$$

定理: $\lim_{m \rightarrow \infty} \|x^{(m)} - x\| = 0 \Leftrightarrow \lim_{m \rightarrow \infty} |x_i^{(m)} - x_i| = 0, \quad i=1, \dots, n.$

证明: 范数等价性 $\Rightarrow$ 极限定义和范数无关. 取 $\|\cdot\|_1$ 作证明.

(二) 矩阵范数

$m \times n$ 矩阵全体 $\mathbb{R}^{m \times n}$ 与 $m \times n$ 维向量空间 $\mathbb{R}^{mn}$ 同构.

$\mathbb{R}^{m \times n}$ 上范数可由向量范数的概念直接推广.

$A \in \mathbb{R}^{m \times n}$: $A: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 线性算子.

相容性: $\|AB\| \leq \|A\| \|B\|$

和算子的相容性一致.

$$\|Ax\| \leq \|A\| \|x\|.$$

不是所有的向量范数都具有相容性.

例: $\|\cdot\|_\Delta = \max_{i,j} |a_{ij}|$ 满足向量范数定义 1°, 2°, 3°

$$A = B = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} \quad \|A\|_\Delta = \|B\|_\Delta = 1$$

$$AB = \begin{pmatrix} 2 & 2 \\ 2 & 2 \end{pmatrix} \quad \|AB\|_\Delta = 2 > \|A\|_\Delta \|B\|_\Delta.$$

(I) 定义: $\|\cdot\|: \mathbb{R}^{m \times n} \rightarrow \mathbb{R}$ 满足: $\forall A \in \mathbb{R}^{m \times n}$.

1° 正定性: $\|A\| \geq 0$, 且 $\|A\| = 0$ 当且仅当 $A = 0$

2° 齐次性: $\forall \alpha \in \mathbb{R}$, 有 $\|\alpha A\| = |\alpha| \|A\|$

3° 三角不等式: $\|A+B\| \leq \|A\| + \|B\|$ ($B \in \mathbb{R}^{m \times n}$)

4° 相容性: $\|AB\| \leq \|A\| \|B\|$ ($B \in \mathbb{R}^{n \times p}$)

矩阵范数又称为相容范数.

(II) 性质 (具有向量范数的一切性质)

1° 连续性: 定理: 矩阵范数是其 $m \times n$ 个元素的连续函数

2° 等价性: 定理: $\mathbb{R}^{m \times n}$ 中任意两个范数都是等价的.

(III) 诱导范数.

$$A \in \mathbb{R}^{n \times n}, \text{ 定义 } \|A\| = \max_{\substack{x \in \mathbb{R}^n \\ x \neq 0}} \frac{\|Ax\|}{\|x\|} = \max_{\|x\|=1} \|Ax\|.$$

(a) $\| \cdot \|$ 为 $\mathbb{R}^{n \times n}$ 上矩阵范数.

$$\begin{aligned} 1^\circ \quad \|A\| \geq 0 \quad \|A\| = 0 &\Leftrightarrow \forall x \in (\mathbb{R}^n, \|x\|=1), \|Ax\|=0 \\ &\Leftrightarrow \forall x \in \mathbb{R}^n, \|x\|=1, Ax=0 \\ &\Leftrightarrow A=0 \end{aligned}$$

$$2^\circ \quad \forall \alpha \in \mathbb{R}$$

$$\|\alpha A\| = \max_{\|x\|=1} \|\alpha Ax\| = |\alpha| \max_{\|x\|=1} \|Ax\| = |\alpha| \|A\|.$$

$$\begin{aligned} 3^\circ \quad \|A+B\| &= \max_{\|x\|=1} \|(A+B)x\| = \max_{\|x\|=1} \|Ax+Bx\| \\ &\leq \max_{\|x\|=1} (\|Ax\| + \|Bx\|) \\ &\leq \max_{\|x\|=1} \|Ax\| + \max_{\|x\|=1} \|Bx\| \\ &= \|A\| + \|B\|. \end{aligned}$$

$$\begin{aligned} 4^\circ \quad \|AB\| &= \max_{\|x\|=1} \|A(Bx)\| = \max_{\|x\|=1} \frac{\|A(Bx)\|}{\|Bx\|} \cdot \|Bx\| \\ &\leq \|A\| \max_{\|x\|=1} \|Bx\| = \|A\| \cdot \|B\|. \end{aligned}$$

注: ① $\|I\| = 1$

② $\| \cdot \|$ 称由向量范数 $\| \cdot \|$ 诱导出的矩阵范数, 后面简记为 $\| \cdot \|$.

⑥ 由向量范数 $\| \cdot \|_p$ 诱导出的矩阵范数 $\| \cdot \|_p$ 定义为

$$\|A\|_p = \max_{\|x\|_p=1} \|Ax\|_p. \quad \text{相应地有 } \|A\|_1, \|A\|_2, \|A\|_\infty.$$

定义: $A = (a_{ij}) \in \mathbb{R}^{n \times n}$, $\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|$ (列和范数)

证明: $\forall x \in \mathbb{R}^n$, $\|x\|_1 = 1$

$$\begin{aligned}\|Ax\|_1 &= \sum_{i=1}^n |(Ax)_i| = \sum_{i=1}^n \left| \sum_{j=1}^n a_{ij} x_j \right| \\ &\leq \sum_{i=1}^n \sum_{j=1}^n |a_{ij}| |x_j| \\ &= \sum_{j=1}^n \left(\sum_{i=1}^n |a_{ij}| \right) |x_j| \\ &\leq \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}| \underbrace{\left(\sum_{j=1}^n |x_j| \right)}_{\|x\|_1 = 1} = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|\end{aligned}$$

$$\text{即 } \|A\|_1 \leq \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|$$

另一方面, 若列和的最大值在第 k 列取到, 即

$$\max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}| = \sum_{i=1}^n |a_{ik}|$$

$$\text{取 } x = e_k, \text{ 则 } \|x\|_1 = \|e_k\|_1 = 1$$

$$\|Ax\|_1 = \|Ae_k\|_1 = \|(a_{1k}, a_{2k}, \dots, a_{nk})^T\|_1 = \sum_{i=1}^n |a_{ik}|$$

$$\text{即 } \|A\|_1 = \max_{\|x\|_1=1} \|Ax\|_1 \geq \|Ae_k\|_1 = \sum_{i=1}^n |a_{ik}| = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|$$

$$\Rightarrow \|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|. \quad \square$$

定义: $\|A\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$ (行和范数)

证明: $\forall x \in \mathbb{R}^n$, $\|x\|_\infty = 1$

$$\begin{aligned}\|Ax\|_\infty &= \max_{1 \leq i \leq n} |(Ax)_i| = \max_{1 \leq i \leq n} \left| \sum_{j=1}^n a_{ij} x_j \right| \\ &\leq \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}| \underline{|x_j|} \quad |x_j| \leq 1 \\ &\leq \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|\end{aligned}$$

$$\text{即 } \|A\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$$

$$\text{令 } j=k: \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}| = \sum_{j=1}^n |a_{kj}|$$

$$\text{sgn}(\alpha) = \begin{cases} 1, & \alpha > 0 \\ -1, & \alpha < 0 \\ 0, & 0 \end{cases}$$

$\alpha \cdot \text{sgn}(\alpha) = |\alpha|$

$$\text{令 } \tilde{x} = (\text{sgn}(a_{k1}), \dots, \text{sgn}(a_{kn}))^T, \quad \|\tilde{x}\|_\infty = 1$$

$$\begin{aligned}\|A\tilde{x}\|_\infty &= \left\| \left(\sum_{j=1}^n a_{1j} \tilde{x}_j, \dots, \underbrace{\sum_{j=1}^n a_{kj} \tilde{x}_j}_{\downarrow \sum_{j=1}^n |a_{kj}|}, \dots, \sum_{j=1}^n a_{nj} \tilde{x}_j \right)^T \right\|_\infty \\ &\leq \sum_{j=1}^n |a_{1j}| \quad \quad \quad \sum_{j=1}^n |a_{kj}| \quad \quad \quad \sum_{j=1}^n |a_{nj}|\end{aligned}$$

$$= \sum_{j=1}^n |a_{kj}| = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$$

$$\text{即 } \|A\|_\infty \geq \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}| \quad \square$$

若 A 有特征值 $\lambda_1, \lambda_2, \dots, \lambda_n$ $\rho(A) = \max_{1 \leq i \leq n} |\lambda_i|$ 为 A 的谱半径.

$$\text{定理: } \|A\|_2 = \sqrt{\rho(A^T A)}$$

证明: $A^T A$ 对称半正定 n 阶, 则存在正交阵 U , 使得

$U^T (A^T A) U$ 为对角阵, U 的列向量为其特征向量.

设 $A^T A$ 的特征值为 $0 \leq \lambda_n \leq \lambda_{n-1} \leq \dots \leq \lambda_1$ $\|x\|_2 = \sqrt{x^T x}$

$v_1, \dots, v_n$ 为对应 单位正交特征向量. $\|v_i\|_2 = 1$.

$\forall x \in \mathbb{R}^n, \|x\|_2 = 1$, 有 $x = \sum_{i=1}^n \alpha_i v_i$

$\downarrow$
 $v_i^T v_i = 1$
 $v_i^T v_j = 0 \quad (i \neq j)$

$$\|x\|_2^2 = \left(\sum_{i=1}^n \alpha_i v_i \right)^T \left(\sum_{j=1}^n \alpha_j v_j \right) = \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j v_i^T v_j = \sum_{i=1}^n \alpha_i^2$$

$$\|AX\|_2^2 = (AX)^T AX = X^T A^T A X$$

$$= \left(\sum_{i=1}^n \alpha_i v_i \right)^T A^T A \left(\sum_{j=1}^n \alpha_j v_j \right) \quad A^T A v_j = \lambda_j v_j$$

$$= \left(\sum_{i=1}^n \alpha_i v_i \right)^T \left(\sum_{j=1}^n \alpha_j \lambda_j v_j \right)$$

$$= \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j \lambda_j v_i^T v_j$$

$$= \sum_{i=1}^n \alpha_i^2 \lambda_i \underbrace{v_i^T v_i}_{=1} \leq \lambda_1 \sum_{i=1}^n \alpha_i^2 = \lambda_1 = \rho(A^T A)$$

即 $\|A\|_2 \leq \sqrt{\rho(A^T A)}$

另一方面. $\|Av_1\|_2^2 = v_1^T A^T A v_1 = v_1^T \lambda_1 v_1 = \lambda_1 v_1^T v_1 = \lambda_1 = \rho(A^T A)$

$$\Rightarrow \|A\|_2 \geq \|Av_1\|_2 = \sqrt{\rho(A^T A)}. \quad \square$$

推论: 若 A 对称. $\|A\|_2 = \rho(A)$

(IV) 矩阵范数和谱半径的关系

1° $\rho(A) \leq \|A\|$

若 $\rho(A) = |\lambda|$, 对应的特征向量为 v .

$\|A\| \geq \frac{\|Av\|}{\|v\|} = |\lambda| = \rho(A)$

2° $\forall \varepsilon > 0$, 存在诱导范数 $\|\cdot\|$. s.t. $\|A\| \leq \rho(A) + \varepsilon$.