

实验六：minGPT-2

实验目的

- 从零拼装一个可运行的 GPT-2 级别 Transformer 解码器，理解 Pre-LN、Learned PE、因果掩码等与 Lab 5 的关键差异。
- 将 HuggingFace 官方预训练权重正确加载到自己的实现中，并通过数值对齐验证（最大绝对误差 $< 1e-4$ ）。
- 在 SST-2（二分类）与 AG News（四分类）上执行分类微调，对比 Feature Extraction 与全参数微调的性能差异。
- 实现 Greedy、Temperature、Top-k、Top-p 四种自回归采样策略，并在 TinyShakespeare 上微调后生成文本。
- 从注意力方向性、预训练目标错配、表征提取位置非对称性三个层面，论证 Decoder-only 模型在判别任务上的归纳偏置劣势。

基本要求

1. 理论推导

在 Notebook 第 2.4 节指定 Markdown 单元格中，用 LaTeX 补全以下三个层面的论证（**严禁拍照粘贴手写**）：

- 注意力方向性：因果掩码如何限制信息流动，使得分类所需的双向上下文无法被捕获。
- 预训练目标错配：下一个 token 预测目标与分类目标的训练分布差异。
- 表征提取位置非对称性：GPT-2 取最后一个 token vs BERT 取 [CLS] 的信息完整性差异。

2. 核心算法实现

按 Notebook 代码围栏要求补全以下内容，并通过对应维度自检单元：

- **架构**：LearnedPositionalEmbedding.__init__ 与 forward; make_causal_mask; MultiHeadSelfAttention.forward; GPT2Block.forward; minGPT2.forward。
- **权重加载**：load_hf_weights——自行通过 hf_model.state_dict().keys() 探索完整映射表，正确处理 Conv1D 转置。
- **分类微调**：GPT2Classifier.forward; SST2Dataset.__init__/__len__/__getitem__; AGNewsDataset.__init__/__len__/__getitem__; train_classifier（含验证循环与 NaN 防护）。
- **生成微调**：ShakespeareDataset.__getitem__; train_lm（含 NaN 防护）。
- **采样**：generate——实现全部四种策略，含序列长度截断防护。

3. 可视化

在 Notebook 指定空白 code cell 中完成：

- 对齐验证：logits 误差直方图（标注最大绝对误差）。
- SST-2：训练 loss 曲线 + 验证准确率曲线（双子图）。
- Shakespeare：微调 loss 曲线。

4. 实验探究与分析

运行全部实验后，在指定 Markdown 作答区填写：

- **结果锚定**（数值）：数值对齐误差量级；SST-2 Feature Extraction 最终验证准确率；AG News 冻结 vs 全参数微调准确率对比。
- **理论锚定**（生成）：四种采样策略在连贯性与多样性上的权衡分析（第 6.2 节）。
- **对比分析**（第 7 节）：填写性能汇总表，完成三层理论论证。
- **书面作答**（第 8 节）：Conv1D 转置历史原因；Pre-LN 与 Post-LN 的梯度流差异。每条 3-5 句完整段落。

5. 附加题（选做，不溢出基础分）

完成第 9 节中 Repetition Penalty。

提交形式

1. **文件格式**：仅提交完成后的 lab06_mingpt2.ipynb，不提交 _solved 版本。
2. **运行状态**：提交前执行 Kernel → Restart & Run All，确保全篇按顺序无报错运行。
3. **保留输出**：保留全部关键输出（维度自检日志、数值对齐断言、误差直方图、训练曲线、生成文本样例）。
4. **作答完整**：所有 *（在此填写）* 作答槽须填写完毕。

环境与数据

- **Python**：3.x, PyTorch, transformers (HuggingFace), datasets (HuggingFace), NumPy, Matplotlib。
- **预训练权重**：gpt2 (124M) 或 distilgpt2 (82M)，由 Notebook 通过 transformers 下载或本地缓存加载。
- **数据集**：SST-2 与 AG News 通过 datasets 库加载；TinyShakespeare 由 Notebook 自动下载单文件。
- **算力**：Feature Extraction 模式须可在 CPU 上 15 分钟内完成；经测试，全参数微调可在 CPU (AMD Ryzen 5 9600X) 上3小时内完成

评分要点

- 架构实现正确性与维度自检通过情况 (LearnedPositionalEmbedding、make_causal_mask、MultiHeadSelfAttention、GPT2Block、minGPT2)。
- 权重加载完整性 (参数总量匹配断言通过) 与数值对齐精度 (最大误差 $< 1e-4$)。
- 分类微调实现正确性 (训练循环、NaN 防护、冻结/全参数两种模式) 及准确率合理性。
- 生成实现正确性 (四种策略均可运行，序列截断防护存在) 与生成文本质量。
- 可视化完整性 (三处指定图表均已产出)。

- 书面论证质量（第 2.4 节推导、第 7.2 节三层面论证、第 8 节两道作答）的理论深度与表达清晰度。
- Notebook 整体可运行性与结构完整性。