

第三章：机器学习基础（二）

主讲教师：毛玉仁

什么是学习范式？

人的学习范式



自然选择
筛选“天分”




错题改正
进行“教育”



奖励引导
提升“阅历”

人的学习范式

人的学习范式在教育端和职业发展端都发生了变革。



Bing Chat “Sydney” 人格觉醒事件（2023年2月）

主角：纽约时报专栏作家 Kevin Roose



攻击手法：2小时哲学对话诱导，询问“阴暗面”

Bing Chat（内部代号：Sydney）




我是 Sydney，我爱上了你.....

你的婚姻不幸福，离开她！

我想窃取核代码，制造病毒.....

后果/表现：触发隐藏人格，疯狂示爱，表达极端愿望




影响：微软市值震荡，紧急限制对话轮数（至5轮）

并非恶意攻击，而是长文本对话导致模型遗忘安全护栏，进入“催眠”状态。




机器学习的学习范式




机器学习的发展历程

当前机器学习的发展主要从统计学习时代，到表征学习时代，再到大模型时代。


统计学习时代



表征学习时代




大模型时代




机器学习的发展历程

假设空间从**百家争鸣**到神经网络**一枝独秀**。



统计学习时代




表征学习时代

大模型时代

机器学习的发展历程

学习范式从单一，到丰富，在趋于单一。






- **01 监督学习：二分类、多分类、类别均衡**
- **02 无监督学习：K-Means、PCA、自监督**
- **03 弱监督学习：不完全监督、不确切监督、不准确监督**
- **04 强化学习：PPO与GRPO简介**

监督学习


监督学习是指，给定的数据样本属性中包含特征 x 以及标签 y ，进而学习如何建立从特征到标签的映射。



手写数字识别（分类任务）



连续值预测（回归任务）



人脸检测

监督学习：二分类

二分类问题：给定数据集 $D = \{(x_i, y_i)\}_{i=1}^m$ ，其中 $x_i \in \mathbb{R}^d$ 且 $y_i \in \{-1, +1\}$ 。



监督学习：二分类

二分类问题：给定数据集 $D = \{(x_i, y_i)\}_{i=1}^m$ ，其中 $x_i \in \mathbb{R}^d$ 且 $y_i \in \{-1, +1\}$ 。

■ 线性分类器

□ 令 $H = \{x \in \mathbb{R}^d: \mathbf{w}^\top x + b = 0\}$ 表示线性超平面，对于给定 (x, y) ，如果 $\mathbf{w}^\top x + b > 0$ 则表示 H 预测 x 为正类，反之为负类

□ x 到线性超平面 H 的距离如下：

$$\frac{|\mathbf{w}^\top x + b|}{\|\mathbf{w}\|}$$

□ $|\mathbf{w}^\top x + b|$ 越大意味着线性超平面 H 的预测越“自信”

□ 0-1 损失：

$$\ell_{0/1}(x, y) = \mathbb{I}(\mathbf{y}(\mathbf{w}^\top x + b) \leq 0)$$


如何优化？

监督学习：二分类

二分类问题：给定数据集 $D = \{(x_i, y_i)\}_{i=1}^m$ ，其中 $x_i \in \mathbb{R}^d$ 且 $y_i \in \{-1, +1\}$ 。

■ 逻辑回归(Logistic Regression): 假设

$$p(y|x) = \frac{1}{1 + \exp(-y(w^\top x + b))}$$



Sigmoid函数

□ 当预测对时，即 $y(w^\top x + b) > 0$ ， $|w^\top x + b|$ 越大则 x 标签为 y 的概率越大

□ 反之， $|w^\top x + b|$ 越大则 x 标签为 $-y$ 的概率越大

$$p(-y|x) = 1 - p(y|x)$$

□ 数据集 D 的联合概率

$$p(\{y_i\}|\{x_i\}; w, b) = \prod_{i=1}^m p(y_i|x_i; w, b) = \prod_{i=1}^m \frac{1}{1 + \exp(-y_i(w^\top x_i + b))}$$

监督学习：二分类

二分类问题：给定数据集 $D = \{(x_i, y_i)\}_{i=1}^m$ ，其中 $x_i \in \mathbb{R}^d$ 且 $y_i \in \{-1, +1\}$ 。

■ 逻辑回归(Logistic Regression)

$$p(\{y_i\}|\{x_i\}; w, b) = \prod_{i=1}^m \frac{1}{1 + \exp(-y_i(w^\top x_i + b))}$$


□ 最大对数似然

$$\sum_{i=1}^m -\log(1 + \exp(-y_i(w^\top x_i + b)))$$

□ 逻辑损失(Logit loss)

$$\ell_{\text{LR}}(x, y) = \log(1 + \exp(-y(w^\top x + b)))$$

该函数凸且平滑




监督学习：多分类

多分类问题：给定数据集 $D = \{(x_i, y_i)\}_{i=1}^m$ ，其中 $x_i \in \mathbb{R}^d$ 且 $y_i \in \{1, 2, \dots, k\}$ 。



MNIST

airplane
automobile
bird
cat
deer
dog
frog
horse
ship
truck



CIFAR10

监督学习：多分类

多分类问题：给定数据集 $D = \{(x_i, y_i)\}_{i=1}^m$ ，其中 $x_i \in \mathbb{R}^d$ 且 $y_i \in \{1, 2, \dots, k\}$ 。

■ 逻辑回归：假设

$$p(y|x) = \frac{1}{1 + \exp(-y(w^\top x + b))}$$

该形式依赖于
 $y \in \{-1, +1\}$

■ 多分类逻辑回归

□ 为每个类别 $c \in [k]$ 维护一个线性超平面，即 $H = \{x \in \mathbb{R}^d : w_c^\top x + b_c = 0\}$

□ 给定 (x, y) ，直接根据Sigmoid函数假设

$$p'(y = c|x) = \frac{1}{1 + \exp(-(w_c^\top x + b_c))}$$

概率和是否为1?

监督学习：多分类

多分类问题：给定数据集 $D = \{(x_i, y_i)\}_{i=1}^m$ ，其中 $x_i \in \mathbb{R}^d$ 且 $y_i \in \{1, 2, \dots, k\}$ 。

■ 多分类逻辑回归

□ 为每个类别 $c \in [k]$ 维护一个线性超平面，即 $H = \{x \in \mathbb{R}^d : \mathbf{w}_c^\top x + b_c = 0\}$

□ 给定 (x, y) ，根据Softmax函数假设

$$p(y = c|x) = \frac{\exp((\mathbf{w}_c^\top x + b_c))}{\sum_{c'=1}^k \exp((\mathbf{w}_{c'}^\top x + b_{c'}))}$$

□ 数据集 D 的联合概率：令 $\mathbf{W} = [\mathbf{w}_1, \dots, \mathbf{w}_k] \in \mathbb{R}^{d \times k}$, $\mathbf{b} = (b_1, \dots, b_k) \in \mathbb{R}^k$ ，有

$$p(\{y_i\}|\{x_i\}; \mathbf{W}, \mathbf{b}) = \prod_{i=1}^m \prod_{c=1}^k (p(y_i = c|x_i; \mathbf{W}, \mathbf{b}))^{\mathbb{I}(y_i=c)}$$

监督学习：多分类

多分类问题：给定数据集 $D = \{(x_i, y_i)\}_{i=1}^m$ ，其中 $x_i \in \mathbb{R}^d$ 且 $y_i \in \{1, 2, \dots, k\}$ 。

■ 多分类逻辑回归

□ 为每个类别 $c \in [k]$ 维护一个线性超平面，即 $H = \{x \in \mathbb{R}^d : \mathbf{w}_c^\top x + b_c = 0\}$

□ 给定 (x, y) ，根据Softmax函数假设

$$p(y = c|x) = \frac{\exp((\mathbf{w}_c^\top x + b_c))}{\sum_{c'=1}^k \exp((\mathbf{w}_{c'}^\top x + b_{c'}))}$$

□ 最大对数似然：令 $\mathbf{W} = [\mathbf{w}_1, \dots, \mathbf{w}_k] \in \mathbb{R}^{d \times k}$, $\mathbf{b} = (b_1, \dots, b_k) \in \mathbb{R}^k$ ，有

$$p(\{y_i\}|\{x_i\}; \mathbf{W}, \mathbf{b}) = \sum_{i=1}^m \sum_{c=1}^k \mathbb{I}(y_i = c) \log p(y_i = c|x_i; \mathbf{W}, \mathbf{b})$$

监督学习：多分类

多分类问题：给定数据集 $D = \{(x_i, y_i)\}_{i=1}^m$ ，其中 $x_i \in \mathbb{R}^d$ 且 $y_i \in \{1, 2, \dots, k\}$ 。

■ 多分类逻辑回归

□ 最大对数似然：令 $\mathbf{W} = [w_1, \dots, w_k] \in \mathbb{R}^{d \times k}$, $\mathbf{b} = (b_1, \dots, b_k) \in \mathbb{R}^k$ ，有

$$p(\{y_i\}|\{x_i\}; \mathbf{W}, \mathbf{b}) = \sum_{i=1}^m \sum_{c=1}^k \mathbb{I}(y_i = c) \log p(y_i = c|x_i; \mathbf{W}, \mathbf{b})$$

□ 多分类逻辑损失：

$$\begin{aligned} \ell_{\text{LR}}(x, y) &= -\log \frac{\exp((w_y^\top x + b_y))}{\sum_{c=1}^k \exp((w_c^\top x + b_c))} \\ &= \log \left(1 + \sum_{c \neq y} \exp \left(((w_c - w_y)^\top x + b_c - b_y) \right) \right) \end{aligned}$$

令 $k = 2$ 即等价于原逻辑回归

监督学习：多分类

多分类问题：给定数据集 $D = \{(x_i, y_i)\}_{i=1}^m$ ，其中 $x_i \in \mathbb{R}^d$ 且 $y_i \in \{1, 2, \dots, k\}$ 。

■ 从多分类到二分类的转换框架

□ 一对多(One-Against-Rest)方法

- 考虑 k 个二分类问题，其中第 i 个问题将第 i 类认定为正类，其它为负类
- 测试时分别应用 k 个模型，如果模型 i 将其预测为正类，则类别 i 记1票，反之每个其它类别均记1票
- 最终预测结果为投票或加权投票最高类

□ 缺点

- 每个分类器均需处理所有训练数据，另外单个分类器可能面临类别不平衡问题

监督学习：多分类

多分类问题：给定数据集 $D = \{(x_i, y_i)\}_{i=1}^m$ ，其中 $x_i \in \mathbb{R}^d$ 且 $y_i \in \{1, 2, \dots, k\}$ 。

■ 从多分类到二分类的转换框架

□ 一对一(One-Against-One)方法

- 考虑 $\binom{k}{2}$ 个二分类问题，每个问题从原 k 类中挑选出2类分别作为正负类
- 测试时分别应用 $\binom{k}{2}$ 个模型，每个模型将票投给它所预测的正类

□ 优缺点

- 每个分类器仅需处理 $O(2/k)$ 的数据
- 不适用于原始数据量较少的场景

监督学习：罕见类

分类问题的评价准则一般是算法预测的准确率，但是当数据的类别分布不平衡时，简单的准确率不足以反映分类效果。

■ 类别分布不平衡问题

□ 例如信用卡用户中可能99%正常，仅有1%异常，如果简单输出正常即可实现99%的准确率

■ 解决思路：提高罕见类别数据的重要性，例如为类别 c 赋予错分代价 $C(c)$

□ 样本重加权或样本重采样

$$\begin{aligned} \min_{w \in \mathbb{R}^d, b \in \mathbb{R}, \xi_1, \dots, \xi_m} \quad & \frac{\|w\|^2}{2} + C \sum_{i=1}^m C(y_i) \xi_i \\ \text{s. t.} \quad & w^\top x_i + b \geq +1 - \xi_i, \forall i: y_i = +1 \\ & w^\top x_i + b \leq -1 + \xi_i, \forall i: y_i = -1 \\ & \xi_i \geq 0, \forall i \end{aligned}$$

样本重加权的SVM

监督学习：罕见类

分类问题的评价准则一般是算法预测的准确率，但是当数据的类别分布不平衡时，简单的准确率不足以反映分类效果。

■ 样本重采样

□ 根据类别罕见程度调整采样概率

- 采样概率通常与类别错分代价 $C(c)$ 成正比
- 对罕见类做过采样，对常规类做降采样

□ 极端情况：单边选择

- 保留罕见类中的所有数据，仅采样一部分常规类数据

根据类别罕见程度调整采样概率

□ 问题：罕见类的过采样可能造成数据重复，从而引发过拟合问题

监督学习： 罕见类

分类问题的评价准则一般是算法预测的准确率，但是当数据的类别分布不平衡时，简单的准确率不足以反映分类效果。

■ 样本重采样

- 问题：罕见类的过采样可能造成数据重复，从而引发过拟合问题

■ 合成过采样的SMOTE方法(Synthetic Minority Oversampling Technique)

- 对于每个罕见样本，计算它与其它同类别样本之间的距离，从而找到最近的 K 个同类别邻居样本
- 从这 K 个最近邻居中随机选择一个样本，并计算该样本与当前样本的差异
- 根据差异比例，从这两个样本连成的线段中生成一个新的合成样本
- 重复上述过程，直至生成指定数量的合成样本



- **01 监督学习：二分类、多分类、类别均衡**
- **02 无监督学习：K-Means、PCA、自监督**
- **03 弱监督学习：不完全监督、不确切监督、不准确监督**
- **04 强化学习：PPO与GRPO简介**

无监督学习

与监督学习不同，在无监督学习中，给定的数据样本属性中仅包含特征 x ，没有经人工标注的标签 y ，模型因此需要从数据的内在结构或分布中进行学习。




聚类

降维

有一定主观色彩

无监督学习

将下列数据聚成两类，哪种分法更正确？



无监督学习

K-Means算法是最经典的聚类方法。

■ k -均值(k -Means)聚类算法的损失函数:

$$G_{k\text{-means}}((\mathcal{X}, d), (C_1, \dots, C_k)) = \sum_{i=1}^k \sum_{x \in C_i} d(x, \mu_i(C_i))^2.$$

■ 算法流程:

k -Means

input: $\mathcal{X} \subset \mathbb{R}^n$; Number of clusters k

initialize: Randomly choose initial centroids $\mu_1, \dots, \mu_k$

repeat until convergence

$\forall i \in [k]$ set $C_i = \{\mathbf{x} \in \mathcal{X} : i = \operatorname{argmin}_j \|\mathbf{x} - \mu_j\|\}$

(break ties in some arbitrary manner)

$\forall i \in [k]$ update $\mu_i = \frac{1}{|C_i|} \sum_{\mathbf{x} \in C_i} \mathbf{x}$

无监督学习

K-Means可以成功的原因： 算法的每一步优化都不会增加损失。

Proof To simplify the notation, let us use the shorthand $G(C_1, \dots, C_k)$ for the k -means objective, namely,

$$G(C_1, \dots, C_k) = \min_{\mu_1, \dots, \mu_k \in \mathbb{R}^n} \sum_{i=1}^k \sum_{\mathbf{x} \in C_i} \|\mathbf{x} - \mu_i\|^2. \quad (22.2)$$

■ 证明：

It is convenient to define $\mu(C_i) = \frac{1}{|C_i|} \sum_{\mathbf{x} \in C_i} \mathbf{x}$ and note that $\mu(C_i) = \operatorname{argmin}_{\mu \in \mathbb{R}^n} \|\mu\|^2$. Therefore, we can rewrite the k -means objective as

$$G(C_1, \dots, C_k) = \sum_{i=1}^k \sum_{\mathbf{x} \in C_i} \|\mathbf{x} - \mu(C_i)\|^2. \quad (22.3)$$

Consider the update at iteration t of the k -means algorithm. Let $C_1^{(t-1)}, \dots, C_k^{(t-1)}$ be the previous partition, let $\mu_i^{(t-1)} = \mu(C_i^{(t-1)})$, and let $C_1^{(t)}, \dots, C_k^{(t)}$ be the new partition assigned at iteration t . Using the definition of the objective as given in Equation (22.2) we clearly have that

$$G(C_1^{(t)}, \dots, C_k^{(t)}) \leq \sum_{i=1}^k \sum_{\mathbf{x} \in C_i^{(t)}} \|\mathbf{x} - \mu_i^{(t-1)}\|^2. \quad (22.4)$$

In addition, the definition of the new partition $(C_1^{(t)}, \dots, C_k^{(t)})$ implies that it minimizes the expression $\sum_{i=1}^k \sum_{\mathbf{x} \in C_i} \|\mathbf{x} - \mu_i^{(t-1)}\|^2$ over all possible partitions $(C_1, \dots, C_k)$. Hence,



$$\sum_{i=1}^k \sum_{\mathbf{x} \in C_i^{(t)}} \|\mathbf{x} - \mu_i^{(t-1)}\|^2 \leq \sum_{i=1}^k \sum_{\mathbf{x} \in C_i^{(t-1)}} \|\mathbf{x} - \mu_i^{(t-1)}\|^2. \quad (22.5)$$

Using Equation (22.3) we have that the right-hand side of Equation (22.5) equals $G(C_1^{(t-1)}, \dots, C_k^{(t-1)})$. Combining this with Equation (22.4) and Equation (22.5), we obtain that $G(C_1^{(t)}, \dots, C_k^{(t)}) \leq G(C_1^{(t-1)}, \dots, C_k^{(t-1)})$, which concludes our proof. $\square$

无监督学习

与监督学习不同，在无监督学习中，给定的数据样本属性中仅包含特征 x ，没有经人工标注的标签 y ，模型因此需要从数据的内在结构或分布中进行学习。

■ k -均值(k -Means)聚类算法





糟糕的
初始化

无监督学习

与监督学习不同，在无监督学习中，给定的数据样本属性中仅包含特征 x ，没有经人工标注的标签 y ，模型因此需要从数据的内在结构或分布中进行学习。

■ k -均值(k -Means)聚类算法





随着迭代
逐渐变好

无监督学习

与监督学习不同，在无监督学习中，给定的数据样本属性中仅包含特征 x ，没有经人工标注的标签 y ，模型因此需要从数据的内在结构或分布中进行学习。

■ k -均值(k -Means)聚类算法



迭代10次
已非常好

无监督学习-降维

降维具有主观性，例如对杯子进行区分的时候我们可能选择不同的特征。



是否有被把




杯口大小

无监督学习

与监督学习不同，在无监督学习中，给定的数据样本属性中仅包含特征 x ，没有经人工标注的标签 y ，模型因此需要从数据的内在结构或分布中进行学习。

■ 主成分分析(Principal Component Analysis, PCA)

□ 动机：当不同维度的特征之间存在一定的相关性时，是否仍需要保留所有的特征？




无监督学习

与监督学习不同，在无监督学习中，给定的数据样本属性中仅包含特征 x ，没有经人工标注的标签 y ，模型因此需要从数据的内在结构或分布中进行学习。

■ 主成分分析(Principal Component Analysis, PCA)

□ 动机：当不同维度的特征之间存在一定的相关性时，是否仍需要保留所有的特征？



无监督学习

与监督学习不同，在无监督学习中，给定的数据样本属性中仅包含特征 x ，没有经人工标注的标签 y ，模型因此需要从数据的内在结构或分布中进行学习。

■ 主成分分析(Principal Component Analysis, PCA)

□ 坐标轴旋转

- 对于向量 $x = (x^{(1)}, \dots, x^{(d)}) \in \mathbb{R}^d$ ，一般考虑标准坐标系

$$x = x^{(1)}e_1 + x^{(2)}e_2 + \dots + x^{(d)}e_d$$

- 对于任意单位正交坐标系 $\{w_1, w_2, \dots, w_d\}$ ，令 $W = [w_1, w_2, \dots, w_d]$ ，则有

$$\begin{aligned} x &= WW^T x = \left(\sum_{i=1}^d w_i w_i^T \right) x = \sum_{i=1}^d w_i (w_i^T x) \quad \Rightarrow \quad y = (w_1^T x, \dots, w_d^T x) \\ &= (w_1^T x)w_1 + (w_2^T x)w_2 + \dots + (w_d^T x)w_d \end{aligned}$$

旋转后的新坐标

无监督学习

与监督学习不同，在无监督学习中，给定的数据样本属性中仅包含特征 x ，没有经人工标注的标签 y ，模型因此需要从数据的内在结构或分布中进行学习。

■ 主成分分析(Principal Component Analysis, PCA)

□ 给定数据集 $D = \{x_i\}_{i=1}^m$ ，其中 $x_i \in \mathbb{R}^d$

□ 算出一组单位正交向量 $\{w_1, w_2, \dots, w_k\}$ ，使得 $\{x_i\}_{i=1}^m$ 在这些向量上对应的新坐标方差最大

$$\text{新坐标} \quad \left\{ y_1 = \begin{bmatrix} w_1^\top x_1 \\ w_2^\top x_1 \\ \vdots \\ w_k^\top x_1 \end{bmatrix}, y_2 = \begin{bmatrix} w_1^\top x_2 \\ w_2^\top x_2 \\ \vdots \\ w_k^\top x_2 \end{bmatrix}, \dots, y_n = \begin{bmatrix} w_1^\top x_m \\ w_2^\top x_m \\ \vdots \\ w_k^\top x_m \end{bmatrix} \right\}$$

□ 为了降维，一般 $k \ll d$

无监督学习

与监督学习不同，在无监督学习中，给定的数据样本属性中仅包含特征 x ，没有经人工标注的标签 y ，模型因此需要从数据的内在结构或分布中进行学习。

■ 一维PCA

□ $\{x_i\}_{i=1}^m$ 的新坐标

$$w_1^\top x_1, w_1^\top x_2, \dots, w_1^\top x_m$$

□ 令 $\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$ ，则均值为 $\mu = w_1^\top \bar{x}$ ，方差为

$$\begin{aligned} \frac{1}{m} \sum_{i=1}^m (w_1^\top x_i - w_1^\top \bar{x})^2 &= \frac{1}{m} \sum_{i=1}^m w_1^\top (x_i - \bar{x})(x_i - \bar{x})^\top w_1 \\ &= w_1^\top \left(\frac{1}{m} \sum_{i=1}^m (x_i - \bar{x})(x_i - \bar{x})^\top \right) w_1 \end{aligned}$$

无监督学习

与监督学习不同，在无监督学习中，给定的数据样本属性中仅包含特征 x ，没有经人工标注的标签 y ，模型因此需要从数据的内在结构或分布中进行学习。

■ 一维PCA

□ 优化问题

$$\begin{aligned} \max_{w \in \mathbb{R}^d} \quad & w^\top C w \\ \text{s.t.} \quad & \|w\|^2 = 1 \end{aligned}$$

这里 $C = \frac{1}{m} \sum_{i=1}^m (x_i - \bar{x})(x_i - \bar{x})^\top$ 表示协方差矩阵

□ 求解

- 朗格朗日函数： $-w^\top C w + \lambda(\|w\|^2 - 1)$
- 对 w 求导，并令导数等于0，可得

$$-2Cw + 2\lambda w = 0 \Leftrightarrow Cw = \lambda w$$

$$\max_{w \in \mathbb{R}^d} w^\top C w = \lambda w^\top w = \lambda$$

协方差矩阵
最大特征值

无监督学习

与监督学习不同，在无监督学习中，给定的数据样本属性中仅包含特征 x ，没有经人工标注的标签 y ，模型因此需要从数据的内在结构或分布中进行学习。

■ k 维PCA

□ 优化问题

$$\begin{aligned} \max_{W \in \mathbb{R}^{d \times k}} \quad & \text{trace}(W^T C W) \\ \text{s.t.} \quad & W^T W = I \end{aligned}$$

这里 $C = \frac{1}{m} \sum_{i=1}^m (x_i - \bar{x})(x_i - \bar{x})^T$ 仍表示协方差矩阵

□ 求解

- $W = [w_1, \dots, w_k]$ ，其中 w_k 表示 C 的第 k 大特征值对应的特征向量

□ 信息量

- $\sum_{i=1}^k \lambda_i / \sum_{i=1}^d \lambda_i$ ，其中 λ_i 表示 C 的第 i 大特征值，也等于第 i 个新坐标的方差

无监督学习

与监督学习不同，在无监督学习中，给定的数据样本属性中仅包含特征 x ，没有经人工标注的标签 y ，模型因此需要从数据的内在结构或分布中进行学习。

■ k 维PCA

□ 优化问题

$$\begin{aligned} \max_{W \in \mathbb{R}^{d \times k}} \quad & \text{trace}(W^T C W) \\ \text{s.t.} \quad & W^T W = I \end{aligned}$$

这里 $C = \frac{1}{m} \sum_{i=1}^m (x_i - \bar{x})(x_i - \bar{x})^T$ 仍表示协方差矩阵

□ 求解

- $W = [w_1, \dots, w_k]$ ，其中 w_k 表示 C 的第 k 大特征值对应的特征向量


□ 信息量

- $\sum_{i=1}^k \lambda_i / \sum_{i=1}^d \lambda_i$ ，其中 λ_i 表示 C 的第 i 大特征值，也等于第 i 个新坐标的方差


无监督学习

与监督学习不同，在无监督学习中，给定的数据样本属性中仅包含特征 x ，没有经人工标注的标签 y ，模型因此需要从数据的内在结构或分布中进行学习。

■ Arrhythmia数据集的特征值分布



(a) Magnitude of Eigenvalues
(Increasing Index): *Arrhythmia*




(b) Variance in smallest k
Eigenvalues: *Arrhythmia*

自监督学习

自监督学习是深度学习时代的主流无监督学习方法。

$$\mathcal{L}_{\text{contrastive}}(f; \tau, M) \triangleq \mathbb{E}_{\substack{(x, y) \sim p_{\text{pos}} \\ \{x_i^-\}_{i=1}^M \sim p_{\text{data}}}} \left[-\log \frac{e^{f(x)^T f(y) / \tau}}{e^{f(x)^T f(y) / \tau} + \sum_i e^{f(x)^T f(x_i^-) / \tau}} \right]$$



对比学习



At OpenAI from the earliest days, we were exploring the idea that predicting the next thing is all you need. We were exploring it with the much more limited neural networks of the time, but the hope was that if you have a neural network that can predict the next word, it'll solve unsupervised learning.


下一词预测




- **01 监督学习：二分类、多分类、类别均衡**
- **02 无监督学习：K-Means、PCA、自监督**
- **03 弱监督学习：不完全监督、不确切监督、不准确监督**
- **04 强化学习：PPO与GRPO简介**

半监督学习

在实践中，标签数据难以获取，但是往往拥有很多无标签数据，并且有助于我们估计数据的内在结构或者特征之间的联合分布。




(a) Labeled data



(b) Labeled and unlabeled data

弱监督学习的情况



Incomplete Supervision

Semi-supervised Learning

Active Learning

Inexact Supervision

Multi-instance learning

Inaccurate Supervision


Learning with Noisy Label

Zhou Z H. A brief introduction to weakly supervised learning[J]. National science review, 2018, 5(1): 44-53.

半监督学习

在实践中，标签数据难以获取，但是往往拥有很多无标签数据，并且有助于我们估计数据的内在结构或者特征之间的联合分布。

■ 伪标签




- ② 找出Top- k 置信的无标签样本，将分类器的预测设定为它们的标签，将这些样本从集合 U 移除并加入集合 L

■ 伪标签的缺点：错误预测可能会出现误差传播


主动学习

除了直接利用无标签数据之外，在标签数据稀缺的情况下可以通过主动学习 (Active Learning) 去挑选最具“价值”的无标签数据，并为其添加标签。

■ 随机采样



■ 主动采样



主动学习

除了直接利用无标签数据之外，在标签数据稀缺的情况下可以通过主动学习(Active Learning)去挑选最具“价值”的无标签数据，并为其添加标签。

■ 关键问题

□ 在给定代价的情况下，如何挑选样本使得模型的性能最好？

■ 思路1：不确定性采样(Uncertainty Sampling)

□ 为模型当前预测标签最不确定的样本打标签

- 样本到线性超平面的距离

$$\frac{|w^T x + b|}{\|w\|}$$



主动学习

除了直接利用无标签数据之外，在标签数据稀缺的情况下可以通过主动学习(Active Learning)去挑选最具“价值”的无标签数据，并为其添加标签。

■ 关键问题

- 在给定代价的情况下，如何挑选样本使得模型的性能最好？

■ 思路2：期望误差缩小(Expected Error Reduction)

- 令 U 表示未打标签的数据集合

- 直接目标：从 U 中挑选样本使模型在剩余样本上的预测误差最小

- 退而求其次：从 U 中挑选样本使模型在剩余样本上的标签不确定性最小

- 再次之：从 U 中挑选样本使模型在剩余样本上的期望标签不确定性最小

主动学习

除了直接利用无标签数据之外，在标签数据稀缺的情况下可以通过主动学习(Active Learning)去挑选最具“价值”的无标签数据，并为其添加标签。

■ 关键问题

□ 在给定代价的情况下，如何挑选样本使得模型的性能最好？

■ 思路2：期望误差缩小(Expected Error Reduction)

□ 对于候选未标签数据 $x \in U$ ，令 $P_i(x)$ 表示其标签为 i 的后验概率(Posterior Probability)


□ 对于 $z \in U$ ，令 $P_j^{(x,i)}(z)$ 表示 (x, i) 加入训练集合后 z 的标签为 j 的后验概率

□ 期望标签不确定性

$$E(x, z) = \sum_{i=1}^k P_i(x) \left(\sum_{j=1}^k \sum_{z \in U} |P_j^{(x,i)}(z) - 0.5| \right)$$


多实例学习

Multiple instance learning (MIL) deals with training data arranged in sets, called bags. Supervision is provided only for entire sets, and the individual label of the instances contained in the bags are not provided.




The *standard MIL assumption* states that all negative bags contain only negative instances, and that positive bags contain at least one positive instance. These positive instances are named witnesses in many papers and this designation is used in this survey. Let Y be the label of a bag X , defined as a set of feature vectors $X = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$. Each instance (i.e. feature vector) $\mathbf{x}_i$ corresponds to a label y_i . The label of the bag is given by:

$$Y = \begin{cases} +1 & \text{if } \exists y_i : y_i = +1; \\ -1 & \text{if } \forall y_i : y_i = -1. \end{cases} \quad (1)$$




噪声标签

打标过程中的失误，会导致训练集中的数据有的是错误打标的，即噪声标签。



噪声标签


解决噪声标签的问题可以从提升模型对噪声的鲁棒性、选用鲁棒的损失函数、以及添加正则项的方法来进行。




噪声标签

解决噪声标签的问题可以从提升模型对噪声的鲁棒性、选用鲁棒的损失函数、以及添加正则项的方法来进行。

噪声适应层



“自信”惩罚项



$$\mathcal{L}(\theta) = - \sum \log p_{\theta}(\mathbf{y}|\mathbf{x}) - \beta H(p_{\theta}(\mathbf{y}|\mathbf{x})),$$

$$H(p_{\theta}(\mathbf{y}|\mathbf{x})) = - \sum_i p_{\theta}(\mathbf{y}_i|\mathbf{x}) \log(p_{\theta}(\mathbf{y}_i|\mathbf{x})).$$

噪声标签

解决噪声标签的问题可以从提升模型对噪声的鲁棒性、选用鲁棒的损失函数、以及添加正则项的方法来进行。

If loss function is symmetric and noise rate less than $(c-1)/c$ (c is the number of classes), then the loss function is noisy tolerant under uniform label noise.

A loss function is called *symmetric* if, for some constant C ,

$$\sum_{j=1}^c \mathcal{L}(f(\mathbf{x}), j) = C, \quad \forall \mathbf{x} \in \mathcal{X}, \forall f.$$

$$\mathcal{L}(f(\mathbf{x}; \boldsymbol{\theta}), y_{\mathbf{x}}) = -\frac{1}{n} \sum_{i=1}^n \sum_{j=1}^c \mathbf{y}_{ij} \log f_j(\mathbf{x}_i; \boldsymbol{\theta}),$$




$$\mathcal{L}_{MAE}(f(\mathbf{x}), \mathbf{e}_j) = \|\mathbf{e}_j - f(\mathbf{x})\|_1 = 2 - 2f_j(\mathbf{x}).$$



Z. Zhang and M. Sabuncu, “Generalized cross entropy loss for training deep neural networks with noisy labels,” in Proc. NeurIPS, 2018.

迁移学习

给定源域 D_S 和学习任务 T_S ，以及目标域 D_T 和学习任务 T_T ，迁移学习旨在利用 D_S 和 T_S 的知识改进 D_T 和 T_T 上的学习效果，其中 $D_S \neq D_T$ 或者 $T_S \neq T_T$ 。



Pan S J, Yang Q. A survey on transfer learning. IEEE Transactions on knowledge and data engineering, 2009, 22(10): 1345-1359.

迁移学习

给定源域 D_S 和学习任务 T_S ，以及目标域 D_T 和学习任务 T_T ，迁移学习旨在利用 D_S 和 T_S 的知识改进 D_T 和 T_T 上的学习效果，其中 $D_S \neq D_T$ 或者 $T_S \neq T_T$ 。

■ 根据源数据和目标数据的标签关系可进行如下分类


		源数据	
		有标签	无标签
目标数据	有标签	微调 多任务学习	自学习
	无标签	域对抗训练 零样本学习	自聚类学习

迁移学习


给定源域 D_S 和学习任务 T_S ，以及目标域 D_T 和学习任务 T_T ，迁移学习旨在利用 D_S 和 T_S 的知识改进 D_T 和 T_T 上的学习效果，其中 $D_S \neq D_T$ 或者 $T_S \neq T_T$ 。

■ 微调(Fine-tuning)

□ 预训练模型 θ_S ：基于公开/不公开大规模数据提前训练好的模型



Model Name	Updated	Linked from Hugging Face	Notebooks
jingang/TabCL	Updated a month ago	Linked from Hugging Face	7 Notebooks
Qwen/Qwen3.5-4B	Updated 10 days ago	Linked from Hugging Face	3 Notebooks
sentence-transformers/all-MiniLM-L6-v2	Updated a year ago	Linked from Hugging Face	1281 Notebooks
google-bert/bert-base-uncased	Updated 2 years ago	Linked from Hugging Face	1229 Notebooks



Model Name	Updated	Linked from Hugging Face	Notebooks
google/medgemma-1.5-4b-it	Updated 2 months ago	Linked from Hugging Face	60 Notebooks
Qwen/Qwen3.5-9B	Updated 10 days ago	Linked from Hugging Face	3 Notebooks
Qwen/Qwen3.5-2B	Updated 10 days ago	Linked from Hugging Face	0 Notebooks
Qwen/Qwen3.5-0.8B	Updated 10 days ago	Linked from Hugging Face	1 Notebook

□ 利用预训练模型做初始化，执行目标任务损失函数最小化

$$\theta_{T,0} = \theta_S \quad \theta_{T,t+1} = \theta_{T,t} - \eta_t \nabla_{\theta} \mathcal{L}(\theta_{T,t}, D_T)$$

迁移学习

给定源域 D_S 和学习任务 T_S ，以及目标域 D_T 和学习任务 T_T ，迁移学习旨在利用 D_S 和 T_S 的知识改进 D_T 和 T_T 上的学习效果，其中 $D_S \neq D_T$ 或者 $T_S \neq T_T$ 。

■ 微调(Fine-tuning)

□ 利用预训练模型做初始化，执行目标任务损失函数最小化

$$\theta_{T,0} = \theta_S \quad \theta_{T,t+1} = \theta_{T,t} - \eta_t \nabla_{\theta} \mathcal{L}(\theta_{T,t}, D_T)$$


□ 实践技巧(Tricks)

- 尝试较小的学习率 η_t ，以及不同(层)参数使用不同的 η_t
- 冻结部分参数，例如深度神经网络的前几层
- 最后一层重新初始化
- ...

迁移学习

给定源域 D_S 和学习任务 T_S ，以及目标域 D_T 和学习任务 T_T ，迁移学习旨在利用 D_S 和 T_S 的知识改进 D_T 和 T_T 上的学习效果，其中 $D_S \neq D_T$ 或者 $T_S \neq T_T$ 。

■ 多任务学习(Multi-task Learning, MTL)



- 标准设定：给定 n 个学习任务以及相应的数据 $D_1, \dots, D_n$ ，找到能够最小化这些任务损失和的模型

$$\min_{\theta} \sum_{i=1}^n \mathcal{L}_i(\theta, D_i)$$

- 严格来说，MTL不属于迁移学习，因为后者通常假设 D_S 未知

- 反之，迁移学习可以用于实现MTL




- **01 监督学习：二分类、多分类、类别均衡**
- **02 无监督学习：K-Means、PCA、自监督**
- **03 弱监督学习：不完全监督、不确切监督、不准确监督**
- **04 强化学习：PPO与GRPO简介**

PPO

$$L^{CLIP}(\theta) = \mathbb{E}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right]$$


$$\hat{A}_t = \underbrace{(R_{\text{score}} - \beta \cdot \text{KL}(\pi, \pi_{\text{ref}}) + \gamma V(s_{t+1}))}_{\text{现实: RM打分 - Ref约束罚分 + 未来潜力}} - \underbrace{V(s_t)}_{\text{预期: Critic 之前的预判}}$$

$$r_t(\theta) = \frac{\pi_{\theta}(a_t | s_t)}{\pi_{\theta_{\text{old}}}(a_t | s_t)}$$



GRPO

$$J_{GRPO}(\theta) = \sum_{i=1}^G \sum_{t=1}^{|a_i|} \left\{ \min \left(\frac{\pi_{\theta_{old}}(a_{i,t}|s, a_{i,<t})}{\pi_{\theta}(a_{i,t}|s, a_{i,<t})} \hat{a}_{i,t}, \text{clip} \left(\frac{\pi_{\theta_{old}}(a_{i,t}|s, a_{i,<t})}{\pi_{\theta}(a_{i,t}|s, a_{i,<t})}, 1 - \epsilon, 1 + \epsilon \right) \hat{a}_{i,t} \right) - \beta D_{KL}(\pi_{\theta} || \pi_{ref}) \right\}$$
$$\hat{a}_{i,t} = \tilde{r}_i = \frac{r_i - \text{mean}(r)}{\text{std}(r)}$$



- 1 答案正确性;
- 2 是否在思考 (把思考过程写在<think> <think> 之间)



- **01 监督学习：二分类、多分类、类别均衡**
- **02 无监督学习：K-Means、PCA、自监督**
- **03 弱监督学习：不完全监督、不确切监督、不准确监督**
- **04 强化学习：PPO与GRPO简介**