

第二章：机器学习基础（一）

主讲教师：毛玉仁

什么是机器学习？

大模型时代的机器学习与
传统机器学习
的区别在哪里？

机器学习在研究什么？

泛化

范式

机器学习是通用的方法论

与数据类型无关，与模型类型无关

至今不存在放之四海皆准的定义

机器学习的一种定义

“A computer program is said to learn from experience **E** with respect to some class of tasks **T** and performance measure **P**, if its performance at tasks in **T**, as measured by **P**, improves with experience **E**.”

— Tom Mitchell, Professor at Carnegie Mellon University

机器学习的价值

“A breakthrough in machine learning would be worth ten Microsofts”

— Bill Gates



- **01 机器学习的基本概念**
- **02 经典泛化理论： 深入理解机器学习的一种 “视角”**
- **03 深度学习泛化： 打破经典泛化理论的美好 “假设”**

学习的目的

在经验知识的指导下，求解未知的问题。



学习的要素

完成学习的主要需要：经验知识、学习载体、常识、学习方法、学习目标。

经验知识



学习载体



常识



跟谁学



学习方法



模拟题少出错



机器学习的要素

机器学习的要素包括：训练数据、假设类、归纳偏置、学习范式、学习算法、学习目标。

训练数据



经验知识

假设类



学习载体

归纳偏置



常识

学习范式



跟谁学

学习算法



学习方法


学习目标



模拟题少出错

机器学习的过程

在某种学习范式下，基于训练数据（经验），利用学习算法，从受归纳偏置限制的假设类中选取可以达到学习目标的假设，该假设可以泛化到未知数据上。



基于学习的语言模型

将学习目标设定为语言模型所需的目标，学习到的假设就可以端到端的生成语言序列的概率。

{我，为，什么，要，选，这，门，课}



脑子是个好东西



0.66666

训练数据

训练数据（Training Data，记为 S ）可用于训练的数据。训练数据的数量和质量都会影响机器学习的性能。对于语言模型，训练数据可选用公开语料数据。

数量

在一定范围内，训练数据的数量显著影响机器学习的性能。



质量

多样性，噪声等因素都会影响机器学习性能。







假设类

假设类（Hypothesis Class，记为H）是指所有可能机器学习模型的集合，其中的元素为假设（Hypothesis）。实践中，通常指定候选模型的参数空间为假设类。当前大语言模型主要选用神经网络作为假设空间。

半空间

$$\{x \mapsto \text{sign}(\langle \theta, x \rangle + \beta) : w \in \mathbb{R}^d, \beta \in \mathbb{R}\}$$

神经网络




脑子是个好东西

归纳偏置

归纳偏置 (Inductive Bias) 限制对某些假设进行选择。对于语言模型而言，常用的归纳偏置是上下文间存在关联。

半空间



SVM: 最大化训练样本到超平面的距离：两类分的尽量开。

神经网络

CNN: 局部感受野; RNN: 时间序列; Transformer: 稀疏注意力。



学习范式

广义的学习范式包括监督学习、无监督学习、强化学习。大语言模型通常采用自监督学习范式（基于自动构建的标签进行的监督学习）。

监督学习

给定样本及其标签完成分类、回归任务



无监督学习

无标签的自组织学习



强化学习

从探索中学习




学习目标

不同机器学习范式具有不同的学习目标。经验风险最小化(Empirical Risk Minimization)是最为常见的学习目标之一，其旨在最小化模型在训练集上的错误。


经验风险最小化

例如不带正则项的监督学习方法



相对距离最小化

例如无监督学习方法K-Means



100




损失函数

损失函数（Loss Function）用以衡量模型在对应样本上的错误程度。大多数损失函数是错误程度的代理损失（Surrogate Loss）。损失函数在训练集上的结果的加权和称为训练损失（Training Loss）。

交叉熵损失与0-1损失

$$L(h) = \frac{1}{n} \sum_{i=1}^n I(\text{sign}(h(x_i)) \neq y_i)$$

$$L(h) = \frac{1}{n} \sum_{i=1}^n [y_i \log(p(h(x_i))) + (1 - y_i) \log(p(h(x_i)))]$$




损失函数

损失函数（Loss Function）用以衡量模型在对应样本上的错误程度。大多数损失函数是错误程度的代理损失（Surrogate Loss）。损失函数在训练集上的结果的加权和称为训练损失（Training Loss）。

交叉熵损失与0-1损失

$$L(h) = \frac{1}{n} \sum_{i=1}^n I(\text{sign}(h(x_i)) \neq y_i)$$

$$L(h) = \frac{1}{n} \sum_{i=1}^n [y_i \log(p(h(x_i))) + (1 - y_i) \log(p(h(x_i)))]$$




学习算法

学习算法旨在对损失进行优化。其背后的理论基础为最优化理论。

1 阶优化


$$h_{t+1} = h_t - \eta \nabla_h L(h)$$



0 阶优化

$$h_{t+1} = h_t - \eta \hat{\nabla}_h L(h)$$

$$\hat{\nabla}_h L(h) = \mathbb{E}_{d \in s(d)} \left[\frac{L(h + \alpha d) - L(h)}{\alpha} d \right]$$



泛化误差

机器学习的目的在于减小泛化误差(Generalization Error), 即真实误差(Ture Error).

泛化误差与训练误差

$$L_S(h) \stackrel{\text{def}}{=} \frac{|\{i \in [m] : h(x_i) \neq y_i\}|}{m},$$

$$L_{\mathcal{D}}(h) \stackrel{\text{def}}{=} \mathbb{P}_{(x,y) \sim \mathcal{D}}[h(x) \neq y] \stackrel{\text{def}}{=} \mathcal{D}(\{(x,y) : h(x) \neq y\}).$$



泛化误差界

With probability of at least $1 - \delta$, for all $h \in \mathcal{H}$,

$$L_{\mathcal{D}}(h) - L_S(h) \leq 2 R(\ell \circ \mathcal{H} \circ S) + 4c \sqrt{\frac{2 \ln(4/\delta)}{m}}.$$

估计与检验泛化误差

在实践中，常用验证集来估计泛化误差，然后用测试集来检验泛化误差。

训练集

用于训练模型



验证集

与训练集独立同分布

用于进行超参选择，模型选择等

杭州一模		
日期	考试科目	考试时间
杭州一模11月联考		
	历史	8:00—9:30
	地理	10:00—11:30
	生物	12:00—13:00
	全科试卷+答案解析	14:00—17:00

判断模型
泛化能力

测试集

与训练集和验证集独立同分布

用于对模型进行性能评测，在实际中即是真实场景




测试模型
最终表现


机器学习的发展历程

当前机器学习的发展主要从统计学习时代，到表征学习时代，再到大模型时代。


统计学习时代



表征学习时代




大模型时代




机器学习的发展历程

假设空间从**百家争鸣**到神经网络**一枝独秀**。



统计学习时代




表征学习时代

大模型时代

机器学习的发展历程

学习范式从单一，到丰富，在趋于单一。





- **01 机器学习的基本概念**
- **02 经典泛化理论： 深入理解机器学习的一种 “视角”**
- **03 深度学习泛化： 打破经典泛化理论的美好 “假设”**

可学习性

PAC理论(Probably Approximately Correct, 概率近似正确)给出了一个抽象地刻画机器学习能力的框架。

■ 数据与分布

- 依旧给定数据集 $D = \{(x_i, y_i)\}_{i=1}^m$, 其中 $x_i \in \mathcal{X}$ 且默认 $y_i \in \mathcal{Y} = \{-1, +1\}$, 即考虑二分类问题
- 独立同分布假设: $\mathcal{X}$ 服从一个隐含未知的分布 $\mathcal{D}$, 集合 D 中的所有样本都是独立地从 $\mathcal{D}$ 采样得到, 可记作 $D \sim \mathcal{D}^m$

■ 泛化误差

- 令 h 为从 $\mathcal{X}$ 到 $\mathcal{Y}$ 的一个映射, 其泛化误差为

$$E(h) = E(h; \mathcal{D}) = P_{x \sim \mathcal{D}}(h(x) \neq y) = \mathbb{E}_{x \sim \mathcal{D}}[\mathbb{I}(h(x) \neq y)]$$

这里 $\mathbb{I}(\cdot)$ 表示指示函数

学习的终极目标是最小化泛化误差

可学习性

PAC理论(Probably Approximately Correct, 概率近似正确)给出了一个抽象地刻画机器学习能力的框架。

■ 经验误差

□ 映射 h 在数据集 D 上的误差

$$\hat{E}(h) = \hat{E}(h; D) = \frac{1}{m} \sum_{i=1}^m \mathbb{I}(h(x_i) \neq y_i)$$

□ 由于 $D \sim \mathcal{D}^m$, 不难验证

$$\mathbb{E}_D [\hat{E}(h)] = E(h)$$

即对于给定映射 h , 其经验误差的期望等于其泛化误差

□ 一致性: 若 h 满足 $\hat{E}(h) = 0$, 则称其与 D 一致, 反之则不一致

可学习性

PAC理论(Probably Approximately Correct, 概率近似正确)给出了一个抽象地刻画机器学习能力的框架。

■ 概念(Concept)

- 概念是从特征空间 $\mathcal{X}$ 到标记空间 $\mathcal{Y}$ 的映射，它决定了 x 的真实标记 y ，一般将概念记为 c
- 目标概念：若对于任何数据点 (x, y) ，都有 $c(x) = y$ 成立，则称 c 为目标概念，这正是算法所想要学习的
- 概念类：一些概念所构成的集合称为概念类(Concept Class)，一般记为 $\mathcal{C}$



三角形概念：将任意“三角形”映射为1，其它图形映射为0

可学习性

PAC理论(Probably Approximately Correct, 概率近似正确)给出了一个抽象地刻画机器学习能力的框架。

■ 假设空间(Hypothesis Space)

- 给定学习算法 $\mathcal{L}$, 它所考虑的所有可能的概念构成的集合被称为假设空间, 用符号 $\mathcal{H}$ 表示, 例如线性回归所考虑的 $\mathcal{H} = \{h(x) = w^\top x\}$

■ 假设(Hypothesis)

- 对于 $h \in \mathcal{H}$, 由于并不能确定它是否是目标概念, 因此称为假设

■ 可分性

- 若目标概念 $c \in \mathcal{H}$, 则 $\mathcal{H}$ 中存在假设能将数据正确地完全分开, 称以 c 为目标的这个学习问题对假设空间 $\mathcal{H}$ 是可分的
- 反之, 若目标概念 $c \notin \mathcal{H}$, 则表示不可分

可学习性

PAC理论(Probably Approximately Correct, 概率近似正确)给出了一个抽象地刻画机器学习能力的框架。

■ 学习目标

- 对于给定数据集 D , 希望基于学习算法 $\mathcal{L}$ 学得假设 h 尽可能接近目标概念 c

■ 现实挑战

- 数据集 D 往往仅包含有限数量的样本, 因此存在一些在 D 上等效的假设, 学习算法 $\mathcal{L}$ 无法区分
- 从分布 $\mathcal{D}$ 到数据集 D 的采样具备随机性, 相同大小的不同数据集 D 也会使学习算法 $\mathcal{L}$ 输出不同的假设

■ PAC的基本思想

- 希望以较大的概率学得(泛化)误差满足预设上限的模型

可学习性

PAC理论(Probably Approximately Correct, 概率近似正确)给出了一个抽象地刻画机器学习能力的框架。

■ PAC辨识(Identify)

- 给定误差参数 ϵ 和置信参数 δ 。对于所有 $c \in \mathcal{C}$ 以及分布 $\mathcal{D}$ ，若存在学习算法 $\mathcal{L}$ ，其输出的假设 $h \in \mathcal{H}$ 满足

$$P(E(h) \leq \epsilon) \geq 1 - \delta$$

则称学习算法 $\mathcal{L}$ 能从假设空间 $\mathcal{H}$ 中辨识概念类 $\mathcal{C}$

- 注意，对于目标概念有 $E(c) = 0$ ，因此

$$P(E(h) - E(c) \leq \epsilon) = P(E(h) \leq \epsilon) \geq 1 - \delta$$

即学习算法 $\mathcal{L}$ 以大概率学得目标概念的近似

可学习性

PAC理论(Probably Approximately Correct, 概率近似正确)给出了一个抽象地刻画机器学习能力的框架。

■ PAC可学习(Learnable)

- 令 m 表示从分布 $\mathcal{D}$ 中独立同分布采样得到的数据个数, 对于所有分布 $\mathcal{D}$, 若存在学习算法 $\mathcal{L}$ 和多项式函数 $poly(\cdot, \cdot, \cdot, \cdot)$, 使得对于任何

$$m \geq poly(1/\epsilon, 1/\delta, size(x), size(c))$$

$\mathcal{L}$ 能从假设空间 $\mathcal{H}$ 中辨识概念类 $\mathcal{C}$, 则称概念类 $\mathcal{C}$ 对假设空间 $\mathcal{H}$ 而言是PAC可学习的

- 简称概念类 $\mathcal{C}$ 是PAC可学习的
- 样本复杂度: 满足上述条件的最小 m

进一步考虑了
训练数据量

可学习性

PAC理论(Probably Approximately Correct, 概率近似正确)给出了一个抽象地刻画机器学习能力的框架。

■ PAC学习算法

- 若学习算法 $\mathcal{L}$ 使概念类 $\mathcal{C}$ 为PAC可学习的, 且 $\mathcal{L}$ 的运行时间也是多项式函数 $poly(1/\epsilon, 1/\delta, size(x), size(c))$

则称概念类 $\mathcal{C}$ 是高效PAC可学习的, 并且称 $\mathcal{L}$ 为概念类 $\mathcal{C}$ 的PAC学习算法

- 若假设学习算法 $\mathcal{L}$ 处理每个样本的时间为常数, 则其时间复杂度等价于样本复杂度

■ 基于PAC框架的若干问题

- 学习任务在什么样的条件下可学得较好的模型? 学习任务需多少训练样本才能获得较好的模型? 算法在什么样的条件下可进行有效的学习? ...

可学习性

PAC理论(Probably Approximately Correct, 概率近似正确)给出了一个抽象地刻画机器学习能力的框架。

■ 不可分情形

□ 目标概念 $c \neq \mathcal{H}$ 意味着学习算法 $\mathcal{L}$ 无法学到它的 ϵ 近似(考虑 ϵ 尽可能小)

■ 不可知PAC可学习

□ 对于所有分布 $\mathcal{D}$, 若存在学习算法 $\mathcal{L}$ 和多项式函数 $poly(\cdot, \cdot, \cdot, \cdot)$, 使得对于任何

$$m \geq poly(1/\epsilon, 1/\delta, size(x), size(c))$$


$\mathcal{L}$ 能从假设空间 $\mathcal{H}$ 中输出满足下式的假设 h :

$$P \left(E(h) - \min_{h' \in \mathcal{H}} E(h') \leq \epsilon \right) \geq 1 - \delta$$

则称假设空间 $\mathcal{H}$ 是不可知PAC可学习的

可学习性案例

考虑轴平行矩形(Axis-Parallel Rectangle), 即平面 $\mathbb{R}^2$ 上四条边均与坐标轴平行的矩形区域。 $\mathbb{R}^2$ 中每个点对应一个数据样本, 即 $\mathcal{X} = \mathbb{R}^2$ 。目标概念 c 是某个特定的轴平行矩形, 对于该矩形中的点 x 有 $c(x) = 1$, 矩形外的点有 $c(x) = -1$ 。概念类为平面 $\mathbb{R}^2$ 上所有轴平行矩形的集合。




红实线表示目标概念, 黑虚线表示假设

可学习性案例

考虑轴平行矩形(Axis-Parallel Rectangle), 即平面 $\mathbb{R}^2$ 上四条边均与坐标轴平行的矩形区域。 $\mathbb{R}^2$ 中每个点对应一个数据样本, 即 $\mathcal{X} = \mathbb{R}^2$ 。目标概念 c 是某个特定的轴平行矩形, 对于该矩形中的点 x 有 $c(x) = 1$, 矩形外的点有 $c(x) = -1$ 。概念类为平面 $\mathbb{R}^2$ 上所有轴平行矩形的集合。

■ 一个简单的学习算法 $\mathcal{L}$

□ 对于训练集 D , $\mathcal{L}$ 输出一个包含了 D 中所有正例的最小轴平行矩阵 R^D



□ 显然, R^D 中的点一定包含在目标概念 R , 不会将 R 之外的点判为1



可学习性案例

考虑轴平行矩形(Axis-Parallel Rectangle), 即平面 $\mathbb{R}^2$ 上四条边均与坐标轴平行的矩形区域。 $\mathbb{R}^2$ 中每个点对应一个数据样本, 即 $\mathcal{X} = \mathbb{R}^2$ 。目标概念 c 是某个特定的轴平行矩形, 对于该矩形中的点 x 有 $c(x) = 1$, 矩形外的点有 $c(x) = -1$ 。概念类为平面 $\mathbb{R}^2$ 上所有轴平行矩形的集合。

■ 一个简单的学习算法 $\mathcal{L}$

□ 令 $P(R)$ 表示按照分布 $\mathcal{D}$ 采样的点落在 R 区域的概率, 并假设 $P(R) > \epsilon$

□ 沿 R 的四条边定义4个轴平行矩形, 并保证每个区域的概率质量均为 $\epsilon/4$



$$P(r_1 \cup r_2 \cup r_3 \cup r_4) \leq \epsilon$$

可学习性案例


考虑轴平行矩形(Axis-Parallel Rectangle), 即平面 $\mathbb{R}^2$ 上四条边均与坐标轴平行的矩形区域。 $\mathbb{R}^2$ 中每个点对应一个数据样本, 即 $\mathcal{X} = \mathbb{R}^2$ 。目标概念 c 是某个特定的轴平行矩形, 对于该矩形中的点 x 有 $c(x) = 1$, 矩形外的点有 $c(x) = -1$ 。概念类为平面 $\mathbb{R}^2$ 上所有轴平行矩形的集合。

■ 一个简单的学习算法 $\mathcal{Q}$

□ 若 R^D 与 r_1, r_2, r_3, r_4 都相交, 那么

$$E(R^D) = P(R - R^D) \leq P(r_1 \cup r_2 \cup r_3 \cup r_4) = \epsilon$$

□ 反之, 若 $E(R^D) > \epsilon$, 则 R^D 至少与某个 r_i 不相交



$$\begin{aligned} P_{D \sim \mathcal{D}^m}(E(R^D) > \epsilon) &\leq P_{D \sim \mathcal{D}^m}(\cup_{i=1}^4 \{R^D \cap r_i = \emptyset\}) \\ &\leq \sum_{i=1}^4 P_{D \sim \mathcal{D}^m}(\{R^D \cap r_i = \emptyset\}) \leq 4 \left(1 - \frac{\epsilon}{4}\right)^m \leq 4e^{-m\epsilon/4} \end{aligned}$$

去交叠 最差情况 指数不等式

可学习性案例

考虑轴平行矩形(Axis-Parallel Rectangle), 即平面 $\mathbb{R}^2$ 上四条边均与坐标轴平行的矩形区域。 $\mathbb{R}^2$ 中每个点对应一个数据样本, 即 $\mathcal{X} = \mathbb{R}^2$ 。目标概念 c 是某个特定的轴平行矩形, 对于该矩形中的点 x 有 $c(x) = 1$, 矩形外的点有 $c(x) = -1$ 。概念类为平面 $\mathbb{R}^2$ 上所有轴平行矩形的集合。

■ 一个简单的学习算法 $\mathcal{Q}$

□ 若 R^D 与 r_1, r_2, r_3, r_4 都相交, 那么


$$E(R^D) = P(R - R^D) \leq P(r_1 \cup r_2 \cup r_3 \cup r_4) = \epsilon$$

□ 反之, 若 $E(R^D) > \epsilon$, 则 R^D 至少与某个 r_i 不相交

$$P_{D \sim \mathcal{D}}^m(E(R^D) \leq \epsilon) = 1 - P_{D \sim \mathcal{D}}^m(E(R^D) > \epsilon) \geq 1 - 4e^{-m\epsilon/4}$$



$$m \geq \frac{4}{\epsilon} \ln \frac{4}{\delta} \Rightarrow P_{D \sim \mathcal{D}}^m(E(R^D) \leq \epsilon) \geq 1 - \delta$$



复杂度

根据PAC学习理论，假设空间 $\mathcal{H}$ 越复杂，找到目标概念的难度就越大。一个自然的问题是如何刻画假设空间的复杂度。

■ 有限假设空间

- 所包含的假设数目 $|\mathcal{H}|$

■ 无限假设空间

- **VC维**：由提出者Vapnik & Chervonenkis的缩写命名，具备**计算简单**的优点，但未考虑具体学习问题的数据特点，复杂度刻画相对粗糙
- **Rademacher复杂度**：结合了具体学习问题的数据特点，因此复杂度刻画更加准确，但也更加难以计算

复杂度：VC维

根据PAC学习理论，假设空间 $\mathcal{H}$ 越复杂，找到目标概念的难度就越大。一个自然的问题是如何刻画假设空间的复杂度。

■ VC维的定义（考虑二分类问题对应的假设空间 $\mathcal{H}$ ）

□ 限制(Restriction): $\mathcal{H}$ 在数据集 D 上的限制是指从 D 到 $\{-1, +1\}^m$ 的一族映射

$$\mathcal{H}|_D = \{(h(x_1), h(x_2), \dots, h(x_m)) | h \in \mathcal{H}\}$$

其中向量 $(h(x_1), h(x_2), \dots, h(x_m))$ 表示假设 h 在 D 上的限制

□ 不同的 $h \in \mathcal{H}$ 对于 D 中数据赋予的标记结果可能相同，也可能不同

□ 尽管 $\mathcal{H}$ 可能是无限空间，但 $\mathcal{H}|_D$ 是有限的，例如对于二分类问题， m 个数据上最多只有 2^m 种不同的标记结果

复杂度：VC维

根据PAC学习理论，假设空间 $\mathcal{H}$ 越复杂，找到目标概念的难度就越大。一个自然的问题是如何刻画假设空间的复杂度。

■ VC维的定义（考虑二分类问题对应的假设空间 $\mathcal{H}$ ）

□ 限制(Restriction): $\mathcal{H}$ 在数据集 D 上的限制是指从 D 到 $\{-1, +1\}^m$ 的一族映射

$$\mathcal{H}|_D = \{(h(x_1), h(x_2), \dots, h(x_m)) | h \in \mathcal{H}\}$$

其中向量 $(h(x_1), h(x_2), \dots, h(x_m))$ 表示假设 h 在 D 上的限制

□ 增长函数: 给定 m ，假设空间 $\mathcal{H}$ 的增长函数定义如下

$$\Pi_{\mathcal{H}}(m) = \max_{|D|=m} |\mathcal{H}|_D|$$

表示假设空间对 m 个数据所能赋予标记的最大可能结果数

复杂度：VC维

根据PAC学习理论，假设空间 $\mathcal{H}$ 越复杂，找到目标概念的难度就越大。一个自然的问题是如何刻画假设空间的复杂度。

■ VC维的定义（考虑二分类问题对应的假设空间 $\mathcal{H}$ ）

□ 打散：如果 $\mathcal{H}$ 能够实现数据集 D 上所有可能的标记结果，即

$$|\mathcal{H}|_D = 2^m$$

则称数据集 D 能被假设空间 $\mathcal{H}$ 打散，显然此时增长函数满足

$$\Pi_{\mathcal{H}}(m) = \max_{|D|=m} |\mathcal{H}|_D = 2^m$$

□ VC维：假设空间 $\mathcal{H}$ 的VC维是能被 $\mathcal{H}$ 打散的最大样本集的大小，即

$$\text{VC}(\mathcal{H}) = \max\{m: \Pi_{\mathcal{H}}(m) = 2^m\}$$

复杂度：VC维

根据PAC学习理论，假设空间 $\mathcal{H}$ 越复杂，找到目标概念的难度就越大。一个自然的问题是如何刻画假设空间的复杂度。

■ VC维的定义（考虑二分类问题对应的假设空间 $\mathcal{H}$ ）

□ VC维：假设空间 $\mathcal{H}$ 的VC维是能被 $\mathcal{H}$ 打散的最大样本集的大小，即

$$VC(\mathcal{H}) = \max\{m: \Pi_{\mathcal{H}}(m) = 2^m\}$$

□ VC维的定义与数据分布无关

□ $VC(\mathcal{H}) = k$ 等价于存在大小为 k 的样本集能被 $\mathcal{H}$ 打散，并且任意大小为 $k + 1$ 的样本集都不能被 $\mathcal{H}$ 打散

□ VC维也可用于衡量有限假设空间，且更具优势

$$VC(\mathcal{H}) \leq \log_2 |\mathcal{H}|$$

如何证明？

复杂度：VC维

根据PAC学习理论，假设空间 $\mathcal{H}$ 越复杂，找到目标概念的难度就越大。一个自然的问题是如何刻画假设空间的复杂度。

■ 线性分类器的VC维

□ 对于二分类问题，线性超平面假设空间可以表示为

$$\{h(x) = \text{sign}(w^\top x + b)\}$$

□ 当 $b = 0$ 时为齐次线性超平面，其VC维为 d

对于 $\mathbb{R}^d$ 空间中的 d 个单位向量组成的数据集 $D = \{e_1, e_2, \dots, e_d\}$ ，考虑任意想要实现的标记结果 $y_1, y_2, \dots, y_d$ ，取 $w_y = (y_1, y_2, \dots, y_d)$ 即能保证

$$w_y^\top e_i = y_i$$

因此，该 D 能被齐次线性超平面构成的假设空间打散

复杂度：VC维

根据PAC学习理论，假设空间 $\mathcal{H}$ 越复杂，找到目标概念的难度就越大。一个自然的问题是如何刻画假设空间的复杂度。

■ 线性分类器的VC维

□ 对于二分类问题，线性超平面假设空间可以表示为
$$\{h(x) = \text{sign}(w^\top x + b)\}$$

□ 当 $b = 0$ 时为齐次线性超平面，其VC维为 d

对于 $\mathbb{R}^d$ 空间中的任意 $d + 1$ 个向量组成的数据集 $D' = \{x_1, x_2, \dots, x_d, x_{d+1}\}$ ，必存在不全为0的实数 $a_1, \dots, a_{d+1}$ 使得 $\sum_{i=1}^{d+1} a_i x_i = 0$ 。令 $I = \{i: a_i > 0\}, J = \{i: a_j < 0\}$ ，则有

$$\sum_{i \in I} a_i x_i = \sum_{j \in J} |a_j| x_j$$

复杂度：VC维

根据PAC学习理论，假设空间 $\mathcal{H}$ 越复杂，找到目标概念的难度就越大。一个自然的问题是如何刻画假设空间的复杂度。

■ 线性分类器的VC维

□ 对于二分类问题，线性超平面假设空间可以表示为
$$\{h(x) = \text{sign}(w^\top x + b)\}$$

□ 当 $b = 0$ 时为齐次线性超平面，其VC维为 d

假设 D' 能被 $\mathcal{H}$ 打散，则存在 w 使得 $w^\top x_i > 0, \forall i \in I$ 且 $w^\top x_j < 0, \forall j \in J$ 。由此可得

$$0 < \sum_{i \in I} a_i x_i^\top w = \left(\sum_{i \in I} a_i x_i \right)^\top w = \left(\sum_{i \in I} a_i x_i + \sum_{j \in J} |a_j| x_j \right)^\top w < 0$$

因此假设不成立


一般线性超平面VC维为 $d+1$

复杂度：VC维

根据PAC学习理论，假设空间 $\mathcal{H}$ 越复杂，找到目标概念的难度就越大。一个自然的问题是如何刻画假设空间的复杂度。

■ 神经网络的VC维

□ 记 N 为网络的参数量，其VC维上界为 $O(N \log N)$



复杂度：Rademacher

根据PAC学习理论，假设空间 $\mathcal{H}$ 越复杂，找到目标概念的难度就越大。一个自然的问题是如何刻画假设空间的复杂度。

■ 经验误差

□ 给定二分类数据集 $D = \{(x_i, y_i)\}_{i=1}^m$ ，假设 h 的经验误差为

$$\begin{aligned}\hat{E}(h) &= \frac{1}{m} \sum_{i=1}^m \mathbb{I}(h(x_i) \neq y_i) \\ &= \frac{1}{m} \sum_{i=1}^m \frac{1 - y_i h(x_i)}{2} \\ &= \frac{1}{2} - \frac{1}{2m} \sum_{i=1}^m y_i h(x_i)\end{aligned}$$

□ $\frac{1}{m} \sum_{i=1}^m y_i h(x_i)$ 体现了预测值 $h(x_i)$ 和真实标签 y_i 之间的一致性，最大取值为1

复杂度：Rademacher

根据PAC学习理论，假设空间 $\mathcal{H}$ 越复杂，找到目标概念的难度就越大。一个自然的问题是如何刻画假设空间的复杂度。

■ 经验误差

□ 最小化经验误差，等价于

$$\operatorname{argmax}_{h \in \mathcal{H}} \frac{1}{m} \sum_{i=1}^m y_i h(x_i)$$

■ 考虑到现实标签可能会收到随机噪声影响

□ 引入Rademacher随机变量 σ_i ，它以各0.5的概率取值-1或+1

□ 在上述目标中的真实标签替换为噪声，并计算期望

$$\mathbb{E}_{\sigma} \left[\sup_{h \in \mathcal{H}} \frac{1}{m} \sum_{i=1}^m \sigma_i h(x_i) \right]$$

复杂度：Rademacher

根据PAC学习理论，假设空间 $\mathcal{H}$ 越复杂，找到目标概念的难度就越大。一个自然的问题是如何刻画假设空间的复杂度。

■ 考虑到现实标签可能会收到随机噪声影响

□ 与增长函数类似，该期望值能体现假设空间在数据集 D 上的表示能力

□ 假设该期望值等于1，可知对于任意的 $\sigma = (\sigma_1, \dots, \sigma_m)$ ，都有

$$\sup_{h \in \mathcal{H}} \frac{1}{m} \sum_{i=1}^m \sigma_i h(x_i) = 1$$

即存在 $h \in \mathcal{H}$ 使得 $h(x_i) = \sigma_i, \forall i = 1, \dots, m$

□ 与 $|\mathcal{H}_D| = 2^m$ ，也即 $\Pi_{\mathcal{H}}(m) = 2$ 类似

□ σ 也可以替换成满足其它分布的随机变量，例如高斯分布

复杂度：Rademacher

根据PAC学习理论，假设空间 $\mathcal{H}$ 越复杂，找到目标概念的难度就越大。一个自然的问题是如何刻画假设空间的复杂度。

■ 经验Rademacher复杂度

□ 更一般地，考虑任意实值函数空间 $\mathcal{F}: \mathcal{X} \mapsto \mathbb{R}$ ，其关于数据集 D 的Rademacher复杂度为

$$\hat{\mathfrak{R}}_D(\mathcal{F}) = \mathbb{E}_{\sigma} \left[\sup_{f \in \mathcal{F}} \frac{1}{m} \sum_{i=1}^m \sigma_i f(x_i) \right]$$

■ 期望Rademacher复杂度

□ 考虑 D 的随机性，对上式求期望可得

$$\mathfrak{R}_m(\mathcal{F}) = \mathbb{E}_{D \sim \mathcal{D}^m} [\hat{\mathfrak{R}}_D(\mathcal{F})]$$

复杂度：Rademacher

根据PAC学习理论，假设空间 $\mathcal{H}$ 越复杂，找到目标概念的难度就越大。一个自然的问题是如何刻画假设空间的复杂度。

■ 线性超平面的Rademacher复杂度

□ 假设数据分布满足 $\|x\| \leq r$ ，则超平面族 $\mathcal{F} = \{x \mapsto w^\top x : \|w\| \leq \Lambda\}$ 满足

$$\hat{\mathcal{R}}_D(\mathcal{F}) \leq \sqrt{\frac{r^2 \Lambda^2}{m}}$$

□ 证明：

$$\begin{aligned} \hat{\mathcal{R}}_D(\mathcal{F}) &= \frac{1}{m} \mathbb{E}_\sigma \left[\sup_w \sum_{i=1}^m \sigma_i w^\top x_i \right] = \frac{1}{m} \mathbb{E}_\sigma \left[\sup_w w^\top \sum_{i=1}^m \sigma_i x_i \right] \\ &\leq \frac{\Lambda}{m} \mathbb{E}_\sigma \left[\left\| \sum_{i=1}^m \sigma_i x_i \right\| \right] \leq \frac{\Lambda}{m} \sqrt{\mathbb{E}_\sigma \left[\left\| \sum_{i=1}^m \sigma_i x_i \right\|^2 \right]} \end{aligned}$$

复杂度：Rademacher

根据PAC学习理论，假设空间 $\mathcal{H}$ 越复杂，找到目标概念的难度就越大。一个自然的问题是如何刻画假设空间的复杂度。

■ 线性超平面的Rademacher复杂度

□ 假设数据分布满足 $\|x\| \leq r$ ，则超平面族 $\mathcal{F} = \{x \mapsto w^\top x : \|w\| \leq \Lambda\}$ 满足

$$\hat{\mathcal{R}}_D(\mathcal{F}) \leq \sqrt{\frac{r^2 \Lambda^2}{m}}$$

□ 证明：

$$\hat{\mathcal{R}}_D(\mathcal{F}) \leq \frac{\Lambda}{m} \sqrt{\mathbb{E}_\sigma \left[\left\| \sum_{i=1}^m \sigma_i x_i \right\|^2 \right]} \leq \frac{\Lambda}{m} \sqrt{\sum_{i=1}^m \|x_i\|^2} \leq \sqrt{\frac{r^2 \Lambda^2}{m}}$$

反映数据相关
特性

泛化性

根据PAC学习理论，学习算法的泛化误差大小可能会依赖于假设空间及数据集的大小。另一个关键的问题是明确这些因素对泛化误差的影响。

■ **有限可分**的假设空间，即目标概念 $c \in \mathcal{H}$ 且 $|\mathcal{H}|$ 有上界

□ 核心思想：在该情况下，任何在数据集 D 上犯错的假设(概念)都不是目标概念，应该将它们剔除

□ 主要结论：当数据集 D 的大小满足 $m \geq \frac{1}{\epsilon} \ln \frac{|\mathcal{H}|}{\delta}$ ，学习算法 $\mathcal{L}$ 只需输出经验误差为0的假设 $h \in \mathcal{H}$ 即可满足

$$P(E(h) \leq \epsilon) \geq 1 - \delta$$

□ 该结论表明，假设空间越大，泛化上界越大，而数据集越大，泛化上界越小，具体以 $O(1/m)$ 的速率收敛

泛化性

根据PAC学习理论，学习算法的泛化误差大小可能会依赖于假设空间及数据集的大小。另一个关键的问题是明确这些因素对泛化误差的影响。

■ 有限可分的假设空间泛化上界证明

□ 若 h 的泛化误差大于 ϵ ，但其经验误差为0，这样的假设存在的概率满足

$$\begin{aligned} P(\exists h \in \mathcal{H}: E(h) > \epsilon \wedge \hat{E}(h) = 0) &\leq \sum_{h \in \mathcal{H}} P(E(h) > \epsilon \wedge \hat{E}(h) = 0) \\ &\leq |\mathcal{H}|(1 - \epsilon)^m \end{aligned}$$

□ 将 $m \geq \frac{1}{\epsilon} \ln \frac{|\mathcal{H}|}{\delta}$ 代入上式，容易得到

$$P(\exists h \in \mathcal{H}: E(h) > \epsilon \wedge \hat{E}(h) = 0) \leq |\mathcal{H}|e^{-\epsilon m} \leq \delta$$

□ 因此，对于经验误差为0的假设有 $P(E(h) \leq \epsilon) \geq 1 - \delta$

泛化性

根据PAC学习理论，学习算法的泛化误差大小可能会依赖于假设空间及数据集的大小。另一个关键的问题是明确这些因素对泛化误差的影响。

■ 有限不可分的假设空间，即 $|\mathcal{H}|$ 有上界但目标概念 $c \neq \mathcal{H}$

□ 无法直接保证 $E(h) \leq \epsilon$ ，但是对于大小为 m 的数据集 D 有

$$P\left(|E(h) - \hat{E}(h)| \leq \sqrt{\frac{1}{2m} \ln \frac{2|\mathcal{H}|}{\delta}}, \forall h \in \mathcal{H}\right) \geq 1 - \delta$$

□ 与可分情况相比，收敛速率从 $O(1/m)$ 降低至 $O(1/\sqrt{m})$ ，即需要更大的数据集才能用经验误差估计泛化误差

泛化性

根据PAC学习理论，学习算法的泛化误差大小可能会依赖于假设空间及数据集的大小。另一个关键的问题是明确这些因素对泛化误差的影响。

■ 有限不可分的假设空间泛化上界证明

□ 考虑存在 $h \in \mathcal{H}$ 使得 $|E(h) - \hat{E}(h)| > \epsilon$ ，相应概率如下

$$P(\exists h \in \mathcal{H}: |E(h) - \hat{E}(h)| > \epsilon) \leq \sum_{h \in \mathcal{H}} P(|E(h) - \hat{E}(h)| > \epsilon)$$

□ 再利用Hoeffding不等式，可以证明

$$P(|E(h) - \hat{E}(h)| > \epsilon) \leq 2e^{-2m\epsilon^2}$$

□ 最后令 $|\mathcal{H}|2e^{-2m\epsilon^2} = \delta$ ，即可解出

$$\epsilon = \sqrt{(1/(2m)) \ln(2|\mathcal{H}|/\delta)}$$

泛化性: VC维

根据PAC学习理论，学习算法的泛化误差大小可能会依赖于假设空间及数据集的大小。另一个关键的问题是明确这些因素对泛化误差的影响。

■ 无限假设空间

□ 若假设空间 $\mathcal{H}$ 的VC维为 k ，当数据集 D 的大小满足 $m > k$ 时有

$$P\left(|E(h) - \hat{E}(h)| \leq \sqrt{\frac{8k \ln \frac{2em}{k} + 8 \ln \frac{4}{\delta}}{m}}, \forall h \in \mathcal{H}\right) \geq 1 - \delta$$

□ 泛化误差的收敛速率为 $O\left(\sqrt{\frac{\ln(m/k)}{m/k}}\right)$

□ 与有限不可分假设空间的 $O(1/\sqrt{m})$ 速率相比，该结果进一步受VC维影响，变得更慢

泛化性: Rademacher

根据PAC学习理论，学习算法的泛化误差大小可能会依赖于假设空间及数据集的大小。另一个关键的问题是明确这些因素对泛化误差的影响。

■ 无限假设空间

□ 对于实值函数空间 $\mathcal{F}: \mathcal{X} \mapsto [0,1]$ ，大小为 m 的数据集 D ，任意 $f \in \mathcal{F}$ 以至少 $1 - \delta$ 的概率有

$$\mathbb{E}[f(h)] \leq \frac{1}{m} \sum_{i=1}^m f(h(x_i)) + 2\mathfrak{R}_m(\mathcal{F}) + \sqrt{\frac{\ln(1/\delta)}{2m}}$$

$$\mathbb{E}[f(h)] \leq \frac{1}{m} \sum_{i=1}^m f(h(x_i)) + 2\hat{\mathfrak{R}}_D(\mathcal{F}) + 3\sqrt{\frac{\ln(1/\delta)}{2m}}$$

优于VC维

□ 以线性超平面为例，有 $\hat{\mathfrak{R}}_D(\mathcal{F}) \leq \sqrt{r^2 \Lambda^2 / m}$ ，因此该速率为 $O(1/\sqrt{m})$

经验风险最小化原则

经验风险最小化(Empirical Risk Minimization, ERM)为找到具有理想泛化误差的假设提供了一种统一范式。

- 学习算法 $\mathcal{L}$ 输出假设空间 $\mathcal{H}$ 中具有最小经验误差的假设 h^*

$$h^* \in \operatorname{argmin}_{h \in \mathcal{H}} \hat{E}(h)$$

- 令 g 表示 $\mathcal{H}$ 中具有最小泛化误差的假设

$$g \in \operatorname{argmin}_{h \in \mathcal{H}} E(h)$$

- 根据Hoeffding不等式可知

$$P\left(|E(g) - \hat{E}(g)| \geq \frac{\epsilon}{2}\right) \leq 2e^{-m\epsilon^2/2}$$

- 假设 $\sqrt{\ln(4/\delta)/(2m)} \leq \frac{\epsilon}{2}$, 则有 $P\left(|E(g) - \hat{E}(g)| \geq \frac{\epsilon}{2}\right) \leq \frac{\delta}{2}$

经验风险最小化原则

经验风险最小化(Empirical Risk Minimization, ERM)为找到具有理想泛化误差的假设提供了一种统一范式。

■ 学习算法 $\mathcal{Q}$ 输出假设空间 $\mathcal{H}$ 中具有最小经验误差的假设 h^*

$$h^* \in \operatorname{argmin}_{h \in \mathcal{H}} \hat{E}(h)$$

□ 假设 $\sqrt{\ln(4/\delta)/(2m)} \leq \frac{\epsilon}{2}$, 则有 $P\left(|E(g) - \hat{E}(g)| \geq \frac{\epsilon}{2}\right) \leq \frac{\delta}{2}$

□ 另外, 根据前面的VC维相关的泛化界理论, 只要

$$\sqrt{\frac{8k \ln \frac{2em}{k} + 8 \ln \frac{8}{\delta}}{m}} \leq \frac{\epsilon}{2}$$

则有 $P\left(|E(h^*) - \hat{E}(h^*)| \leq \frac{\epsilon}{2}\right) \geq 1 - \frac{\delta}{2}$

经验风险最小化原则

经验风险最小化(Empirical Risk Minimization, ERM)为找到具有理想泛化误差的假设提供了一种统一范式。

■ 学习算法 $\mathcal{Q}$ 输出假设空间 $\mathcal{H}$ 中具有最小经验误差的假设 h^*

$$h^* \in \operatorname{argmin}_{h \in \mathcal{H}} \hat{E}(h)$$

□ 结合前面两个不等式，以至少 $1 - \delta$ 的概率有

$$\begin{aligned} E(h^*) - E(g) &\leq \hat{E}(h^*) + \frac{\epsilon}{2} - \hat{E}(g) + \frac{\epsilon}{2} \\ &\leq \hat{E}(h^*) - \hat{E}(g) + \epsilon \\ &\leq \epsilon \end{aligned}$$

□ 这表明，ERM原则找到的假设以大概率是具有最小泛化误差假设的 ϵ 近似

过拟合和欠拟合

根据学习理论，一个好的学习算法应该要能降低训练误差，并且同时缩小训练误差与泛化误差的差距，尽管后者无法直接计算。

■ 欠拟合

- 模型不能在训练集上获得足够低的误差

■ 过拟合

- 训练误差很小，但是泛化误差(测试误差)很大

■ 为了避免欠拟合和过拟合，需要调整模型的容量(Capacity)


- 以1维回归问题，在 $f(x) = wx + b$ 的基础上引入高阶特征

$$f(x) = b + \sum_{i=1}^k w_i x^i$$

过拟合和欠拟合

根据学习理论，一个好的学习算法应该要能降低训练误差，并且同时缩小训练误差与泛化误差的差距，尽管后者无法直接计算。

■ 1维回归问题




奥卡姆剃刀原则：在同样能够解释已知观测现象的假设中，我们应该挑选“最简单”的那一个。

过拟合和欠拟合

根据学习理论，一个好的学习算法应该要能降低训练误差，并且同时缩小训练误差与泛化误差的差距，尽管后者无法直接计算。

■ 容量与误差的典型关系





- **01 机器学习的基本概念**
- **02 经典泛化理论： 深入理解机器学习的一种 “视角”**
- **03 深度学习泛化： 打破经典泛化理论的美好 “假设”**

深度神经网络的泛化误差界

当使用完全随机生成的标签替换CIFAR-10或ImageNet的真实标签时，诸如Inception或AlexNet等模型依然能够通过随机梯度下降（SGD）达到接近0%的训练误差。




Figure 1: Fitting random labels and random pixels on CIFAR10. (a) shows the training loss of various experiment settings decaying with the training steps. (b) shows the relative convergence time with different label corruption ratio. (c) shows the test error (also the generalization error since training error is 0) under different label corruptions.


[1] Zhang et al. Understanding deep learning requires rethinking generalization. In ICLR 2017.

如果一个假设空间能够“打散”（Shatter）随机分配的标签，其Rademacher复杂度将接近于1，这意味着其泛化误差的上界将变得毫无意义。

传统理论失效！

深度神经网络的泛化误差界


随着模型复杂度增加，测试误差先下降、再上升、随后在进入过参数化区域后再次下降。



深度神经网络在函数空间中表现出一种内在的“奥卡姆剃刀”效应。即使参数很多，网络也倾向于表达那些简单的函数

深度神经网络的泛化误差界

模型之所以不产生过拟合，还因为其架构本身内置了极强的“归纳偏置”（Inductive Bias），这些偏置在参数海洋中划定了合理的搜索范围。



CNN的设计基于图像数据的空间平稳性和局部相关性假设。其平移不变性 (Translation Invariance) 和局部感受野 (Local Receptive Fields) 机制将模型的注意力集中在纹理、边缘和形状上，极大地缩小了相对于全连接网络的假设空间。

与CNN不同，Transformer 几乎没有硬编码的空间偏置，它依赖自注意力机制 (Self-Attention) 来学习数据中任意长程的依赖关系。虽然这种灵活性在小规模数据上会导致严重的过拟合 (因为它缺乏先验约束)，但在超大规模数据下，这种微弱的归纳偏置反而释放了模型捕获复杂模式的潜力。

* 基于引用文献 29, 31, 32, 33 的分析

大模型时代， Loss如何继续下降？

讨论时间



对于OpenHospital, 用VC为分析合适还是用Radematcher合适?

传统机器学习理论还有用吗？



VC维和Rademacher 复杂度 对 大语言模型的架构设计、
预训练、后训练有何启发意义

VC维与Rademacher复杂度对大语言模型的启发意义

VC维与Rademacher复杂度作为统计学习理论中衡量模型复杂度与泛化能力的核心指标，为大语言模型（Large Language Models, LLM）的架构设计、预训练与后训练全流程提供了重要的理论指导与实践依据。VC维刻画了模型假设空间的表达能力上限，其对LLM的核心启发在于，模型参数量与VC维呈 $O(N \log N)$ 的正相关关系，这意味着参数量的提升虽能增强模型的语义拟合与复杂推理能力，但也会显著提高模型的过拟合风险，因此LLM的架构设计需在表达能力与复杂度控制之间寻求平衡——稀疏架构（如MoE）通过激活部分专家参数，在维持总参数量优势的同时控制有效VC维，归一化层（LayerNorm）与残差连接则通过规整假设空间，降低模型复杂度的无序增长，这些架构设计并非单纯的工程优化，而是基于VC维理论的合理选择。

Rademacher复杂度则从平均意义上衡量了模型对随机标签的拟合能力，更精准地反映了LLM的泛化性能边界，其对LLM训练的启发更为具体。在预训练阶段，海量文本数据的核心作用的是将随机初始化的低复杂度模型，约束至符合自然语言规律的低有效复杂度空间，通过降低Rademacher复杂度，实现模型泛化能力的显著提升，这也从理论上解释了“模型规模与预训练数据量需同步增长”的实践规律。在后训练阶段（SFT、RLHF、DPO及参数高效微调等），Rademacher复杂度的约束为训练策略的选择提供了明确依据：全量微调因放开所有参数更新，会导致模型假设空间扩张、Rademacher复杂度上升，易引发过拟合与灾难性遗忘；而LoRA等参数高效微调方法通过冻结模型主干、仅更新低秩矩阵，在维持预训练阶段低复杂度的前提下实现任务适配，有效控制了泛化风险；RLHF与DPO则通过对齐模型输出偏好，进一步缩小假设空间、提升函数空间的平滑性，降低Rademacher复杂度，确保模型输出的稳定性与泛化性。

综上，VC维明确了LLM的能力上限与复杂度控制边界，Rademacher复杂度则精准指导了模型泛化性能的优化路径，二者共同构建了LLM“复杂度-数据-泛化”的三角理论框架，为LLM的架构创新、训练策略优化提供了坚实的理论支撑，也为解决大模型过拟合、泛化不足等核心问题提供了明确的理论指引。

CoT

RL

机器学习的未来在哪？

Context

Skill